



Лекция 02

Данные и эксплоративный анализ как основа качества ML-решения

«Начинать всегда с данных, а не с модели»

Курс «Машинное обучение и безопасность систем»

НИУ ВШЭ · МИЭМ · ОП «Информационная безопасность и технологии ИИ» · 1 курс магистратуры

Автор: Силаев Ю. В. · Время изучения: ~65 минут · 50 слайдов



О чём эта лекция за минуту

2 / 50

Часть 1 · Введение

Ключевая установка курса, с которой начинается работа с любой ML-задачей

Начинающий инженер берёт датасет, запускает обучение и получает высокое значение метрики. Через месяц в эксплуатации модель оказывается бесполезной – оценка качества была завышена дубликатами, разметка содержала систематические ошибки, а распределение признаков давно изменилось.

Все эти проблемы существовали в данных до выбора модели. Они были видны при первом внимательном просмотре датасета. Опытный инженер посмотрел бы на данные и обнаружил их за час разведочного анализа – но этого часа в графике проекта не было.

Эксплоративный анализ данных (EDA) – это именно тот час. Это привычка начинать ML-задачу с разбора данных и фиксации их свойств, а не с подбора модели и тюнинга гиперпараметров. Особенно важно в задачах информационной безопасности, где данные почти никогда не ведут себя как в учебном курсе по ML.

ИТОГ ЛЕКЦИИ

После лекции вы будете

смотреть на любой ИБ-датасет и видеть, что в нём пошло не так, ещё до того, как первая модель обучена.

Это входной билет ко всем последующим темам курса: постановке задачи, метрикам, валидации, моделям.



Учебные результаты лекции

После изучения этой лекции вы научитесь:

- 1.** описывать датасет в терминах объекта наблюдения, признаков, целевой переменной и единицы анализа;
- 2.** выявлять базовые проблемы качества данных: пропуски, дубликаты, выбросы, несогласованности, шум разметки;
- 3.** различать содержательный выброс и ошибку данных – критический навык для задач ИБ;
- 4.** проверять полноту, согласованность и целостность датасета на уровне базовых эмпирических процедур;
- 5.** формулировать проверяемые гипотезы о данных и фиксировать ограничения выборки до выбора модели;
- 6.** объяснять, почему в ИБ-данных наблюдения часто зависимы, а распределение признаков может меняться;
- 7.** вести минимальный журнал EDA, по которому результат разведочного анализа можно воспроизвести и пересмотреть.



Что нужно знать до начала

4 / 50

Часть 1 · Введение

Предварительные требования и место лекции в курсе

Статистика

Базовый уровень: распределения, оценки, описательные статистики, представление о выборочной природе данных.

Линейная алгебра

Векторы и матрицы, скалярное произведение. Признаки объекта будем записывать как вектор $x \in \mathbb{R}^d$.

Python и pandas

Чтение CSV, фильтрация, группировки, базовая работа с DataFrame. Установленное окружение (Jupyter или аналог).

Концепции ИБ

Знакомство с основными видами угроз, понятиями актива и модели угроз на уровне общей грамотности.

МЕСТО В КУРСЕ

Блок 0 – Вводный

← L01

Введение в курс

→ Это L02

Данные и EDA

→ L03

Постановка задач ML в ИБ

→ L04

Метрики и цена ошибок

→ L05

Валидация и leakage



План лекции

5 / 50

Часть 1 · Введение

Семь частей. Каждая часть читается автономно

№	Часть	Слайды	Кол-во	Время
1	Введение в лекцию	1-5	5	~6 мин
2	Мотивация	6-10	5	~6 мин
3	Основное содержание	11-39	29	~35 мин
4	Связки с практикой ИБ	40-44	5	~7 мин
5	Итоги	45-47	3	~3 мин
6	Источники для углубления	48-49	2	~2 мин
7	Глоссарий	50	1	~2 мин

Сквозной номер слайда и маркер части – в правом верхнем углу каждого слайда.

Подвал с номером и названием лекции – внизу слева.

ВСЕГО

50

слайдов

~65

минут изучения



Почему ML-проект, начатый с модели, обычно проваливается

Типичный сценарий и где именно в нём прячется ошибка

1

Студент берёт датасет

Скачивает публичный набор данных, читает CSV в DataFrame, бегло смотрит первые строки. Распределения, источники данных, способ разметки — не разбираются.

2

Гонит в xgboost

Пайплайн обучения собирается за полчаса. Случайный split 80/20, gradient boosting со значениями параметров по умолчанию, кросс-валидация на 5 фолдах.

3

Получает AUC 0.99

Метрика выглядит впечатляюще. Студент пишет отчёт о высоком качестве модели и рекомендует её к развёртыванию. Менеджер проекта доволен результатом.



ЧТО ОБНАРУЖИВАЕТСЯ ЧЕРЕЗ МЕСЯЦ В ЭКСПЛУАТАЦИИ

Дубликаты flow между train и test завысили оценку. **Шум разметки** оказался систематическим — два аналитика SOC расходились в 18% тикетов. **Распределение признаков** после обновления сетевой инфраструктуры изменилось, и модель видит уже не те данные, на которых обучалась. Все три проблемы были видны при первом часе EDA — но этого часа в графике проекта не было.



ИБ-кейс: AUC 0.99, который ничего не значит

7 / 50

Часть 2 · Мотивация

Как модель выучивает артефакт сбора данных вместо признаков атаки

ИБ-КЕЙС

Детектор HTTP-флуда на собранных в лоб данных

ПОСТАНОВКА

Команда собирает датасет HTTP-запросов: атакующий трафик генерируется в стенде нагрузочным инструментом в течение часа, легитимный – снимается с боевого балансировщика в произвольные часы рабочего дня.

Объединяют, добавляют метку attack/benign, перемешивают, делят 80/20. Обучают gradient boosting на 40 признаках TCP/HTTP.

ЧТО ОБНАРУЖИВАЕТ ВНИМАТЕЛЬНЫЙ ПРОСМОТР

AUC на тесте = 0.992. Но топовые признаки по важности – **не размер пакета и не TTL, а час дня и source IP.**

Стенд атаки работал в 14:00-15:00 с одного диапазона адресов. Легитимный трафик – в произвольные часы с тысяч IP. Модель идеально различает «час сбора» и «диапазон стенда», а не атаку.

Мораль: EDA по «час дня» и по «source IP» до начала обучения обнаружил бы эту проблему за пять минут. Модель её не обнаружила и обнаружить не могла.



CIC-IDS-2018 – карточка-напоминание. Первое появление в курсе

ИБ-КЕЙС · СКВОЗНОЙ ДАТАСЕТ

CIC-IDS-2018

Публичный датасет сетевого трафика от Canadian Institute for Cybersecurity (Университет Нью-Брансуик). Записан в виде агрегированных flow-сессий за десять рабочих дней. Используется как сквозной пример для всего курса – на нём мы будем разбирать EDA, метрики, валидацию, моделирование, аномалии, временную структуру, дрейф.

~16 млн

flow-записей

10

рабочих дней

80

признаков

14 + 1

типов атак + Benign

ГДЕ ВСТРЕТИТСЯ В КУРСЕ: L02 · L04 · L05 · L07 · L08 · L09 · L10 · L11 · L12 · L17 · L18

Источник: A. Sharafaldin, A. H. Lashkari, A. A. Ghorbani. Canadian Institute for Cybersecurity, UNB, 2018. unb.ca/cic/datasets/ids-2018.html



Что происходит в реальных ИБ-системах, когда час разведочного анализа сэкономили

Пропуск EDA редко проявляется сразу. Модель проходит приёмочные тесты, развёртывается и работает. Проблема обнаруживается тогда, когда её уже дорого исправлять – в эксплуатации, при разборе инцидента или при попытке воспроизвести результат на новых данных. Четыре характерных сценария:

Ложные тревоги в проде

Распределение признаков в обучающей выборке не соответствовало эксплуатационному. Аналитики SOC получают сотни false positives в сутки и через две недели начинают игнорировать оповещения модели.

Тихий дрейф

Модель обучена на трафике до обновления инфраструктуры. После обновления качество медленно деградирует. Без понимания, какие срезы данных нестабильны, причину дрейфа найти невозможно.

Невоспроизводимый разбор инцидента

При post-mortem нужно понять, почему модель пропустила атаку. Но журнала свойств данных нет, исходный датасет уже изменился, и установить, что модель видела в обучении, нельзя.

Утечка через дубликаты

Один и тот же поток событий попал и в train, и в test. Метрика на отложенной выборке была завышена. В эксплуатации качество оказалось существенно ниже заявленного – и претензии идут к команде.



Установка, на которой строится весь курс

ОПРЕДЕЛЕНИЕ · КЛЮЧЕВОЙ ТЕЗИС

Эксплоративный анализ данных (EDA)

– это способ обнаружить проблемы данных и сформулировать проверяемые гипотезы о них до того, как модель и её метрики начнут эти проблемы маскировать.

Что в этой формулировке важно:

EDA – не украшение отчёта. Это не «нарисовать пять красивых графиков на финальном слайде». Это рабочая процедура, у которой есть вход, выход и журнал.

EDA – не подготовка к моделированию. Это самостоятельный этап, после которого вы можете решить, что от моделирования вообще стоит отказаться или что задача поставлена некорректно.

EDA проводится до выбора модели и метрик. Иначе и модель, и метрика начнут компенсировать дефекты данных, делая их менее заметными. Это самый опасный режим работы – модель «работает», но не на тех закономерностях.



БЛОК 1 ИЗ 4 · ОСНОВНОЕ СОДЕРЖАНИЕ

3.1

Анатомия датасета

Базовые термины, без которых разговор о EDA невозможен. Объект наблюдения, единица анализа, признаки, целевая переменная, источник данных – пять вопросов, на которые отвечаем до того, как открыли датасет в pandas.

В БЛОКЕ: объект и единица · признаки и цель · источники · ошибка · резюме 6 слайдов · ~7 мин



Объект наблюдения и единица анализа

Что именно считается одной строкой датасета

ОПРЕДЕЛЕНИЕ

Объект наблюдения — сущность, о которой собирается информация в датасете.

Единица анализа — уровень агрегации, на котором эта сущность представлена одной строкой и одной меткой.

Зачем это важно

Один и тот же поток сырых событий можно агрегировать на разных уровнях: пакет, flow, сессия, пользователь, устройство. Каждый выбор — это разный датасет, разные признаки и разный смысл метрики качества.

Решение принимается **до сбора данных**, потому что от него зависит, как считать признаки и формировать выборки.

ПРИМЕР · СЕТЕВЫЕ ДАННЫЕ

- 1** **Пакет** — 1 строка = 1 IP-пакет
- 2** **Flow** — 1 строка = 1 поток
- 3** **Сессия** — 1 строка = 1 пользовательская сессия
- 4** **Устройство** — 1 строка = 1 устройство за окно

Это четыре разных датасета на одних и тех же сырых данных.



Признаки и целевая переменная

Базовая нотация, в которой курс будет говорить о данных и моделях

ОПРЕДЕЛЕНИЕ · НОТАЦИЯ КУРСА

Признаки (features) – измеримые свойства объекта наблюдения, по которым строится предсказание. Вектор $\mathbf{x} \in \mathbb{R}^d$, d – размерность.

Целевая переменная (target) – величина y , которую модель должна предсказывать.
В бинарной классификации обычно $y \in \{0, 1\}$.

Примеры для разных ИБ-задач

Задача	Объект (1 строка)	Признаки $\mathbf{x}$	Цель y
Обнаружение сетевой атаки	1 flow между парой адресов	длительность, байты, пакеты, флаги TCP, порты	<i>Benign / mup атака</i>
Классификация ВПО	1 PE-файл	размер, энтропия секций, импорты, метаданные	<i>семейство ВПО / clean</i>
Детекция фишинга	1 URL после нормализации	длина, домен 1-го уровня, наличие IDN, возраст домена	<i>phishing / benign</i>
Приоритизация SOC-тикетов	1 тикет	источник, тип события, текст, история пользователя	<i>true positive / false positive</i>



Источники данных и риски маршрута

Каждый этап получения датасета вносит свои артефакты – и модель их выучит

Датасет не возникает сразу. Он проходит четыре этапа: сбор сырых событий → парсинг и приведение к табличному виду → агрегация на уровень единицы анализа → разметка. На каждом этапе появляются артефакты, которые в готовом CSV выглядят как «настоящие» признаки. Модель не отличит признак от артефакта и выучит то, что больше коррелирует с меткой.



Вывод для EDA: *знать происхождение датасета – часть разведочного анализа. Без этого нельзя отличить признак от артефакта маршрута.*



Частая ошибка: «строка CSV – это объект»

Почему сама структура файла не отвечает на вопрос об объекте

ЧАСТАЯ ОШИБКА

«У меня CSV-файл с логами аутентификации. Каждая строка – одно событие входа. Значит, объект наблюдения – строка, а признаки беру по всем столбцам этой строки.»

ПОЧЕМУ ЭТО НЕВЕРНО

Объект наблюдения определяется задачей, а не файлом. Для «обнаружить компрометацию учётной записи» объект – пользователь за окно времени, а не отдельное событие. Признаки агрегируются (число входов за час, доля неуспешных), а строка CSV – лишь сырое событие.

Одни и те же auth-логи – три разных задачи – три разных объекта

Обнаружение брутфорса

Пара (источник, аккаунт) за окно 5 мин

Компрометация аккаунта

Пользователь за окно 1 день

Аномалия входа

Одно событие входа (строка CSV)



Мини-резюме: анатомия датасета

16 / 50

Часть 3 · Основное содержание

Пять вопросов, на которые надо ответить до того, как открыть первый CSV

Если на любой из этих пяти вопросов вы не можете ответить – EDA начинать рано. Сначала уточняем постановку, потом смотрим данные.

- 1 Что такое объект наблюдения?** *Сущность, о которой собираются данные. Решение принимается задачей, не файлом.*
- 2 Какова единица анализа?** *Уровень агрегации: пакет / flow / сессия / пользователь / устройство.*
- 3 Что является признаками x ?** *Измеримые свойства объекта, вектор размерности d . Записываются после выбора единицы анализа.*
- 4 Что является целевой переменной y ?** *Величина, которую модель должна предсказывать. В курсе по умолчанию – бинарная классификация.*
- 5 Каков источник и маршрут данных?** *Сбор → парсинг → агрегация → разметка. Каждый этап вносит артефакты, которые модель может выучить.*



БЛОК 2 ИЗ 4 · ОСНОВНОЕ СОДЕРЖАНИЕ

3.2

Четыре компонента качества данных

Качество данных раскладывается на четыре независимых вопроса. На каждый из них в EDA должен быть отдельный ответ. Это центральный блок лекции – будут даны MCAR/MAR/MNAR и разбираются конкретные дефекты в CIC-IDS-2018.

В БЛОКЕ: полнота · MCAR/MAR/MNAR · кейс CIC-IDS-2018 · согласованность · целостность · актуальность 9 слайдов · ~11 мин



Полнота: пропуски и их типология

MCAR, MAR, MNAR – на прикладном уровне (без формальной статистики)

Пропуск – это не просто «пустая ячейка». От причины пропуска зависит, что с ним делать: игнорировать, заполнить, использовать сам факт пропуска как признак, или отказаться от строки. Прикладная типология – три варианта механизма пропусков.

MCAR

Missing Completely At Random

Вероятность пропуска не зависит ни от наблюдаемых, ни от ненаблюдаемых значений. Пропуск чисто случайный.

Пример: Сбой коллектора на 30 секунд – потеряны записи во всех потоках без привязки к их свойствам.

Низкий: можно удалить, не сместит выборку.

MAR

Missing At Random

Вероятность пропуска зависит от наблюдаемых признаков, но не от самого пропущенного значения.

Пример: Поле «User-Agent» отсутствует чаще у мобильных клиентов – пропуск объясним через тип устройства.

Средний: импутация по группам, без удаления.

MNAR

Missing Not At Random

Вероятность пропуска зависит от самого пропущенного значения. Пропуск содержит информацию.

Пример: Подозрительный процесс активно скрывает поле «parent_pid» – пропуск сам по себе признак атаки.

Высокий: пропуск – это признак. Удаление искажает.



Как пропуски выглядят на датасете курса

ИБ-КЕЙС · СКВОЗНОЙ ДАТАСЕТ

Скоростные признаки flow и деление на ноль

ЧТО НА САМОМ ДЕЛЕ В ДАННЫХ

В CIC-IDS-2018 два признака – **Flow Bytes/s** и **Flow Packets/s** – вычисляются как «байты ÷ длительность» и «пакеты ÷ длительность».

Если flow длится 0 микросекунд (быстрый одиночный пакет), знаменатель равен нулю. В CSV это даёт **+Infinity** или **NaN** – и в датасете таких строк миллионы.

ДИАГНОЗ ПО ТИПОЛОГИИ MCAR/MAR/MNAR

Это не MCAR. Пропуск возникает там, где **длительность = 0**, то есть зависит от наблюдаемого признака. **Это MAR.**

Игнорировать (модели не примут **+inf**) или заменить на 0 – обе крайности неверны.

Правильный шаг EDA: зафиксировать в журнале долю строк с **+inf** по дням, понять закономерность.

Связь с курсом: техническая реализация обработки через *sklearn Pipeline* и *ColumnTransformer* – в L10.



Частая ошибка: `dropna()` как первый шаг

Почему автоматическое удаление строк с пропусками смещает выборку

ЧАСТАЯ ОШИБКА

«В датасете есть пропуски, я не хочу с ними возиться – просто вызываю `df.dropna()` и обучаю модель на оставшихся данных.»

ПОЧЕМУ ЭТО НЕВЕРНО

Удаление работает корректно только при MCAR – а это редкий случай. При MAR удаление смещает выборку: класс, в котором пропуск чаще, будет недопредставлен. При MNAR удаление выкидывает именно те объекты, в которых пропуск содержит сигнал о цели.

Что делать вместо автоматического `dropna()`

1 Сначала диагностика

Доля пропусков, распределение по группам, корреляция с целью и другими признаками.

2 Потом гипотеза о типе

MCAR / MAR / MNAR? Гипотеза проверяется на конкретных срезах данных.

3 Только потом действие

Удаление, импутация, признак-индикатор или отдельная модель – по типу.



Согласованность: одно поле – много форм

Тихие дефекты, которые не дают пропусков и не дают ошибок парсинга

Несогласованность – это не пропуск и не ошибка формата. Все строки на месте, файл читается, но одно и то же поле обозначает разные сущности или хранится в разных формах. Модель в обучении видит их как разные значения, в эксплуатации – снова, и каждый раз учит «новую» закономерность.

Четыре характерных источника несогласованности

Источник	Как выглядит	Пример в ИБ-данных
Единицы измерения	Один признак в разных строках в разных единицах	<i>Размер файла: байты, КБ, МБ в одном столбце</i>
Форматы	Одно значение записано по-разному	<i>IP-адрес: 192.168.1.1, 192.168.001.001, ::ffff:c0a8:101</i>
Временные зоны	Время без явного указания TZ – или смещение зон	<i>auth-логи с разных серверов: UTC, Europe/Moscow, local</i>
Справочники	Одна сущность под разными именами – или разные под одним	<i>Категория атаки: «DDoS», «DoS», «Denial-of-Service»</i>



Целостность: дубликаты и почти-дубликаты

Самый частый источник завышенной оценки качества модели

Дубликат – это два объекта, которые модель считает разными, а они представляют одну и ту же сущность. Бывают трёх видов. С точки зрения EDA опасны все три, но обнаруживаются по-разному.

Точные дубликаты

Полностью идентичные строки. Появляются от дублирующих коллекторов, повторного импорта, сбоев конвейера.

Как ищем: `df.duplicated()` – мгновенно.

Низкая стоимость обнаружения, высокая – пропуска.

Нормализованные дубликаты

Различаются по форме, но один и тот же объект: URL с trailing slash и без; домен в разном регистре; IP в IPv4 и IPv4-mapped IPv6.

Как ищем: Сначала нормализация полей – потом `dedup`.

Требуют разбора домена. Самые коварные.

Частичные дубликаты

Совпадают по подмножеству ключей, но отличаются в незначимых полях (timestamp, request_id). Один и тот же flow в двух коллекторах.

Как ищем: `Dedup` по выбранным ключам.

Решение зависит от задачи.

Мост к L05: опасность дубликатов между будущими *train* и *test* (когда «один и тот же объект» оказался в обеих выборках) – отдельная тема. Корректный *split* разберём в L05.



Частая ошибка: дубликаты — это мелочь

Почему пропуск этого шага EDA даёт ложно высокую метрику

ЧАСТАЯ ОШИБКА

«Несколько одинаковых строк в датасете — это техническая мелочь. Модель и так разберётся. Главное — общий объём данных большой.»

ПОЧЕМУ ЭТО НЕВЕРНО

При случайном split одна и та же строка с высокой вероятностью оказывается и в train, и в test. Модель «угадывает» по тестовой выборке потому, что уже видела эти объекты в обучении. Качество на тесте оказывается завышенным, в эксплуатации — резко падает. Дубликат не уменьшает шумность данных, а имитирует обобщение.

Числовой пример: что показывает метрика на дубликатах

С дубликатами (наивно)

AUC на тесте = **0.992** в эксплуатации = **0.71**

После dedup

AUC на тесте = **0.84** в эксплуатации = **0.82**



Актуальность: «свежие данные» в ИБ

Почему датасет полугодовой давности может быть уже непригоден

Актуальность – четвёртый компонент качества, специфичный для ИБ. Распределение признаков и состав угроз меняются непрерывно: появляются новые семейства ВПО, обновляется инфраструктура, меняются техники атак. Модель, обученная на «устаревшем» датасете, в эксплуатации видит совсем другие данные.

Обновление инфраструктуры

Сменили DNS-резолвер – изменились паттерны DNS-запросов.
Поставили новый прокси – у трафика появилась подпись прокси.

Новые техники атак

TTPs (tactics, techniques, procedures) меняются: то, что было нормой год назад, сегодня – индикатор компрометации.

Изменения нормального поведения

Сезонность, переход на удалённую работу, новые рабочие сервисы.
«Нормальный» трафик 2023 года ≠ нормальный сегодня.

Устаревание справочников

Базы доменов, репутаций IP, индикаторов компрометации стареют за дни. То, что было индикатором malware, может уже не работать.

Мост к L17: систематическое изменение распределения данных называется **drift** – это отдельная тема устойчивости моделей в эксплуатации.



Мини-резюме: четыре компонента качества

Четыре независимых вопроса к датасету – каждый требует ответа в журнале EDA

П

Полнота

Вопрос: Где и почему пропуски?

MCAR / MAR / MNAR. Не dropna() как первый шаг.

С

Согласованность

Вопрос: Все ли значения одного признака – одна сущность?

Единицы, форматы, временные зоны, справочники.

Ц

Целостность

Вопрос: Нет ли скрытых дубликатов?

Точные, нормализованные, частичные. Особо опасны между train и test.

А

Актуальность

Вопрос: Не устарел ли датасет?

Инфраструктура, TTPs, сезонность, справочники. См. L17 о drift.



БЛОК 3 ИЗ 4 · ОСНОВНОЕ СОДЕРЖАНИЕ

3.3

Выбросы, шум разметки, дисбаланс

Три тесно связанных явления, которые часто путают. В задачах ИБ они особенно опасны: выброс может быть именно той атакой, ради которой собран датасет; разметка часто противоречива между аналитиками; положительный класс редкий по своей природе.

В БЛОКЕ: выбросы и IQR · кейс flow CIC-IDS-2018 · ошибка автоудаления · шум разметки · кейс SOC-тикетов · дисбаланс 8 слайдов · ~10 мин



Выброс: ошибка или содержательное событие?

Уникальное различие для L02. Самое опасное упрощение – стирать оба

ОПРЕДЕЛЕНИЕ

Выброс (outlier) – наблюдение, существенно отклоняющееся от основной массы данных. В EDA различаем два принципиально разных случая: **выброс-ошибка** (дефект сбора или ввода данных) и **выброс-событие** (редкое, но содержательное наблюдение).

ВЫБРОС-ОШИБКА

Откуда: сбой парсера, единица измерения не та, артефакт сбора, опечатка ввода.

Что делать: разобрать причину, исправить источник, удалить или заменить в датасете.

Пример: длительность flow = 18 446 744 073 709 микросекунд (переполнение uint64 при отрицательной разности времён).

ВЫБРОС-СОБЫТИЕ

Откуда: редкое реальное наблюдение – атака, аномальная сессия, новый тип события.

Что делать: оставить в данных, отметить, при необходимости – выделить в отдельный класс.

Пример: flow длиной 6 часов с одного host – это сессия RDP-туннелирования в датасете, ради которого мы и собирали данные.



Базовая статистика выбросов: правило IQR

Простой инструмент первичной диагностики (но именно инструмент, а не приговор)

ФОРМУЛА · ПРАВИЛО IQR ТЬЮКИ

$$IQR = Q_3 - Q_1$$

«Нормальная» область: $[Q_1 - 1.5 \cdot IQR , \quad Q_3 + 1.5 \cdot IQR]$

Q_1, Q_3 – первый и третий квартили; всё за границей – кандидат в выбросы.

Длинный правый хвост

Многие ИБ-признаки (длительность flow, размер файла) имеют сильно скошенное распределение. До IQR применяем log-преобразование – оно «выпрямляет» хвост.

Подходит не всегда

IQR – только для непрерывных признаков с относительно унимодальным распределением. Для категориальных, временных, мультимодальных нужны другие подходы.

Это диагностика, не действие

Попадание в «хвост» по IQR – повод присмотреться, а не повод удалить. Решение «выброс – ошибка или событие» принимаем после содержательного разбора.



Кейс: хвост Flow Duration в CIC-IDS-2018

29 / 50

Часть 3 · Основное содержание

Где IQR говорит «выброс», а домен – «именно это и нужно»

ИБ-КЕЙС · СКВОЗНОЙ ДАТАСЕТ

Распределение Flow Duration: что говорит IQR и что – домен

ЧТО ГОВОРИТ IQR

Признак **Flow Duration** в CIC-IDS-2018 имеет ярко выраженный правый хвост: медианное значение – порядка миллисекунд, но десятки процентов flow длятся часы.

По правилу Тьюки в кандидаты в выбросы попадает ~5-8% строк. На log-шкале хвост по-прежнему длинный.

ЧТО ГОВОРИТ ДОМЕН ИБ

Длинные flow – это часто именно **то, что детектируем**: slow-rate DDoS, медленный exfiltration, RDP-туннели, C2 beaconing с долгими keep-alive.

Удалить хвост = удалить положительный класс из обучения.

Вывод: статистический критерий – это сигнал к разбору, а не команда на удаление. Решение принимает доменный анализ, а не IQR.



Частая ошибка: удалить выбросы автоматом

Почему в ИБ это особенно опасно

ЧАСТАЯ ОШИБКА

«Берём IQR-границы, всё, что за ними, – отбрасываем. Это «выбросы», они шумят. После очистки модель учится лучше – метрика растёт.»

ПОЧЕМУ ЭТО НЕВЕРНО

В ИБ-датасетах выброс часто – именно то, что мы детектируем. Slow-rate DDoS с длинными flow, аномальный объём загрузки данных с одного host, нестандартный размер процесса в памяти – статистически это «хвост», содержательно – это цель задачи. Удалив их, мы получаем чистенький датасет нормального трафика и модель, которая не способна детектировать атаку – потому что не видела ни одной.

Правильная последовательность шагов с выбросом

1 Обнаружить

IQR, log-шкала, разрезы по подгруппам.
Получить кандидатов.

2 Разобрать причину

Ошибка данных или редкое содержательное событие? Смотрим конкретные строки.

3 Решить и зафиксировать

Удалить как ошибку, оставить как событие, или сделать признак-индикатор. Запись в журнал EDA.



Метка у тоже может быть неверной – и это отдельный источник проблем в ML

ОПРЕДЕЛЕНИЕ

Шум разметки (label noise) – расхождение между **истинным значением целевой переменной** объекта и тем значением, которое записано в датасете. Шум разметки невозможно полностью устранить – его можно **оценить, локализовать и учесть в выборе модели и метрик**.

Ошибка аннотатора

Человек устал, не понял контекст, кликнул не туда. Случайная одиночная ошибка в одной строке.

Пример: Аналитик SOC поставил «benign» на скриншоте с явным фишингом – банальная невнимательность.

Редко, но накапливается.

Межаннотаторное расхождение

Разные размечающие систематически расходятся в одной и той же ситуации – обычно из-за нечёткой инструкции.

Пример: Один аналитик помечает «brute force после 5 неудач», другой – после 20. Метки разных серверов несравнимы.

Системно. Самый частый и опасный источник.

Запаздывающая или частичная разметка

Истинная метка станет известна позже наблюдения – или вообще не для всех объектов.

Пример: О компрометации узнали через 90 дней после события. До этого все события класса не были размечены как «атака».

Искажает оценку качества и временную валидацию.



Кейс: тикеты SOC от трёх аналитиков

Что увидит EDA в датасете, где разметка делается людьми

ИБ-КЕЙС · ШУМ РАЗМЕТКИ

Один и тот же инцидент – три разных вердикта

ПОСТАНОВКА

Датасет: 12 000 SOC-тикетов за квартал, размеченных тремя аналитиками – А, В, С. Каждый тикет видит один аналитик и ставит вердикт:

TP (true positive – атака), **FP** (false positive – ложная тревога), **Triage** (требуется дополнительной проверки).

ЧТО ОБНАРУЖИВАЕТ EDA

В дублирующейся подвыборке (тикеты, на которые случайно посмотрели двое):

- А и В расходятся в **18%** тикетов
- А и С расходятся в **11%** тикетов

Аналитик С чаще ставит **Triage** там, где А решительно ставит **FP**. Граница «доп. проверка/ложная тревога» – нечёткая.

Что это значит для модели: минимум 11-18% «правильных» меток в датасете заведомо ненадёжны. Это потолок качества, выше которого модель просто не сможет учиться – независимо от архитектуры.



Положительный класс почти всегда редкий – и это свойство задачи, а не дефект

В типичных ИБ-задачах атаки составляют доли процента от всего трафика. Дисбаланс классов – это не «проблема данных, которую надо лечить», а свойство задачи, которое влияет на выбор метрик, валидации и архитектуры решения.

ТИПИЧНЫЕ ПРОПОРЦИИ В ИБ-ДАННЫХ

Детекция фишинга в почте	~ 1 на 10^3
Обнаружение malware в файлах	~ 1 на 10^4
Сетевые атаки в трафике	~ 1 на 10^5
Компрометация учётной записи	~ 1 на 10^6

ЧТО ИЗ ЭТОГО СЛЕДУЕТ

- 1** Ассурасу бесполезна. Модель «всегда нет» даёт 99.99%.
- 2** Нужны метрики, ориентированные на редкий класс: precision/recall, PR-AUC, метрика @top-k.
- 3** Положительный класс часто размечен отсроченно и/или частично.
- 4** Для очень редкого класса разумно рассматривать задачу как поиск аномалий, а не классификацию.

Мост к L04: выбор метрик для редкого класса – отдельная тема.

Мост к L11: при экстремальном дисбалансе переходим от классификации к anomaly detection.



ИЗ ПРЕДЫДУЩЕГО БЛОКА

В блоке 3.3 разобрали три явления, которые часто путают: **выбросы** (ошибка или содержательное событие?), **шум разметки** (систематические расхождения аналитиков), **дисбаланс классов** (свойство задачи, а не дефект данных).



БЛОК 4 ИЗ 4 · ОСНОВНОЕ СОДЕРЖАНИЕ

3.4

От «посмотрел» к «зафиксировал»

Проблемы мы научились видеть. Теперь – как их искать систематически и фиксировать так, чтобы результат был воспроизводим.

В БЛОКЕ: визуализации · зависимость наблюдений · ошибка «корреляция = доказательство» · журнал EDA *6 слайдов · ~7 мин*



Минимальный набор, который надо построить для любого датасета

Шесть видов визуализаций покрывают 90% задач разведочного анализа. Можно использовать seaborn (на основе matplotlib) – он позволяет получить эти графики в одну-две строки кода.

Гистограмма

Распределение одного числового признака

Когда: Первый взгляд: форма распределения, моды, скос, хвосты.

ECDF

Эмпирическая функция распределения

Когда: Когда нужны конкретные квантили – медиана, 95-й перцентиль.

Boxplot по группам

Сравнение распределений в разрезах

Когда: Сравнить признак по классам, дням, источникам, версиям.

Scatter / hexbin

Совместное распределение двух признаков

Когда: Найти линейные и нелинейные связи, кластеры, артефакты.

Корреляционная матрица

Попарные корреляции

Когда: Скрининг признаков на коллинеарность и сильные связи с целью.

Временной ряд

Признак во времени

Когда: Найти сезонность, дрейф, разрывы, обусловленные сбором.



Зависимость наблюдений: почему интуиция ломается

Учебные датасеты обычно из независимых наблюдений. ИБ-данные – почти никогда

Базовое допущение классического ML – наблюдения независимы и одинаково распределены (i.i.d.). В ИБ-данных это допущение нарушено по умолчанию. Зависимость наблюдений обнаруживается на EDA – и должна быть учтена при выборе split, метрики и архитектуры.

T

По времени

События одного flow, одной сессии, одной кампании коррелируют друг с другом. Случайный shuffle между train и test смешает их.

U

По пользователю / устройству

Все события одного пользователя в auth-логах – это, по сути, одно «наблюдение» для модели пользовательского поведения.

C

По кампании / атакующему

Тысячи фишинговых писем одной рассылки используют один шаблон. Учить и тестировать на одной кампании – то же, что на одной строке.

S

По источнику данных

Логи с разных серверов могут иметь разную нормализацию и временные смещения. Внутри одного источника наблюдения скоррелированы.

Мост к L05: *правильный split при зависимости – это не случайное перемешивание, а группированный/временной split. Корректный split при зависимости разберём в L05.*



Частая ошибка: график – это доказательство

Почему «вижу закономерность» ≠ «закономерность существует»

ЧАСТАЯ ОШИБКА

«На графике видно: длительность flow коррелирует с типом атаки. Это и будет основным признаком модели – закономерность подтверждена визуально.»

ПОЧЕМУ ЭТО НЕВЕРНО

Визуализация – это снимок данных, а не закон природы. На случайной выборке возникают мнимые корреляции; на одном источнике видны артефакты сбора; красивый паттерн на скриншоте может исчезнуть на следующем дне. Корреляция не равна причинности, паттерн на снимке не равен закономерности в популяции. Визуализация – повод сформулировать гипотезу, а не приговор для модели.

Как проверить, что увиденное – не артефакт

1 Воспроизводимость

Тот же паттерн виден по разным дням, источникам, подгруппам – или только на одном срезе?

2 Доменное обоснование

Есть ли содержательное объяснение, почему так должно быть? Или это просто «глазами кажется»?

3 Устойчивость к выборке

Если повторить EDA на другой выборке тех же данных – паттерн остаётся или растворяется?



Журнал EDA: обязательный артефакт

38 / 50

Часть 3 · Основное содержание

Суть содержания L02. После лекции надо сделать шаблон, который вы заполняете для каждого датасета

ОПРЕДЕЛЕНИЕ

Журнал EDA – документ, фиксирующий, какие проверки данных были выполнены, какие проблемы найдены, какие гипотезы сформулированы и какие ограничения датасета принимаются как данность. Это **вход в постановку задачи и валидацию**, а не отчёт о проделанной работе.

Минимальная структура журнала EDA

01

Описание датасета

Объект наблюдения, единица анализа, признаки, целевая переменная, источник, период сбора, размер.

02

Найденные проблемы

Пропуски (с типом MCAR/MAR/MNAR), несогласованности, дубликаты, выбросы, шум разметки, дисбаланс.

03

Сформулированные гипотезы

Что мы предполагаем о данных и что собираемся проверять. Не утверждения, а проверяемые формулировки.

04

Ограничения и риски

Что мы НЕ знаем о данных. Какие допущения принимаем. Что нужно перепроверить при изменении данных.



Мини-резюме блока: смотреть и фиксировать

Полный цикл EDA как конвейер из четырёх шагов



ДАЛЬШЕ – ЧАСТЬ 4:

Связки с практикой ИБ. Где EDA включается в работе SOC, развёрнутые кейсы CIC-IDS-2018 и SOC-тикетов, чек-лист EDA для ИБ-данных и границы этики работы с данными.



Где в реальной работе SOC-команды разведочный анализ включается, и зачем

EDA – не «один раз перед моделью». В жизненном цикле ML-решения для SOC разведочный анализ возникает на трёх разных этапах, и каждый раз с разной целью.

1 ДО МОДЕЛИРОВАНИЯ Понять данные

Разобраться с источником, объектом, разметкой, дефектами. Сформулировать гипотезы. Зафиксировать журнал EDA для будущей валидации.

Цель: войти в постановку задачи с понятным датасетом, а не «попробуем gradient boosting».

2 ПОСЛЕ ЗАПУСКА Сверить факты

Распределения признаков в проде совпадают с обучением? Доля false positives стабильна? Сезонность не сломала срабатывания?

Цель: подтвердить, что данные в эксплуатации соответствуют тем, на которых модель училась.

3 ПРИ РАЗБОРЕ ИНЦИДЕНТА Найти причину

Почему модель пропустила атаку? Почему дала ложный сигнал? Какой именно срез данных был аномальным?

Цель: post-mortem, восстановление причины, обновление журнала EDA с новой информацией.



Кейс: разбор CIC-IDS-2018 за час EDA

41 / 50

Часть 4 · Связки с практикой ИБ

Что обнаружит внимательный инженер за один сеанс разведочного анализа

ИБ-КЕЙС · СКВОЗНОЙ ДАТАСЕТ

Чек-лист реального разбора датасета

✓ Полнота

В Flow Bytes/s и Flow Packets/s найдены +Infinity и NaN — десятки тысяч строк. Тип MAR (зависит от длительности).

✓ Дубликаты

При наивном split в test попадают flow, идентичные обучающим (одни и те же 5-tuple). Нужен dedup по 5-tuple.

✓ Выбросы

Длинный правый хвост Flow Duration. Удаление по IQR удалит slow-rate DDoS — нельзя.

✓ Дисбаланс

Benign — ~84%, отдельные типы атак — менее 0.1%. Для редких типов задача ближе к anomaly detection.

✓ Временная структура

Каждый день — отдельный сценарий атаки. Случайный split = leakage через дни.

✓ Артефакты сбора

Часть признаков (source IP, timestamp-производные) различает дни сильнее, чем тип атаки. Кандидаты на исключение.

Все шесть пунктов — обнаруживаются за один сеанс EDA. Все шесть — критически влияют на выбор модели, метрик, split.



Кейс: что меняет EDA разметки SOC

От «обучим классификатор» к «уточним инструкцию и переразметим»

ИБ-КЕЙС · РАЗМЕТКА И ПРОЦЕСС

Как EDA меняет проект, а не только датасет

БЕЗ EDA

Берём 12 000 размеченных тикетов, делим 80/20, обучаем классификатор. F1 на тесте = 0.67. Команда продукта недовольна качеством. Начинают тюнить модель, пробовать другие архитектуры, балансировать классы. Качество не растёт. Через два месяца проект приостанавливают.

Проблема: потолок качества задаёт шум разметки, а не модель.

С EDA РАЗМЕТКИ

EDA показывает: А и В расходятся в 18% случаев. Команда уточняет инструкцию аналитикам: вводит чёткие критерии Triage vs FP, согласовывает пороги по brute force. Размечают подвыборку повторно – расхождения падают до 6%. На новой разметке F1 = 0.81 с той же моделью.

Вывод: лучшее улучшение модели – лучшая разметка.

Что меняет EDA: из задачи «обучить модель» в задачу «улучшить процесс разметки, потом обучить модель». EDA – это рычаг на проект целиком, а не только на датасет.



Этические и правовые границы EDA

Базовая ответственность инженера на этапе разведочного анализа

EDA – момент, когда инженер впервые видит сырые данные. До любых преобразований и моделей. Это первая точка ответственности за то, что с этими данными происходит. Подробно тему ИБ-этики разберём в L20; здесь – три обязательных вопроса для каждого датасета.

Персональные данные

В auth-логах, тикетах SOC, метаданных писем – почти всегда есть ПДн. Кто имел право видеть эти данные? Не утекают ли они через скриншоты, копии в чатах, экспорт в Excel?

Действие: *Хранение, доступ, обезличивание – по политикам организации.*

Служебная и конфиденциальная информация

Содержимое писем, файлов, запросов может раскрывать коммерческую тайну. EDA даёт доступ к таким срезам – выводы и графики тоже становятся чувствительной информацией.

Действие: *Журнал EDA и скриншоты – в защищённом контуре, не в публичных репозиториях.*

Происхождение датасета

Кто собрал данные, на каких правовых основаниях, для каких целей? Использование данных для целей, отличных от заявленных при сборе, – отдельный правовой риск.

Действие: *Привязка использования к согласию/политике сбора – до начала EDA.*



Двенадцать вопросов, чтобы применять к любому датасету

01

Что такое объект наблюдения и какова единица анализа?

02

Какие признаки и какова целевая переменная?

03

Каков источник данных и каков маршрут их получения?

04

Где пропуски и какого они типа (MCAR / MAR / MNAR)?

05

Все ли значения признаков согласованы по единицам и форматам?

06

Есть ли дубликаты – точные, нормализованные, частичные?

07

Не устарели ли данные? Не изменилась ли среда сбора?

08

Какие выбросы – ошибки данных, а какие – содержательные события?

09

Какова надёжность разметки? Есть ли межаннотаторное расхождение?

10

Какова пропорция классов и что это значит для метрик?

11

Где в данных скрыта зависимость наблюдений?

12

Какие этические и правовые ограничения накладывает датасет?



Шесть утверждений, на которых построена вся L02

1**Данные первичны, модель вторична**

Качество, надёжность и интерпретируемость модели предопределяются качеством данных, а не выбором алгоритма.

2**Качество – это четыре компонента**

Полнота, согласованность, целостность, актуальность. Каждый требует отдельного ответа в журнале EDA.

3**Выброс ≠ ошибка**

В ИБ выброс часто и есть та редкая атака, ради которой собирался датасет. Автоматическое удаление недопустимо.

4**Наблюдения в ИБ зависимы**

По времени, пользователю, кампании, источнику. Это влияет на split, метрики и архитектуру решения.

5**Журнал EDA – обязательный артефакт**

Описание датасета, найденные проблемы, гипотезы, ограничения. Без него EDA нельзя ни повторить, ни передать.

6**EDA – это вход в постановку задачи**

Не подготовка к моделированию, а самостоятельный этап. После него можно решить, что задача поставлена неверно.



EDA нужен всегда, но не закрывает все вопросы постановки задачи

ГДЕ ПРИМЕНЯТЬ EDA

- ✓ Перед любой ML-задачей – обязательно. Без EDA не должна обучаться ни одна модель.
- ✓ После запуска модели – на регулярной основе для контроля распределений и качества срабатываний.
- ✓ При разборе инцидентов и снижении качества – как первый инструмент диагностики причины.
- ✓ При смене источника данных, обновлении инфраструктуры, появлении новых типов атак.

ЧЕГО EDA НЕ ДЕЛАЕТ

- ✗ **Не подменяет постановку задачи**
EDA даёт почву для неё, но саму задачу формулируем отдельно – в L03.
- ✗ **Не подменяет выбор метрики**
Метрика определяется ценой ошибок и природой задачи – это L04.
- ✗ **Не подменяет валидацию**
Корректный split, leakage, воспроизводимость – отдельная тема в L05.
- ✗ **Не подменяет модель**
Журнал EDA даёт ограничения, но в самой лекции мы моделей не обсуждаем.



Что читать дальше в курсе

47 / 50

Часть 5 · Итоги

Карта связей: куда ведут темы, открытые в данной лекции

L03	L05	L10	L11	L17
Постановка задач ML в ИБ	Валидация и leakage	Pipeline и feature engineering	Unsupervised и anomaly detection	Дрейф и мониторинг моделей
Опираясь на журнал EDA, формулируем задачу: что предсказываем, у кого, с какой ценой ошибки.	Корректный split при зависимости наблюдений и при дубликатах – продолжение тем из блоков 3.3 и 3.4.	Техническая обработка пропусков, выбросов и категориальных признаков через sklearn Pipeline.	Альтернативный подход для случая экстремального дисбаланса (1 на 10^5 и реже) – из блока 3.3.	Тема актуальности данных (компонент качества) превращается в отдельную инженерную дисциплину.

Полная карта курса: L01 (введение) → L02 (данные и EDA) → L03-L05 (постановка / метрики / валидация) → L06+ (модели и приложения).
Каждая следующая тема опирается на журнал EDA, который вы научились вести.



Что читать, чтобы укрепить материал лекции

1

КЛАССИКА

John W. Tukey. *Exploratory Data Analysis* – 1977

Классика, давшая дисциплине название. Главы 1-3 – обязательны: задают сам способ мышления об EDA.

2

ОСНОВА ML

C. Bishop. *Pattern Recognition and Machine Learning, Chapter 1* – 2006

Введение в ML с акцентом на статистические основания. Какие предположения о данных делают модели.

3

ОСНОВА ML

T. Hastie, R. Tibshirani, J. Friedman. *The Elements of Statistical Learning, Chapter 2* – 2009

Обзор supervised learning. Раздел про bias-variance и роль данных в обобщающей способности.

4

ПРАКТИКА

Wes McKinney. *Python for Data Analysis, 3rd ed.* – 2022

Практический справочник по pandas. Главы 7-10 – инструменты, которыми реализуется журнал EDA.



Для углубления, практики и работы со сквозным датасетом курса

СТАТЬИ

H. Wickham. *Tidy Data*. Journal of Statistical Software, 2014.

Принципы организации данных в табличном виде. Базовый язык, на котором мы говорим про датасет.

S. Garcia, J. Luengo, F. Herrera. *Data Preprocessing in Data Mining*. Springer, 2015.
Систематический разбор обработки пропусков, выбросов, дисбаланса.

ДОКУМЕНТАЦИЯ

pandas user guide

pandas.pydata.org/docs/user_guide
Разделы Missing Data, IO Tools, Group By.

seaborn tutorials

seaborn.pydata.org/tutorial
Готовые примеры всех 6 базовых визуализаций из слайда 35.

scikit-learn – Imputing missing values

scikit-learn.org/stable/modules/impute.html

ИБ-ДАТАСЕТЫ

CIC-IDS-2018 (UNB)

unb.ca/cic/datasets/ids-2018.html
Сквозной датасет курса. Описание сценариев атак и состава признаков.

Engelen et al. *Troubleshooting an Intrusion Detection Dataset*. 2021.

Критический разбор дефектов CIC-IDS – полезно прочитать после слайдов 19 и 41.

MITRE ATT&CK

attack.mitre.org
Каталог TTPs – контекст для разметки и валидации актуальности.



Двенадцать ключевых терминов

Объект наблюдения – Сущность, о которой собираются данные в датасете.

Признак (feature) – Измеримое свойство объекта, $x \in \mathbb{R}^d$.

EDA – Способ обнаружить проблемы до того, как модель их замаскирует.

MCAR / MAR / MNAR – Три механизма пропусков, различающие случайность их природы.

Выброс (outlier) – Наблюдение далеко от основной массы. Ошибка ИЛИ редкое событие.

Зависимость наблюдений – Объекты в выборке не независимы (по времени, пользователю, источнику).

Единица анализа – Уровень агрегации: одна строка датасета = ?

Целевая переменная (target) – Величина y , которую предсказывает модель.

Журнал EDA – Документ, фиксирующий проверки, проблемы, гипотезы, ограничения.

Дубликат – Точный, нормализованный или частичный – объект, который модель видит дважды.

Шум разметки – Расхождение между истинной меткой и записанной в датасете.

Дисбаланс классов – Положительный класс редкий. В ИБ – норма, а не дефект.