



Л Е К Ц И Я 0 4

Метрики качества и цена ошибок в задачах обнаружения и классификации

Машинное обучение и безопасность систем

Магистратура НИУ ВШЭ · МИЭМ · ОП «Информационная безопасность и технологии ИИ» · 1 курс

Автор: Силаев Ю. В. · Время изучения: ≈ 60 минут · 48 слайдов



Метрика качества – не одно число, а семейство выборов, привязанных к задаче

После этой лекции вы будете воспринимать слово «качество» осторожнее. Качество ML-модели – это не одно универсальное число, а семейство величин, каждая из которых отвечает на отдельный вопрос: «как часто мы ошибаемся», «насколько чисты наши тревоги», «насколько полно мы ловим целевые события», «как модель ранжирует объекты». В задачах информационной безопасности выбор метрики напрямую зависит от цены ошибок, дисбаланса классов, нагрузки на аналитика и режима использования модели – будет ли она блокировать действия, поднимать алерт или просто сортировать события для триажа.

КЛЮЧЕВОЙ ТЕЗИС

Метрика качества имеет смысл только вместе с ценой ошибок, распределением классов, выбранным порогом и контекстом принятия решения.



Что вы будете знать и уметь

Учебные результаты лекции

После изучения лекции вы научитесь:

- читать и интерпретировать матрицу ошибок для бинарной и многоклассовой классификации;
- объяснять различие между accuracy, precision, recall, F1, ROC-AUC и PR-AUC и выбирать между ними осознанно;
- выбирать метрики для задач с сильным дисбалансом классов, характерных для информационной безопасности;
- разделять качество ранжирования объектов и качество классификации после фиксации порога;
- описывать последствия false positive и false negative в типовых ИБ-сценариях – пропуск атаки, ложная тревога, перегрузка аналитика;
- аргументированно выбирать метрику под конкретную задачу обнаружения, фильтрации или приоритизации событий.



Что нужно знать до начала

4 / 48

Часть 1 · Введение

Предварительные требования

Эта лекция опирается на материал предыдущих лекций блока «Базовая рамка ML» и на базовый математический бэкграунд курса.

ИЗ ЭТОГО КУРСА

L02 – Данные и EDA: понятие объекта, признака, целевой переменной; первичный взгляд на распределение классов.

L03 – Постановка задач ML в ИБ: формулировка задачи, понятие baseline и концептуальное представление о цене ошибок в ИБ-сценарии.

БАЗОВАЯ ПОДГОТОВКА

Теория вероятностей: условные вероятности, доли, простые отношения. Сложная статистика не требуется.

Общая ИБ-эрудиция: понимание сценариев – детектор атак, фильтр фишинга, антифрод, triage SOC-алертов – на концептуальном уровне.

Валидация, линейные модели и калибровка вероятностей появятся в L05-L07.



План лекции

5 / 48

Часть 1 · Введение

Семь частей, 48 слайдов, около 60 минут изучения

№	Часть лекции	Слайды	Время
1	Введение	1-5	≈ 6 мин
2	Мотивация	6-9	≈ 5 мин
3	Основное содержание – 5 смысловых блоков	10-37	≈ 35 мин
4	Связки с практикой ИБ	38-42	≈ 7 мин
5	Итоги	43-45	≈ 3 мин
6	Источники для углубления	46-47	≈ 2 мин
7	Глоссарий	48	≈ 1 мин



Когда «точность 99%» – бесполезная модель

Контринтуитивная завязка: цифра-обманка

Представьте детектор сетевых атак. На реальном корпоративном трафике атаки – редкое событие: доля подозрительных flow обычно составляет от 0.1 % до нескольких процентов от всего объёма. Остальное – обычные легитимные обращения сотрудников и сервисов.

Постройте предельно глупую модель: «всегда отвечать Benign». Эта модель не различает атаки и легитимный трафик, не приносит пользы. Но её формальная ассурасу на таком потоке – около 99.9 %.

Числовая иллюстрация

10 000 flow за смену

10 атак (0.1 %)

9 990 легитимных flow

Модель «всегда Benign»:

Ассурасу = 99.9 %

Пойманных атак: 0

*99.9 % не описывает работу детектора – оно описывает только то, что в потоке мало атак.
Главный мотив всей лекции: одна универсальная метрика не работает.*



Один и тот же false positive в разных ИБ-задачах даёт разную боль

ИБ-КЕЙС

Три типовых ИБ-сценария с разной асимметрией цены FP и FN

Фильтр фишинга

Контекст. Подозрительные письма помечаются плашкой «Внимание».

FP – ложная тревога

Легитимное письмо помечено как фишинг. Раздражает, но пользователь его откроет.

FN – пропуск атаки

Пользователь кликает по фишингу – утечка учётных данных.

FN » FP

Антифрод

Контекст. Подозрительная операция уходит на ручную проверку оператору.

FP – ложная тревога

Честная операция задержана на минуты. Клиент раздражён, поддержка нагружена.

FN – пропуск атаки

Мошенническое списание прошло – прямая денежная потеря.

FN > FP, FP заметен

Сетевой firewall

Контекст. Модель сразу разрывает соединение, без подтверждения человеком.

FP – ложная тревога

Заблокирована легитимная активность – сбой работы сервиса.

FN – пропуск атаки

Атака прошла внутрь периметра – рисков снаружи больше нет.

FP сопоставим с FN

Один и тот же FP в фишинг-фильтре, антифроде и firewall'е имеет разную цену.
Метрика без учёта этой асимметрии не описывает реальное качество модели.



Последствия неверной метрики

Три типовых сценария отказа боевой ML-системы в ИБ

Неверная метрика не убивает модель сразу. На этапе обучения формальное число выглядит достойно – проблемы проявляются в проде. Чаще всего в трёх формах.

1

Пропуск инцидента

Модель с высокой ассигасу пропускает почти все атаки. SOC уверен в защите – реальные инциденты обнаруживаются постфактум.

2

Перегрузка SOC-аналитиков

Модель оптимизирована под recall. Поток алертов превышает смену – аналитики закрывают тревоги без разбора (alert fatigue).

3

Потеря доверия к системе

Блокировки и предупреждения непредсказуемы. Систему отключают или обходят – даже при формально хороших метриках.



Ключевой тезис лекции

Опорное утверждение

ОПРЕДЕЛЕНИЕ

Метрика качества имеет смысл только вместе с ценой ошибок, распределением классов, выбранным порогом и контекстом принятия решения.

Цена ошибок

FP и FN бьют по системе по-разному – это часть постановки задачи.

Распределение классов

Редкий положительный класс делает ассигуру и ROC-AUC ненадёжными.

Порог

Между score модели и меткой класса стоит выбор порога (будет в L07).

Контекст решения

Блокировка, уведомление, триаж – у каждого режима своя метрика.



Блок 1. Матрица ошибок

10 / 48

Часть 3 · Блок 1

Атомарная единица всех метрик: четыре исхода бинарного решения



Б1

Что мы разберём в этом блоке

Матрица ошибок – это способ описать, что именно делает классификатор в каждой ситуации. Все метрики качества классификации, которые введём дальше, выражаются через четыре числа из этой матрицы.

План блока

- Четыре исхода бинарного решения – TP, FP, TN, FN (определения).
- Confusion matrix как таблица 2×2 – с мини-примером на 100 объектах.
- Базовые «сырые» доли – TPR, FPR, FNR, TNR.
- Тот же подсчёт на сквозном датасете CIC-IDS-2018 – числа понесём в Б2.



Четыре исхода бинарного решения

11 / 48

Часть 3 · Блок 1

Определения TP , FP , TN , FN : $y \in \{0, 1\}$ – стандартная нотация для классификации

В бинарной классификации модель решает: объект относится к положительному классу (1) или к отрицательному (0). Сравнение с истинной меткой даёт ровно четыре возможных исхода.

TP

True Positive – верный позитив

Атака есть, модель сказала «атака». Угроза распознана корректно.

FP

False Positive – ложная тревога

Атаки нет, модель сказала «атака». Сработала тревога на легитимной активности.

FN

False Negative – пропуск атаки

Атака есть, модель сказала «легитимный». Угроза прошла мимо детектора.

TN

True Negative – верный негатив

Атаки нет, модель сказала «легитимный». Поведение распознано как нормальное.



Confusion matrix: таблица 2×2

12 / 48

Часть 3 · Блок 1

Строки – истина, столбцы – предсказание. Мини-пример на 100 объектах

		Предсказание модели	
Истина		Pred = 1	Pred = 0
y = 1	y = 1	TP 30	FN 10
		FP 5	TN 55

Числа на пересечении: количество объектов соответствующего исхода.

МИНИ-ПРИМЕР

Что мы тестируем

Прогнали детектор на 100 событиях. По истинной разметке: 40 атак (y=1) и 60 легитимных (y=0).

Проверка суммы

$$TP + FN = 30 + 10 = 40$$

→ всего атак (y=1)

$$FP + TN = 5 + 55 = 60$$

→ всего легитимных (y=0)



Четыре отношения, которые читают матрицу построчно

Сами по себе TP, FP, FN, TN — абсолютные количества, зависящие от размера выборки. Чтобы сравнивать модели, переводим их в нормированные доли. Доли считаются «по строкам матрицы» — отдельно по положительным и отдельно по отрицательным объектам.

ФОРМУЛЫ

TPR (recall, sensitivity)

$$\text{TPR} = \text{TP} / (\text{TP} + \text{FN})$$

Какая доля настоящих атак поймана. «Полнота».

FPR (fall-out)

$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN})$$

Доля легитимных, помеченных как атака.

FNR (miss rate)

$$\text{FNR} = \text{FN} / (\text{TP} + \text{FN})$$

Какая доля атак пропущена. $\text{TPR} + \text{FNR} = 1$.

TNR (specificity)

$$\text{TNR} = \text{TN} / (\text{FP} + \text{TN})$$

Доля легитимных, верно пропущенных. $\text{FPR} + \text{TNR} = 1$.

Это не метрики качества: сами по себе TPR и FPR ничего не говорят о цене ошибок и о доле атак в потоке.

Метрики (accuracy, precision, F1, AUC) — в следующих блоках.



Те же четыре числа на сквозном датасете курса

ИБ-КЕЙС

Детектор атак на CIC-IDS-2018: 10 000 flow за смену, 50 атак (0.5 %)

Что выдала модель

TP

35

пойманных атак

FN

15

пропущенных атак

FP

200

ложных тревог

TN

9 750

верно пропущенных

Как это читать

Из 50 настоящих атак модель поймала 35 и пропустила 15. Среди 9 950 легитимных событий 200 ошибочно помечены как атаки.

Сырые доли

$$TPR = 35 / 50 = 0.70$$

$$FNR = 15 / 50 = 0.30$$

$$FPR = 200 / 9\,950 \approx 0.020$$

$$TNR = 9\,750 / 9\,950 \approx 0.980$$



После выбора порога каждый объект получает метку – какие метрики есть

Б2

Что мы разберём в этом блоке

Зафиксируем порог и предположим, что каждый объект уже получил метку «атака» или «легитимный». Какие метрики качества доступны на этом уровне – и в каких ситуациях они вводят в заблуждение? Это четыре классические метрики: accuracy, precision, recall, F1.

План блока

- Accuracy и её главное ограничение – дисбаланс классов.
- Precision и recall как пара: «насколько чисты тревоги» vs «насколько полно ловим».
- Расчёт precision и recall на наших числах из Блока 1 (CIC-IDS-2018).
- F1-мера: компромисс между precision и recall, и его ограничения.



Самая известная метрика – и самая опасная при дисбалансе

ФОРМУЛА

$$\text{Accuracy} = \frac{(TP + TN)}{(TP + FP + TN + FN)}$$

ОПРЕДЕЛЕНИЕ

Ассурасу – доля объектов, которым модель присвоила верную метку, от их общего числа. Не различает FP и FN: ошибка в обе стороны считается одинаково.

ГДЕ ЛОМАЕТСЯ

Дисбаланс классов

Когда положительный класс редкий (атаки = 0.1 %), модель «всегда отвечать Benign» даёт ассурасу 99.9 %. Это не качество модели – это просто структура потока.

На наших числах из Б1:

$$\text{Accuracy} = (35 + 9750) / 10\,000 = \mathbf{0.9785}$$

≈ 98 % – но FN ещё 15



Частая ошибка: ассурасу

17 / 48

Часть 3 · Блок 2

Янтарный – что часто слышим. Красный – почему это неверно

ЧАСТО ГОВОРЯТ

«Ассурасу 99.9 % – модель почти идеальна, можно нести её в прод.»

ПОЧЕМУ ЭТО НЕВЕРНО

$\text{Ассурасу} = (\text{TP} + \text{TN}) / N$

не различает FP и FN и сильно зависит от доли классов. При 0.1 % положительного класса «всегда Benign» детектор не делает ничего полезного – но формально достигает 99.9 %. **Модель пропускает все атаки, а отчёт показывает «отличное качество».**



Precision и recall: два разных взгляда

18 / 48

Часть 3 · Блок 2

Пара метрик, которые читают матрицу ошибок «по столбцу» и «по строке»

Precision и recall смотрят на матрицу под разными углами и отвечают на разные вопросы. Их обычно подают вместе – одна без другой не описывает качество детектора в задачах с дисбалансом.

PRECISION

Насколько чисты наши тревоги

$$\text{Precision} = TP / (TP + FP)$$

Доля настоящих атак среди всех объектов, которые модель пометила как атаку. Высокая precision = мало ложных тревог.

RECALL (TPR, SENSITIVITY)

Насколько полно мы ловим

$$\text{Recall} = TP / (TP + FN)$$

Доля настоящих атак, которые модель действительно поймала. Высокая recall = мало пропусков.

Recall $\equiv$ TPR из Б1. А precision – это новая, четвёртая метрика; в матрице она читается «по столбцу Pred = 1».



Расчёт на CIC-IDS-2018

19 / 48

Часть 3 · Блок 2

Те же 35 / 15 / 200 / 9750 – но теперь через *precision* и *recall*

ИБ-КЕЙС

Те же числа из слайда 14: $TP = 35$, $FN = 15$, $FP = 200$, $TN = 9\,750$

PRECISION

$$\begin{aligned} &= TP / (TP + FP) \\ &= 35 / (35 + 200) \\ &= 35 / 235 \end{aligned}$$

$$\approx 0.149$$

≈ 15 % тревог – настоящие атаки

RECALL

$$\begin{aligned} &= TP / (TP + FN) \\ &= 35 / (35 + 15) \\ &= 35 / 50 \end{aligned}$$

$$= 0.70$$

70 % атак пойманы

ИНТЕРПРЕТАЦИЯ ДЛЯ АНАЛИТИКА

На каждые 235 поднятых алертов аналитик увидит только 35 настоящих атак – остальные 200 окажутся ложными тревогами. При этом 15 атак всё равно ушли мимо: пойманы лишь 7 из каждых 10.



F1-мера и её ограничения

Гармоническое среднее *precision* и *recall* – и почему оно не универсально

ФОРМУЛА

$$F1 = 2 \cdot P \cdot R / (P + R)$$

где $P = \text{precision}$, $R = \text{recall}$

ОПРЕДЕЛЕНИЕ

Гармоническое среднее *precision* и *recall*.
Чувствительно к меньшему из двух: если одно низкое, F1 тоже низкое.

НА НАШИХ ЧИСЛАХ

$P = 0.149$, $R = 0.70$

$F1 = 2 \cdot 0.149 \cdot 0.70 / (0.149 + 0.70)$

≈ 0.247

ОГРАНИЧЕНИЯ

- FP и FN считаются одинаково – асимметрия цены ошибок не учитывается.
- F1 зависит от порога так же, как *precision* и *recall*.
- Сравнение F1 между задачами с разной долей классов некорректно.



Янтарный – что часто слышим. Красный – почему это неверно

ЧАСТО ГОВОРЯТ

«F1 учитывает и precision, и recall – будем выбирать модель и порог именно по F1.»

ПОЧЕМУ ЭТО НЕВЕРНО

F1 одинаково взвешивает FP и FN. В реальной ИБ-задаче цена пропуска и цена ложной тревоги почти никогда не равны: фишинг-фильтр готов мириться с FP ради FN, блокирующий firewall – наоборот.

F1 – метрика на одном фиксированном пороге. Сменили порог – F1 изменилось. Сравнение моделей по F1 без указания порога некорректно.



Мини-резюме блока 2

22 / 48

Часть 3 · Блок 2

Что запомнить о ранжирующих метриках

1

Все четыре метрики этого блока – accuracy, precision, recall, F1 – считаются на ОДНОМ фиксированном пороге.

2

Accuracy не различает FP и FN и опасна на дисбалансе. На наших числах: 98 % accuracy при 15 пропущенных атаках.

3

Precision и recall – пара, которую читают вместе. Одно без другого не описывает качество детектора.

4

F1 – компромисс precision и recall, но одинаково взвешивает FP и FN. В ИБ это часто противоречит цене ошибок.

5

Дальше – метрики, не зависящие от выбора порога: ROC-AUC и PR-AUC (Блок 3).



Блок 3. Метрики без фиксированного порога

До выбора порога модель – это ранжирование объектов по score



Что мы разберём в этом блоке

Метрики Блока 2 работали при фиксированном пороге. Но любая модель сначала выдаёт score – число, упорядочивающее объекты по подозрительности. Метрики качества ранжирования оценивают весь этот порядок целиком, не привязываясь к одной отсечке.

План блока

- ROC-кривая: как строится из (FPR, TPR) при разных порогах.
- ROC-AUC: формальный смысл – вероятность правильного порядка пары.
- PR-кривая и PR-AUC: чем отличаются от ROC.
- Когда ROC-AUC обманывает на редком положительном классе.



ROC-кривая: как строится

24 / 48

Часть 3 · Блок 3

Проходим по всем порогам – получаем точки (FPR, TPR) и соединяем их


ИНСТРУКЦИЯ

Шаг 1. Упорядочиваем объекты по score модели от большего к меньшему.

Шаг 2. Перебираем все возможные пороги – от «никто не атака» до «все атаки».

Шаг 3. На каждом пороге считаем пару (FPR, TPR) – формулы из Б1.

Шаг 4. Точки наносим на плоскость (FPR – по X, TPR – по Y) и соединяем по возрастанию порога.





ROC-AUC: что измеряет

25 / 48

Часть 3 · Блок 3

Не просто «площадь под кривой» — у этого числа есть формальный смысл

ФОРМАЛЬНО

$$AUC = P(\text{score}(x^+) > \text{score}(x^-))$$

где x^+ — случайный положительный объект, x^- — случайный отрицательный

ОПРЕДЕЛЕНИЕ

ROC-AUC — вероятность того, что случайный положительный объект получит больший score, чем случайный отрицательный. Это качество РАНЖИРОВАНИЯ, а не классификации.

ШКАЛА ЗНАЧЕНИЙ

1.00

идеальное ранжирование — все x^+ выше всех x^-

0.90

сильная модель: положительные в верхней части списка

0.70

посредственно: есть сигнал, но много путаницы

0.50

случайная модель — score не несёт информации

< 0.50

хуже случайной — стоит инвертировать предсказания



PR-кривая и PR-AUC

26 / 48

Часть 3 · Блок 3

Та же логика «перебираем порог», но по другим осям

УСТРОЙСТВО

$X = \text{Recall}$, $Y = \text{Precision}$


PR-AUC – площадь под кривой

КЛЮЧЕВОЕ ОТЛИЧИЕ ОТ ROC

ROC использует FPR, в котором есть TN.

PR использует только precision и recall – а в них TN не входит.

При сильном дисбалансе TN огромен и «вытягивает» ROC-AUC вверх. PR-кривая этого эффекта не имеет.





Когда ROC-AUC обманывает

27 / 48

Часть 3 · Блок 3

Числовой пример: ROC-AUC выглядит отлично, а модель почти бесполезна

ИБ-КЕЙС

Очень редкий положительный класс: атаки = 0.1 % (100 атак на 100 000 событий)

ЧТО ПОКАЗЫВАЕТ МОДЕЛЬ

ROC-AUC = 0.95

«отличная модель», звучит как успех

ПРИ ВЗГЛЯДЕ В ТОП-100 ПО SCORE

Precision@100 = 0.05

из топ-100 алертов – только 5 атак

ПОЧЕМУ ТАК ВЫХОДИТ

ROC-AUC = 0.95 значит: случайный x^+ ранжируется выше случайного x^- в 95 % случаев. Но «случайный x^- » – это один из 99 900 объектов. Среди них даже 5 % неудачных отношений к x^+ дают тысячи легитимных событий, которые ранжируются выше настоящих атак.

Для редкого положительного класса смотрим PR-AUC.



Янтарный – что часто слышим. Красный – почему это неверно

ЧАСТО ГОВОРЯТ

«ROC-AUC = 0.95 – модель почти идеальна, сравним так все варианты и выберем лучший.»

ПОЧЕМУ ЭТО НЕВЕРНО

ROC-AUC завышен при редком положительном классе. Большая часть пар (x^+ , x^-) ранжируется правильно автоматически – потому что отрицательных очень много и легко.

При доле положительного класса $< 1\%$ сравнивайте модели по **PR-AUC** или **precision@k** – это те метрики, которые видят разницу между похожими по ROC моделями.



Мини-резюме блока 3

29 / 48

Часть 3 · Блок 3

Что запомнить о многоклассовых метриках

1

ROC-AUC и PR-AUC – метрики качества ранжирования. Не зависят от выбора одного порога.

2

ROC-AUC = вероятность того, что случайный x^+ получит больший score, чем случайный x^- .

3

PR-кривая = (Recall, Precision). TN не входит в обе метрики – поэтому PR не «вытягивает» дисбаланс.

4

При редком положительном классе ROC-AUC систематически завышен. Сравнивайте по PR-AUC или precision@k.

5

«AUC» без уточнения недостаточно – указывайте ROC-AUC или PR-AUC.



Что меняется, когда классов больше двух – на примере CIC-IDS-2018

Б4

Что мы разберём в этом блоке

В CIC-IDS-2018 не один класс «атака», а около 14 разных типов атак плюс Benign. Метрики Блоков 2 и 3 определены для бинарного случая, и при переходе к нескольким классам появляется новый выбор: как агрегировать пер-классовые числа в одно сводное.

План блока

- Три способа агрегации пер-классовых метрик: macro, micro, weighted.
- Когда какое averaging выбирать – решающая таблица под ИБ-задачи.
- Почему опасно смотреть только на агрегированное число – без разбора по классам.



Три способа свести пер-классовые числа в одно сводное

Пусть у нас K классов. На каждом классе считаем precision, recall, F1 как в бинарном случае (один-против-всех). Получаем K чисел. Чтобы сравнивать модели одной цифрой, эти числа нужно агрегировать. Есть три классических способа.

MACRO

Среднее по классам

$$\text{macro-F1} = (1/K) \cdot \sum \text{F1}_k$$

Простое среднее F1 по K классам. Все классы равноправны – независимо от размера.

→ все классы равны

MICRO

Сначала суммируем

$$\text{micro-F1} = \text{F1}(\sum \text{TP}, \sum \text{FP}, \sum \text{FN})$$

Сначала складываем TP, FP, FN по всем классам, потом считаем общий F1.

→ все объекты равны

WEIGHTED

Среднее с весами

$$\text{weighted-F1} = \sum w_k \cdot \text{F1}_k$$

Среднее F1 с весами w_k – обычно это доля объектов класса k . Часто близко к micro.

→ классы по их размеру

То же самое для precision и recall: бывают macro-precision, micro-precision, weighted-precision и аналоги для recall.



Какое averaging выбрать

32 / 48

Часть 3 · Блок 4

Решающая таблица: характеристика задачи → подходящая агрегация

Характеристика задачи	Выбираем	Почему
Редкие и частые классы одинаково важны – нельзя «утопить» редкие в большом классе	macro	Все классы получают равный вес – низкий F1 на редком классе сразу виден
Важна общая доля правильных решений во всём потоке событий	micro	Доминирует поведение на массовых классах – «польза в среднем»
Нужен «средневзвешенный F1 для отчётности», классы важны пропорционально размеру	weighted	Формула как у macro, но веса = доли классов – часто близко к micro
ИБ-сценарий: оценить работу на редком типе атаки (Brute Force, SQL-i)	macro	Не даёт редкой атаке «спрятаться» за Benign – её F1 повлияет на итог наравне со всеми

В CIC-IDS-2018 Benign-трафик доминирует, отдельные атаки – десятки-сотни объектов. macro покажет реальное качество детектора атак; micro и weighted в основном «отчитаются» по Benign.



Янтарный – что часто слышим. Красный – почему это неверно

ЧАСТО ГОВОРЯТ

«У модели macro-F1 = 0.60 на 14 классах атак – нормально, можно нести в прод.»

ПОЧЕМУ ЭТО НЕВЕРНО

macro-F1 = 0.60 – это среднее. За ним может стоять расклад: 13 классов с $F1 \approx 0.65$, а один – $F1 = 0.05$. В среднем – 0.60.

Этот один «утонувший» класс – может быть именно той атакой, ради которой строилась модель. Всегда смотрите **F1 по каждому классу отдельно**. Детально этот анализ ошибок будет в L09.



Три разные сущности – и порог между ними. То, что выдаёт модель, ещё не решение



Что мы разберём в этом блоке


Все четыре предыдущих блока опирались на одно невысказанное допущение: «есть итоговые метки классов». Но модель выдаёт не метку, а число. Между числом и решением – два шага: калибровка вероятности и выбор порога.

План блока

- Цепочка из четырёх сущностей: score → probability → class → decision.
- Порог решения и компромисс precision vs recall.
- Почему 0.5 – это не «правильный по умолчанию» порог.



Четыре сущности и три преобразования между ними



ОПРЕДЕЛЕНИЯ

score

Сырое число, которое выдаёт модель. Не обязательно вероятность; масштаб произволен и зависит от модели.

class

Дискретная метка (0 или 1). Получается из probability сравнением с порогом τ : $p \geq \tau \rightarrow 1$, иначе 0.

probability

Калиброванная оценка вероятности класса: «если модель сказала 0.7, в среднем такие объекты атаки в 70 % случаев».

decision

Действие: «заблокировать», «уведомить аналитика», «передать на проверку». Зависит от политики использования.



Порог: компромисс P vs R

36 / 48

Часть 3 · Блок 5

Двигая порог, мы выбираем баланс precision и recall. Детально в L07

ПРАВИЛО СДВИГА ПОРОГА

Порог τ ↓

→ ↑ **recall** (ловим больше атак)

→ ↓ **precision** (больше ложных тревог)


Порог τ ↑

→ ↑ **precision** (тревоги чище)

→ ↓ **recall** (пропускаем больше атак)

один и тот же score – разные метрики

ДВЕ КРИВЫЕ КАК ФУНКЦИИ ПОРОГА



precision обычно растёт, но может колебаться

В L07. Как выбирать порог под цену ошибок и калибровать вероятности.



Частая ошибка: порог 0.5 «по умолчанию»

Янтарный – что часто слышим. Красный – почему это неверно

ЧАСТО ГОВОРЯТ

«У моей модели порог 0.5 – это значение по умолчанию из библиотеки, и оно как-то само работает.»

ПОЧЕМУ ЭТО НЕВЕРНО

0.5 – это математический артефакт сигмоиды, а не оптимум. Сигмоида делит ось пополам именно в 0.5, но эта точка не имеет отношения к цене ошибок задачи.

В ИБ-задачах с дисбалансом оптимальный порог обычно сильно сдвинут: **для блокирующих систем – выше (нужна максимальная precision), для триажа SOC – ниже (нужна полнота).** Как выбрать порог под задачу – детально в L07.



Сквозной датасет курса – кратко напомним структуру

ИБ-КЕЙС

Datасet от University of New Brunswick. Сетевой трафик с захватом известных атак.

≈ 16 млн

сетевых flow

захвачены за 10 дней с реальной корпоративной
инфраструктуры

≈ 80

признаков на flow

длительность, объёмы пакетов, флаги, межпакетные
интервалы и др.

≈ 14

типов атак + Benign

Brute Force, DoS, DDoS, Botnet, Infiltration, Web Attacks
(несколько подтипов)

≈ 1.5 %

доля атак в потоке

сильный дисбаланс: на каждую атаку приходится ~65
легитимных flow

Дисбаланс ≈ 1.5 % – это «нормально по меркам ИБ». В продовых системах доля атак часто на порядок ниже. Все ловушки ассигуры и ROC-AUC, разобранные выше, проявляются именно на таких данных.



ROC-AUC говорит одно, PR-AUC – другое. Какая модель «лучше»?

ИБ-КЕЙС

Положительный класс $\approx 1.5\%$. Две модели обучены на одних и тех же данных.

МОДЕЛЬ А

Глобально хороший детектор

ROC-AUC **0.97**

PR-AUC **0.45**

ROC выше – будто лучше

МОДЕЛЬ В

Хорошо разделяет верхушку

ROC-AUC **0.92**

PR-AUC **0.71**

PR выше – в топе чище

Для триажа SOC берём В. При редком положительном классе важнее качество в топе списка по score, и это про PR-AUC.



Кейс 2. Triage SOC-алертов

40 / 48

Часть 4 · Практика ИБ

Ограниченная ёмкость аналитика → метрика приходит из задачи, а не из библиотеки

ИБ-КЕЙС

5 000 алертов в смену, аналитик успевает разобрать 200

ОГРАНИЧЕНИЕ ЗАДАЧИ

Модель ранжирует алерты по score. Аналитик берёт топ-200 по убыванию score – этих 200 хватает на одну смену. Всё, что ниже топа, до завтра не разобрано.

ВОПРОС

Что нас интересует – сколько настоящих атак среди этих 200 алертов. Recall на всём потоке – вторичен: остальное физически не разберут.

МЕТРИКА

Precision@200

Доля настоящих атак среди топ-200 по score модели.

ПРИМЕР НА НАШИХ ЧИСЛАХ

Если в топ-200 – 50 настоящих атак,

то $\text{Precision@200} = 0.25$

1 настоящая атака на 4 алерта – реалистично



Цена FP и FN: четыре сценария

41 / 48

Часть 4 · Практика ИБ

Один и тот же score – разные требования к precision и recall

Режим использования модели	Цена ошибок	Нужно
Блокировка (firewall, антифрод-блок)	FP блокирует легитимного пользователя – заметный сбой бизнеса	высокий precision
Уведомление (баннер «фишинг?»)	FP раздражает, но не блокирует. FN – клик по фишингу = утечка	высокий recall
Приоритизация (triage SOC)	Цена ошибок «по бюджету»: разбирается только топ-k	precision@k
Передача аналитику (ручная проверка антифрод)	FP = чужое время оператора, FN = деньги клиента	баланс P и R

В L07. Как численно выбрать порог под цену FP и FN в каждом из этих режимов.



Что в L04 – введение, что – дальше

Эта лекция запускает сквозную линию курса «цена ошибок и порог»

L04 даёт словарь и базовые ловушки метрик. Несколько важных тем мы намеренно оставили на потом – они появятся в последующих лекциях курса.

L07

Порог и калибровка

ЗДЕСЬ

В L04: ввели понятие порога и компромисс precision/recall.

ДАЛЬШЕ

В L07: как выбирать порог под бизнес-функцию потерь, как калибровать score → вероятность.

L09

Анализ ошибок

ЗДЕСЬ

В L04: упомянули, что макро-метрика может маскировать «утонувший» класс.

ДАЛЬШЕ

В L09: детальный slice-анализ ошибок по подгруппам и типам атак.

L17

Метрики под drift

ЗДЕСЬ

В L04: считали метрики на статичном датасете.

ДАЛЬШЕ

В L17: те же метрики применяем под распределение, которое меняется со временем (стресс-тесты).



Семь ключевых утверждений

1

Метрика без цены ошибок и контекста решения – бесполезна. Это ключевой тезис лекции.

2

Ассигасу опасна на дисбалансе. 99 % не означает «модель работает».

3

Precision и recall – пара, которую читают вместе. Одно без другого ничего не описывает.

4

ROC-AUC при редком положительном классе систематически завышен. Сравнивайте по PR-AUC или precision@k.

5

Масго раскрывает редкие классы. Без него «утонувший» класс не виден.

6

Порог 0.5 – не оптимум, а артефакт сигмоиды. Выбор порога – отдельный шаг.

7

Score, probability, class, decision – три разные сущности. То, что выдаёт модель, – ещё не решение.

ОПОРНАЯ МЫСЛЬ

«Какую метрику выбрать?» – неверный вопрос.
Верный – какая метрика отражает цену ошибок в задаче.



Метрика под задачу

44 / 48

Часть 5 · Итоги

Решающая таблица: характеристика задачи → метрика, на которую стоит смотреть

Характеристика задачи	Метрика	Почему
Сбалансированные классы, бинарный случай	accuracy, ROC-AUC	Ассурасу информативна, ROC-AUC не вытягивается дисбалансом
Редкий положительный класс (< 1 %)	PR-AUC, precision@k	ROC-AUC завышен; смотрим качество в верхушке ранжирования
Многоклассовая задача с редкими атаками	macro-F1 + F1 по классам	Макро не даст редким утонуть; разбор по классам обязателен
Ранжирование под ёмкость аналитика	precision@k	Прямое соответствие задаче «что в топ-k – настоящие атаки»
Блокирующее решение (firewall, антифрод-блок)	precision при заданном recall	FP блокирует легитимного пользователя – цена FP высока

Каждая ИБ-задача добавляет нюансы – это лишь типовые правила выбора.




Связи с другими лекциями

45 / 48

Часть 5 · Итоги

L04 запускает сквозную линию «цена ошибок и порог» – L04 → L07 → L09 → L17



ЧТО БЫЛО ДО L04

L03 – постановка задачи: понятие baseline, концепция цены ошибок.

L02 – данные и EDA: первый взгляд на распределение классов в CIC-IDS-2018.

ЧТО БУДЕТ ПОСЛЕ L04

L05 – валидация и leakage: на каких данных мерить эти метрики честно.

L07 – порог и калибровка: как численно выбирать порог под цену ошибок.



С чего начать, если хочется глубже

УЧЕБНИК

Hastie, Tibshirani, Friedman – The Elements of Statistical Learning

Глава 7: Model Assessment and Selection

Раздел 7.2 (Bias-Variance), 7.4 (Effective Number of Parameters), 7.10 (Cross-Validation). Для метрик классификации – раздел про ROC.

УЧЕБНИК

Bishop – Pattern Recognition and Machine Learning

Глава 1.5 – Decision Theory

Фундаментальная связь между вероятностью, порогом и функцией потерь. Минимально необходимый минимум для понимания, что такое «оптимальный порог».

СТАТЬЯ

Davis, Goadrich – PR vs ROC Curves (ICML 2006)

Полностью

Каноническое объяснение, почему при сильном дисбалансе ROC-AUC и PR-AUC дают разные ответы. Короткая, читается за час.



Документация, разборы и сам датасет

DOCS

scikit-learn user guide

scikit-learn.org → [metrics & model_evaluation](#)

Полный справочник `metrics` и `classification_report`. Все формулы и параметры `averaging` – здесь.

TUTORIAL

PR-кривые для редких классов

[scikit-learn](#) → [Precision-Recall examples](#)

Готовый код построения PR-кривой, `average_precision_score` и сравнения с ROC-AUC на сильно дисбалансных данных.

DATASET

CIC-IDS-2018

unb.ca/cic/datasets/ids-2018.html

Официальная страница датасета: описание сценариев атак, схема сбора трафика, варианты загрузки (`raw pcap`, `processed CSV`).

ARTICLE

Confusion Matrix at Wikipedia

en.wikipedia.org/wiki/Confusion_matrix

Самая полная сводка названий метрик и их синонимов: $\text{TPR} \equiv \text{recall} \equiv \text{sensitivity}$, и так далее. Удобна как справочник.

Если что-то непонятно – начинайте с Wikipedia (быстрое уточнение терминов) и sklearn docs (формулы и параметры), а уже потом – Hastie и Bishop.



13 ключевых терминов

TP / FP / TN / FN. Четыре исхода бинарного решения: верный позитив, ложная тревога, верный негатив, пропуск.

Accuracy. $(TP+TN) / N$. Доля правильных меток. Не различает FP и FN. Опасна при дисбалансе.

Precision. $TP / (TP+FP)$. Доля настоящих среди помеченных как положительные.

Recall (TPR). $TP / (TP+FN)$. Доля настоящих положительных, которых модель поймала.

F1. $2 \cdot P \cdot R / (P+R)$. Гармоническое среднее P и R. Чувствительно к меньшему.

TPR / FPR / FNR / TNR. Сырые доли «по строкам» матрицы ошибок.

ROC-AUC. Площадь под ROC. Вероятность правильного порядка случайной пары (x^+, x^-) .

PR-AUC. Площадь под PR-кривой. Не «вытягивается» дисбалансом – TN не входит.

Precision@k. Доля настоящих положительных в топ-k. Метрика для ranking-задач.

Macro / micro / weighted. Три способа агрегации пер-классовых метрик в многоклассовой задаче.

Порог решения τ . Граница перевода score (или probability) в дискретную метку класса.

Score / probability / class. Три сущности между моделью и решением: число $\rightarrow$ калибровка $\rightarrow$ метка.

Дисбаланс классов. Сильно неравные доли классов. Типично для ИБ ($< 1\%$ атак).