



ЛЕКЦИЯ 06

Линейные модели и вероятностная интерпретация решений

Машинное обучение и безопасность систем

Магистратура НИУ ВШЭ (МИЭМ) · ОП «Информационная безопасность и технологии ИИ»

Автор: Силаев Ю. В. · Время изучения лекции ≈ 70 минут



Эта лекция за одну минуту

О чём лекция и зачем она нужна именно в курсе по безопасности

Линейная модель – первый содержательный класс моделей в курсе. Она предсказывает результат как взвешенную сумму признаков, и её ценность двойная. Во-первых, это интерпретируемый и воспроизводимый baseline: прежде чем строить сложную модель, инженер по безопасности проверяет, какое качество даёт простая. Во-вторых, у логистической регрессии есть строгое вероятностное обоснование – её функция потерь $\log\text{-loss}$ выводится из принципа максимального правдоподобия, а не вводится по аналогии.

Baseline

Понятная точка отсчёта для фишинга, URL, логов и табличных данных.

Вероятность из MLE

$\log\text{-loss}$ = отрицательное $\log$ -правдоподобие модели Бернулли.

Объяснимость

Коэффициенты помогают аудировать признаки и ловить утечки.



Учебные результаты лекции

После изучения лекции вы сможете:

- записывать линейную модель для регрессии и классификации и объяснять роль весов и свободного члена;
- описывать логистическую регрессию и связь $\text{score} \rightarrow \text{sigmoid} \rightarrow \text{вероятность положительного класса}$;
- выводить $\log\text{-loss}$ из правдоподобия Бернулли и записывать его через margin (отступ);
- интерпретировать коэффициенты с учётом масштаба признаков и способа кодирования;
- отличать вероятностный выход модели от откалиброванной вероятности;
- применять линейную модель как объяснимый baseline в типовых задачах ИБ.



Что нужно знать до начала

4 / 52

Часть 1 · Введение

Предварительные требования и опора на предыдущие лекции

Лекция опирается на математическую подготовку и на несколько уже пройденных тем курса. Если какой-то пункт ниже вызывает затруднение, вернитесь к указанной лекции или к базовому курсу математики прежде, чем продолжать.

Математика	Скалярное произведение векторов, производные и цепное правило, основы теории вероятностей (распределение Бернулли).
Метрики качества	Понятия точности, полноты, ROC-AUC, F1 и цена ошибок – введены в L04.
Валидация и утечки	Train / val / test split, понятие data leakage и воспроизводимость эксперимента – введены в L05.
Базовые понятия	Объект, признак, целевая переменная, понятие baseline (введён в L03).



План лекции

5 / 52

Часть 1 · Введение

Семь частей курса · ориентируйтесь по номеру слайда и маркеру части

№	Часть лекции	Слайды	Время
1	Введение	1-5	~6 мин
2	Мотивация: зачем линейные модели в ИБ	6-9	~5 мин
3	Основное содержание: от score к вероятности	10-39	~38 мин
4	Связки с практикой ИБ (CIC-IDS-2018)	40-46	~9 мин
5	Итоги и навигация по курсу	47-49	~4 мин
6	Источники для углубления	50-51	~3 мин
7	Глоссарий	52	~2 мин

Полное время самостоятельного изучения лекции ≈ 70 минут (1-1.5 мин на слайд).



Где простая модель оказывается первым рабочим инструментом

В реальных задачах информационной безопасности линейная модель почти никогда не бывает самой точной – и всё же она часто стоит первой в конвейере. Причина в том, что она быстро обучается, не требует подбора множества гиперпараметров и даёт коэффициенты, которые можно прочесть и объяснить аналитику. Это делает её удобной для задач, где важны прозрачность и скорость проверки гипотезы о признаках.

Фишинговые письма

TF-IDF-признаки текста → линейная модель отделяет фишинг от легитимной почты.

Вредоносные URL

Символьные и статистические признаки адреса дают быстрый объяснимый детектор.

Сетевой трафик

Табличные признаки соединения – baseline для разделения Benign и атаки.

Триаж алертов

Приоритизация срабатываний по набору объяснимых факторов для аналитика SOC.



Сквозная линия курса: baseline-дисциплина (введена в L03)

Представьте, что инженер сразу обучил градиентный бустинг и получил ROC-AUC 0.95. Хороший результат? Ответить нельзя – пока не известно, что даёт простая модель на тех же данных. Если линейный baseline уже выдаёт 0.94, выигрыш сложной модели почти отсутствует и не оправдывает потерю интерпретируемости. Если baseline даёт 0.70, прирост реален и значим.

Принцип baseline-дисциплины. Сложная модель имеет право на жизнь только тогда, когда она измеримо превосходит простую. Baseline – это не разминка, а точка отсчёта, относительно которой считается реальный выигрыш.

Эта линия проходит через весь курс: L03 (введение baseline) → L06 (линейная модель) → L08 (простое дерево) → L13 (MLP против бустинга) → L15 (TF-IDF для текстов).



Типовые провалы реальных ИБ-систем, которых можно избежать

⚠ ЧАСТАЯ ОШИБКА

«Сразу берём самую мощную модель – бустинг или нейросеть, она наверняка лучше».

Инженер пропускает простую модель и теряет точку отсчёта. Теперь невозможно сказать, дала ли сложная модель реальный выигрыш или просто повторила то, что уже было в данных.

ПОЧЕМУ ЭТО ОПАСНО

Непрозрачность для аналитика – сложную модель труднее объяснить при разборе инцидента.

Скрытая утечка – без baseline незаметно, что высокий результат держится на утечечном признаке (как в L05).

Лишняя сложность – поддержка и мониторинг тяжёлой модели дороже, а реального выигрыша может не быть.




Карта лекции: от score к классу

9 / 52

Часть 2 · Мотивация

Маршрут, по которому пройдёт основное содержание (Часть 3)

Дальше в лекции мы пройдём по одной сквозной цепочке: как из признаков объекта получается итоговое решение модели. Каждый шаг этой цепочки – отдельный смысловой блок Части 3.



Блоки 3А-3В строят эту цепочку, **блок 3С** объясняет, откуда берётся функция потерь (вывод log-loss), **блоки 3D-3Е** разбирают интерпретацию коэффициентов и калибровку вероятности.



БЛОК 3А

С чего начинается линейная модель

Линейная комбинация признаков, веса и свободный член. Линейная регрессия как интуитивная отправная точка и её собственная функция потерь.



Линейная комбинация признаков

11 / 52

Часть 3 · Блок 3А

Базовая операция всех линейных моделей курса

Любая линейная модель устроена одинаково: она умножает каждый признак объекта на свой вес, складывает результаты и добавляет свободный член. Получается одно число – score. Дальше с этим числом поступают по-разному: для регрессии оно и есть ответ, для классификации его ещё предстоит превратить в вероятность.

$$\text{score}(x) = \langle w, x \rangle + b = w_1 \cdot x_1 + w_2 \cdot x_2 + \dots + w_d \cdot x_d + b$$

$$x \in \mathbb{R}^d$$

вектор признаков объекта: d чисел, описывающих наблюдение.

$$w \in \mathbb{R}^d$$

вектор весов: вклад каждого признака в итоговый score.

$$b \in \mathbb{R}$$

свободный член (bias): сдвиг, не зависящий от признаков.




Линейная регрессия как интуиция

12 / 52

Часть 3 · Блок 3А

Самый простой способ применить линейную комбинацию

Если ответ модели – это число (например, оценка длительности сетевой сессии или ожидаемого объёма трафика), то score сам по себе и есть предсказание: $\hat{y} = \langle w, x \rangle + b$. Геометрически модель подбирает прямую (в общем случае – гиперплоскость), которая проходит «сквозь облако точек» так, чтобы предсказания были как можно ближе к истинным значениям. Регрессия не входит в обязательную часть курса как самостоятельная тема – она нужна здесь как наглядная отправная точка перед классификацией.



Что показывает график

Синие точки – наблюдения, тёмная линия – модель $\hat{y} = \langle w, x \rangle + b$. Наклон линии задаёт вес w , точка пересечения с осью – свободный член b .

Цель обучения – выбрать w и b так, чтобы вертикальные отклонения точек от линии были минимальны.



Функция потерь регрессии: MSE

13 / 52

Часть 3 · Блок 3А

У каждой задачи – своя мера ошибки

Чтобы обучить модель, нужно измерить, насколько её предсказания плохи. Для регрессии естественная мера – средний квадрат отклонения предсказания от истинного значения. Эту функцию минимизируют, подбирая веса.

$$L(w) = (1/N) \cdot \sum_i (y_i - \langle w, x_i \rangle - b)^2$$

y_i – истинное значение для объекта i ; $\langle w, x_i \rangle + b$ – предсказание модели; N – число наблюдений.

Главная мысль. Линейная комбинация $\langle w, x \rangle + b$ – общая для регрессии и классификации. Различаются они функцией потерь: у регрессии это MSE, у классификации будет log-loss. К нему мы и переходим.



Почему для меток 0/1 нужна другая модель

⚠ ЧАСТАЯ ОШИБКА

«Закодирую классы как 0 и 1 и обучу обычную линейную регрессию – она и будет классификатором».

Идея заманчивая: модель уже умеет предсказывать числа. Но прямая линия плохо описывает вероятность принадлежности к классу.

ПОЧЕМУ ЭТО НЕВЕРНО

Выход не ограничен – score свободно выходит за пределы $[0,1]$, а значение «вероятность 1.7» смысла не имеет.

Чувствительность к выбросам – далёкая правильно классифицированная точка тянет прямую и сдвигает границу.

Нужна модель вероятности – score надо сжать в $[0,1]$. Это и есть sigmoid (блок 3В).



БЛОК 3В

Логистическая регрессия: от score к вероятности

Граница решения, sigmoid-функция и вероятность положительного класса. Чёткое различие score, вероятности и итогового класса.




Где линейная модель проводит черту между классами

В бинарной классификации объект относят к одному из двух классов. Линейная модель делает это так: вычисляет $\text{score} = \langle w, x \rangle + b$ и смотрит на его знак. Множество точек, где $\text{score} = 0$, образует границу решения – прямую (в общем случае гиперплоскость), разделяющую пространство признаков на две области.

ОПРЕДЕЛЕНИЕ

Граница решения (decision boundary)

Множество точек x , для которых $\langle w, x \rangle + b = 0$. По одну сторону модель предсказывает класс «+», по другую – класс «-». Для линейной модели эта граница всегда прямая или плоская.





Sigmoid: из score в [0,1]

17 / 52

Часть 3 · Блок 3В

Превращаем неограниченное число в вероятность

Знак score говорит о классе, но его величина – произвольное число. Чтобы получить вероятность, score пропускают через sigmoid-функцию $\sigma(z)$: она монотонно сжимает любое z из $(-\infty, +\infty)$ в интервал $(0, 1)$.


$$\sigma(z) = 1 / (1 + e^{(-z)})$$

$$\sigma(0) = 0.5$$

$$z \rightarrow +\infty \Rightarrow \sigma \rightarrow 1 \quad (\text{класс } +)$$

$$z \rightarrow -\infty \Rightarrow \sigma \rightarrow 0 \quad (\text{класс } -)$$

Здесь $z = \langle w, x \rangle + b$ – тот самый score из блока 3А.



$\sigma(z)$ – вероятность класса «+» в зависимости от score z



Линейная модель, выдающая вероятность класса

ОПРЕДЕЛЕНИЕ

Логистическая регрессия

Модель бинарной классификации, которая оценивает вероятность положительного класса как сигмоиду от линейного score:

$$p = P(y=1 \mid x) = \sigma(\langle w, x \rangle + b)$$

Несмотря на слово «регрессия» в названии, это модель классификации. «Регрессия» здесь – историческое наследие: модель линейна по параметрам w . Обучение состоит в подборе w и b так, чтобы предсказанные вероятности лучше всего соответствовали наблюдаемым меткам – формальный критерий этого мы выведем в блоке 3С.



Score, вероятность, класс

19 / 52

Часть 3 · Блок 3В

Три разных объекта, которые легко перепутать

На выходе модели последовательно появляются три разные величины. Их важно различать – путаница между ними источник многих ошибок интерпретации (см. следующий слайд).

Величина	Запись	Диапазон	Смысл
score	$z = \langle w, x \rangle + b$	Любое число из $(-\infty, +\infty)$	Насколько модель «склоняется» к классу +
вероятность	$p = \sigma(z)$	Число из $(0, 1)$	Оценка $P(y=1 \mid x)$, мера уверенности
класс	$\hat{y} = [p \geq t]$	Метка 0 или 1	Итоговое решение при пороге t (по умолчанию 0.5)

Цепочка односторонняя: score $\rightarrow$ вероятность $\rightarrow$ класс. Обратно восстановить нельзя – по классу 0/1 не вернуть вероятность.



Самая частая путаница на выходе классификатора

⚠ ЧАСТАЯ ОШИБКА

«Модель выдала 0.81 – значит, это класс 1 с вероятностью 81%, и score у объекта тоже примерно 0.81».

Три величины сливаются в одну: число 0.81 объявляется одновременно score, вероятностью и почти классом.

ПОЧЕМУ ЭТО НЕВЕРНО

0.81 – это вероятность, не score. Score (например, $z = 1.45$) лежит до sigmoid; именно $\sigma(1.45) \approx 0.81$ даёт вероятность.

Класс зависит от порога, а не от «81%». При пороге 0.9 объект с $p = 0.81$ будет отнесён к классу 0, а не 1.

Вывод: всегда держите в голове, на каком из трёх этапов вы находитесь.



БЛОК 3С · ЯДРО ЛЕКЦИИ

Откуда берётся функция потерь: вывод log-loss

Принцип максимального правдоподобия → модель Бернулли → log-loss → margin-формулировка. Связь отступа и штрафа за уверенную ошибку.



Как вообще выбирают параметры вероятностной модели

Идея метода проста: среди всех возможных весов w выберем те, при которых наблюдаемые данные наиболее правдоподобны. То есть подберём параметры так, чтобы модель приписывала уже случившимся меткам максимально высокую вероятность.

$$w^* = \operatorname{argmax}_w P(\text{данные} \mid w)$$

Здесь $P(\text{данные} \mid w)$ – правдоподобие: вероятность увидеть именно нашу обучающую выборку при данных весах. Чтобы записать его явно, нужно задать вероятностную модель одного наблюдения. Для бинарной классификации это модель Бернулли.

Зачем максимум. Максимизация правдоподобия – стандартный способ обучения вероятностных моделей. Из него мы и получим функцию потерь логистической регрессии.



Вероятность метки для отдельного наблюдения

Логистическая регрессия выдаёт вероятность $p_i = \sigma(\langle w, x_i \rangle + b)$ того, что объект i принадлежит классу 1. Тогда вероятность увидеть его реальную метку $y_i \in \{0, 1\}$ записывается одной формулой:

$$P(y_i \mid x_i) = p_i^{y_i} \cdot (1 - p_i)^{1 - y_i}$$

Если $y_i = 1$

$$P = p_i^1 \cdot (1 - p_i)^0 = p_i$$

Остаётся вероятность класса 1.

Если $y_i = 0$

$$P = p_i^0 \cdot (1 - p_i)^1 = 1 - p_i$$

Остаётся вероятность класса 0.

Одна формула охватывает оба класса – это и делает запись Бернулли удобной для вывода.



От одного объекта – ко всем N наблюдениям

Если наблюдения независимы, вероятность увидеть всю выборку – это произведение вероятностей по всем объектам. Так получается функция правдоподобия $L(w)$:

$$L(w) = \prod_i p_i^{(y_i)} \cdot (1 - p_i)^{(1 - y_i)}$$

Произведение многих чисел из $(0, 1)$ быстро становится крошечным и неудобным для вычислений и оптимизации. Стандартный приём – перейти к логарифму: он превращает произведение в сумму и не меняет точку максимума, так как логарифм монотонно возрастает.

Следующий шаг. Логарифмируем правдоподобие и меняем знак – максимизация L превращается в минимизацию $\log\text{-loss}$.



От правдоподобия к log-loss

25 / 52

Часть 3 · Блок 3С ★

Логарифмируем, меняем знак – получаем функцию потерь

ШАГ 1 · ЛОГАРИФМ ПРЕВРАЩАЕТ ПРОИЗВЕДЕНИЕ В СУММУ

$$\log L(w) = \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

ШАГ 2 · МЕНЯЕМ ЗНАК: МАКСИМИЗАЦИЯ → МИНИМИЗАЦИЯ

$$L_{\log}(w) = - \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

Главный результат: log-loss – это отрицательное логарифмическое правдоподобие модели Бернулли.

Минимизируя log-loss, мы ровно максимизируем правдоподобие. «Штраф за уверенную ошибку» – теперь строгий результат, а не аналогия.



Margin-формулировка log-loss

26 / 52

Часть 3 · Блок 3С ★

Компактная запись через отступ – нотация экзамена

СМЕНА НОТАЦИИ. С этого места метки записываем как $y \in \{-1, +1\}$ вместо $\{0, 1\}$.

В новой нотации алгебра упрощается, и обе ветви Бернулли сливаются в одно выражение:

$$L(w) = \sum_i \log(1 + \exp(-y_i \cdot \langle w, x_i \rangle))$$

ОПРЕДЕЛЕНИЕ · ОТСТУП (MARGIN)

$m_i = y_i \cdot \langle w, x_i \rangle$. Отступ положителен, если знак score совпал с истинной меткой (верная классификация), и тем больше, чем увереннее верный ответ.




Margin и штраф за ошибку

27 / 52

Часть 3 · Блок 3С ★

Как отступ управляет величиной потерь

Потеря на одном объекте – это $\log(1 + \exp(-m_i))$, функция от отступа m_i . Она монотонно убывает: большой положительный отступ почти не штрафует, отрицательный – штрафует тем сильнее, чем увереннее ошибка.



Потеря $\log(1 + \exp(-m))$ в зависимости от отступа m

$$m \gg 0$$

уверенно верно
потеря $\rightarrow 0$

$$m \approx 0$$

у границы решения
потеря $\approx \log 2 \approx 0.69$

$$m < 0$$

ошибка, тем хуже
чем увереннее
потеря растёт линейно



Мини-резюме: вывод log-loss

28 / 52

Часть 3 · Блок 3С ★

Что необходимо унести из ядра лекции

- Параметры выбирают по принципу максимального правдоподобия: $\text{argmax}_w P(\text{данные} \mid w)$.
- Вероятность одной метки задаётся моделью Бернулли: $p^y \cdot (1-p)^{(1-y)}$.
- Логарифм превращает произведение в сумму; смена знака даёт log-loss.
- log-loss = отрицательное log-правдоподобие – это строгий результат, а не аналогия.
- В нотации $y \in \{-1, +1\}$ потеря компактна: $L(w) = \sum \log(1 + \exp(-y\langle w, x \rangle))$.
- Отступ $m = y\langle w, x \rangle$ управляет штрафом: больше отступ – меньше потеря.



БЛОК 3D

Интерпретация коэффициентов

Что говорят веса модели, почему их нельзя читать без учёта масштаба признаков и кодирования. Коэффициенты как первый инструмент интерпретации.

Подробно про интерпретацию – в L09. Здесь – первый инструмент.



Как читать вес отдельного признака

Каждый признак входит в score со своим весом w_j . Знак веса показывает направление влияния, а абсолютная величина – силу этого влияния при прочих равных (*ceteris paribus*). Это первое, на что смотрит инженер, открывая обученную линейную модель.

Знак w_j

$w_j > 0$ – признак тянет score к классу «+».

$w_j < 0$ – к классу «-».

Величина $|w_j|$

Чем больше модуль, тем сильнее вклад признака в итоговый score (при сопоставимом масштабе).

Важная оговорка. Сравнивать величины весов между признаками можно только если признаки в одном масштабе. Об этом – следующие слайды.



Почему вес зависит от единиц измерения

Вес признака обратно связан с его масштабом: если измерять тот же признак в более мелких единицах, его значения вырастут, а вес во столько же раз уменьшится – при том же вкладе в score. Поэтому «маленький» вес не значит «неважный признак».

Признак «объём трафика»	Значение x	Вес w	Вклад $w \cdot x$
в килобайтах	2.0	0.80	1.60
в байтах ($\times 1024$)	2048	0.00078	1.60

Тот же признак, тот же вклад в score (1.60) – но вес отличается в 1024 раза. Вывод: чтобы сравнивать веса между собой, признаки предварительно стандартизируют (приводят к сопоставимому масштабу).



Ошибка: вес без учёта масштаба

32 / 52

Часть 3 · Блок 3D

Самая частая ошибка чтения коэффициентов

⚠ ЧАСТАЯ ОШИБКА

«У признака A вес 0.8 , у признака B вес 0.0008 – значит, A в тысячу раз важнее B ».

Весы сравнивают «в лоб», как будто признаки уже в одном масштабе.

ПОЧЕМУ ЭТО НЕВЕРНО

Масштаб маскирует важность – малый вес может стоять при признаке с огромными значениями (как «байты» из примера).

Сравнение легально только после стандартизации – тогда веса выражены в одинаковых единицах «на одно стандартное отклонение».

Альтернатива – смотреть на вклад $w \cdot x$ на реальных данных, а не на сам вес.



Как линейная модель работает с категориальными признаками

Линейная модель принимает числа, поэтому категориальный признак (например, протокол: TCP / UDP / ICMP) кодируют набором бинарных столбцов – по одному на категорию. Это и есть one-hot encoding. Одну категорию обычно делают базовой (опускают), и веса остальных интерпретируются относительно неё.

Протокол	is_TCP	is_UDP	is_ICMP
TCP	1	0	0
UDP	0	1	0
ICMP	0	0	1

Как читать веса

Если базовая категория – TCP, то вес при is_UDP показывает, насколько UDP-трафик сдвигает score относительно TCP.

Поэтому коэффициент категории – это всегда сравнение с базой, а не «абсолютная важность» категории.



Когда коэффициенты в принципе несопоставимы

⚠ ЧАСТАЯ ОШИБКА

«В одной модели вес признака 1.2, в другой 0.4 – значит, в первой он важнее».

Коэффициенты сравнивают между моделями, обученными при разной предобработке: другое кодирование, другая база, другая стандартизация.

ПОЧЕМУ ЭТО НЕВЕРНО

Разная база one-hot – если базовые категории отличаются, веса измеряют сдвиг относительно разных точек отсчёта.

Разная стандартизация – вес «на одно стандартное отклонение» зависит от того, на каких данных оно посчитано.

Правило: сравнивать коэффициенты осмысленно только внутри одной схемы предобработки.



Что унести про интерпретацию весов

- Знак веса задаёт направление влияния признака, модуль – силу при прочих равных.
- Вес зависит от масштаба признака: «маленький» вес $\neq$ «неважный признак».
- Сравнивать веса между собой можно только после стандартизации признаков.
- Коэффициент one-hot категории – это сравнение с базовой категорией, а не абсолютом.
- Коэффициенты разных моделей сопоставимы только при одинаковой предобработке.
- Коэффициенты – первый инструмент интерпретации; систематический разбор – в L09.

Зачем это в ИБ. Чтение коэффициентов помогает находить подозрительные и утечечные признаки – это мы увидим на CIC-IDS-2018 в Части 4.



БЛОК 3Е

Калибровка вероятностей



Ошибка: sigmoid = вероятность

37 / 52

Часть 3 · Блок 3Е

Чем опасно доверие к сырой вероятности в ИБ

⚠ ЧАСТАЯ ОШИБКА

«Модель выдала $p = 0.95$ – значит, объект с вероятностью 95% является атакой».

Сырой выход sigmoid принимают за точную, проверенную вероятность и строят на ней решения.

ПОЧЕМУ ЭТО ОПАСНО В ИБ

Порог под цену ошибки сломается – если выбирать порог по цене FP/FN (как в L04), некалиброванная p даёт неверный порог.

Ложное доверие аналитика – «95%» воспринимается как факт, хотя реальная доля атак среди таких объектов может быть 70%.

Решение: вероятности нужно калибровать (Platt scaling, isotonic) – это тема L07.



Вероятность $\rightarrow$ порог $\rightarrow$ класс

38 / 52

Часть 3 · Блок 3Е

Порог не обязан быть 0.5

Чтобы получить итоговый класс, вероятность сравнивают с порогом t : если $p \geq t$, объект относят к классу 1. По умолчанию $t = 0.5$, но это не закон. Порог выбирают под цену ошибок задачи (введена в L04): в одних сценариях дороже пропуск атаки, в других – ложная тревога.

Низкий порог

$$t = 0.2$$

Ловим больше атак, но растёт число ложных тревог. Уместен, когда пропуск атаки очень дорог.

Порог по умолчанию

$$t = 0.5$$

Нейтральная отправная точка, не учитывающая цену ошибок.

Высокий порог

$$t = 0.8$$

Меньше ложных тревог, но часть атак пропускаем. Уместен при дорогом ложном срабатывании.

Продолжение в L07. Систематический выбор порога под цену ошибок и калибровка вероятностей – отдельная тема следующей лекции.



Мини-резюме: вероятность и порог

39 / 52

Часть 3 · Блок 3Е

Завершение основного содержания (Часть 3)

- Выход sigmoid лежит в $(0,1)$, но не обязан быть откалиброванной вероятностью.
- Модель откалибрована, если $p \approx 0.8$ соответствует $\sim 80\%$ объектов класса 1 на практике.
- Доверие к сырой p опасно: ломается порог под цену ошибок, аналитик переоценивает уверенность.
- Класс получают сравнением p с порогом t ; $t = 0.5$ – лишь отправная точка.
- Порог выбирают под цену ошибок (L04); калибровка и выбор порога – тема L07.



Напоминание: на этих данных мы иллюстрируем весь курс

CIC-IDS-2018 – открытый датасет сетевого трафика, который используется как сквозной пример всего курса. Каждая строка – одно сетевое соединение (flow), описанное набором числовых признаков. Задача: отличить нормальный трафик (Benign) от атак.

СКВОЗНОЙ ДАТАСЕТ КУРСА

CIC-IDS-2018 – кратко

~16 млн сетевых соединений (flow)

~80 числовых признаков на flow

Benign + атаки DoS, DDoS, Brute Force, ботнет и др.

табличный формат – идеален для линейной модели

Конвенция курса: где нужен пример на реальных данных – берём CIC-IDS-2018. В этой лекции – для классификации соединений и интерпретации коэффициентов.



Бинарная классификация соединения *Benign* / атака

ИБ-КЕЙС · ПОСТАНОВКА

Детектор атак на табличных признаках

Вход: признаки соединения – длительность, число пакетов, объём байт, флаги. **Выход:**

$p = P(\text{атака} \mid \text{признаки})$, затем класс по порогу. **Протокол:**


train/val/test split и контроль leakage – по протоколу из L05.

Почему линейная модель здесь уместна как первый шаг: признаки уже числовые и табличные, обучение мгновенное, а коэффициенты сразу показывают, какие характеристики соединения тянут решение в сторону «атака». Это даёт объяснимый baseline ещё до того, как заходить в бустинг или нейросети.



Что веса говорят инженеру (иллюстративные значения)

После стандартизации признаков веса сопоставимы, и их знак с величиной читаются напрямую. Положительный вес тянет решение к классу «атака», отрицательный – к «Benign».



Как читает инженер

Высокая интенсивность пакетов и большой объём байт сильнее всего тянут к «атака» – согласуется с DoS/DDoS.

Большой средний размер пакета смещает к «Benign».

Веса дают проверяемую гипотезу о признаках – её можно обсудить с аналитиком.



Линейная модель на разреженных текстовых признаках

ИБ-КЕЙС · ТЕКСТЫ

Классификация писем: фишинг или нет

Признаки: TF-IDF по словам письма – тысячи разреженных признаков (большинство нулевые). **Модель:** логистическая регрессия поверх TF-IDF – классический сильный baseline для текстов. **Интерпретация:** слова с большим положительным весом – маркеры фишинга («urgent», «verify», «account»).

Линейная модель на TF-IDF часто конкурирует со сложными моделями на коротких текстах, при этом остаётся быстрой и полностью объяснимой. Детальный разбор текстовых пайплайнов – в L15.

→ Подробно про TF-IDF и тексты – в L15.



Почему TF-IDF и линейная модель – естественная пара

Текстовые и логовые признаки часто разрежены: на каждый объект приходится лишь горстка ненулевых значений из десятков тысяч возможных. Линейная модель работает с этим особенно хорошо.

Масштабируемость

$\text{score} = \langle w, x \rangle$ считается только по ненулевым признакам – быстро даже при десятках тысяч измерений.

Объяснимость

Каждому слову/признаку соответствует один вес; легко вывести топ маркеров класса.

Контраст со сложными моделями. Деревья и нейросети на очень разреженных высокоразмерных данных часто работают хуже и дольше – здесь линейная модель не просто baseline, а сильный кандидат в финал.



Ошибка: утечный признак

45 / 52

Часть 4 · Практика ИБ

Когда коэффициенты выдают слишком хорошее качество

⚠ ЧАСТАЯ ОШИБКА

«Модель дала ROC-AUC 0.999 на детекции атак – отличный результат, выкатываем в прод!»

Подозрительно высокое качество принимают за успех, а не за сигнал тревоги.

ПОЧЕМУ ЭТО СИГНАЛ УТЕЧКИ

Коэффициенты выдают виновника – один признак имеет огромный вес, остальные почти нулевые. Это первый признак leakage.


Часто это утечка из будущего – признак вроде «метка инцидента» или ID, косвенно содержащий ответ (см. L05).

Линейный baseline тут – инструмент аудита: интерпретируемость помогает поймать утечку раньше, чем чёрный ящик.



Когда прямой границы недостаточно

Линейная модель проводит только прямую границу. Если классы разделяются нелинейно, она принципиально не сможет их разделить – сколько бы данных ни было. Классический пример – задача XOR: ни одна прямая не отделит её классы.



Что делать

Признаковая инженерия – добавить нелинейные комбинации признаков, чтобы данные стали линейно разделимы.

Нелинейные модели – деревья и ансамбли (L08), нейросети (L13) строят сложную границу автоматически.

Но и тогда линейный baseline остаётся точкой отсчёта: он показывает, какой прирост даёт переход к сложной модели.



Семь ключевых утверждений

1. Baseline-ценность

Линейная модель – объяснимый и воспроизводимый baseline для ИБ-задач.

2. score $\rightarrow$ p $\rightarrow$ класс

Три разные величины; sigmoid превращает score в вероятность, порог – в класс.

3. log-loss из MLE

Функция потерь выводится из правдоподобия Бернулли, а не вводится по аналогии.

4. margin

$L(w) = \sum \log(1 + \exp(-y\langle w, x \rangle))$; отступ управляет штрафом за уверенную ошибку.

5. Масштаб коэффициентов

Веса интерпретируемы только с учётом масштаба и кодирования признаков.

6. Калибровка $\neq$ вероятность

Сырой выход sigmoid не обязан быть честной вероятностью.

7. Границы линейности

Нелинейно разделяемые классы требуют признаковой инженерии или нелинейных моделей.



Чек-лист принятия решения

✓ ПОДХОДИТ, КОГДА

- нужен быстрый объяснимый baseline;
- признаки числовые / табличные;
- признаки разреженные (TF-IDF, логи);
- важна интерпретируемость и аудит;
- нужна стабильная простая модель.

✗ НЕ ЛУЧШИЙ ВЫБОР, КОГДА

- классы разделимы только нелинейно;
- важны сложные взаимодействия признаков;
- максимальное качество важнее объяснимости;
- признаки требуют богатой иерархии решений.

Но даже когда линейная модель не финальная – она остаётся обязательной точкой отсчёта (baseline-дисциплина).



Место L06 в курсе

49 / 52

Часть 5 · Итоги

Откуда пришли и куда ведёт эта лекция

ОПИРАЕТСЯ НА (НАЗАД)

L04 метрики и цена ошибок

L05 split, leakage, протокол

L03 понятие baseline

L06 · Линейные модели (вы здесь)

ВЕДЁТ К (ВПЕРЁД)

L07
регуляризация, калибровка,
порог

L08
деревья и ансамбли

L09
интерпретируемость

L15
TF-IDF и тексты

Ближайшее продолжение – L07: то, что мы отложили (калибровка вероятностей и систематический выбор порога).



Что прочитать для глубокого понимания

Pattern Recognition and Machine Learning – Bishop, C. (2006)

Гл. 4 – линейные модели для классификации; гл. 3 – регрессия. Вывод log-loss и связь с правдоподобием.

The Elements of Statistical Learning – Hastie, Tibshirani, Friedman

Гл. 4 – линейные методы классификации; логистическая регрессия и её обучение.

Machine Learning: A Probabilistic Perspective – Murphy, K. (2012)

Гл. 8 – логистическая регрессия с вероятностной точки зрения; MLE и связь с log-loss.



Инструменты и данные для самостоятельной работы

LogisticRegression – документация – *scikit-learn*

Параметры, регуляризация, мультиклассовость. Тьюториал по линейным моделям и калибровке (CalibratedClassifierCV).

Открытый датасет сетевого трафика – *CIC-IDS-2018*

Сквозной датасет курса. Подходит для практики: классификация Benign/атака линейной моделью на табличных признаках.

Logistic Regression – серия роликов – *StatQuest (video)*

Наглядное объяснение sigmoid, log-loss и интерпретации коэффициентов для тех, кому нужен визуальный заход.

Совет: начните с практики на CIC-IDS-2018 – обучите логрегрессию и прочитайте коэффициенты, прежде чем переходить к сложным моделям.



Ключевые термины лекции

score – $\langle w, x \rangle + b$ – линейная комбинация до sigmoid

логистическая регрессия – $p = \sigma(\langle w, x \rangle + b)$, модель $P(y=1|x)$

правдоподобие – вероятность данных при параметрах w

log-loss – $-\log$ -правдоподобие Бернулли

коэффициент – вес признака w_j в score

калибровка – соответствие p фактической доле класса

sigmoid – $\sigma(z) = 1/(1+e^{-z})$, сжимает score в $(0,1)$

decision boundary – граница $\langle w, x \rangle + b = 0$ между классами

MLE – выбор w по максимуму правдоподобия

margin (отступ) – $m = y\langle w, x \rangle$, кодирует верность и уверенность

one-hot – кодирование категории бинарными столбцами

порог – граница t для перехода $p \rightarrow$ класс