



ЛЕКЦИЯ L07

Регуляризация, калибровка вероятностей и выбор порога принятия решений

Машинное обучение и безопасность систем

Магистратура НИУ ВШЭ (МИЭМ) · ОП «Информационная безопасность и технологии ИИ»

Автор: Силаев Ю. В. · Время изучения: ~70 минут



Эта лекция за одну минуту

2 / 52

ЧАСТЬ 1 · ВВЕДЕНИЕ

Что вы поймёте к концу L07

Модель не заканчивается на обучении. В L06 вы получили линейную модель, которая выдаёт score и через sigmoid превращает его в число от 0 до 1. Но качество ML-решения определяется не только обученной моделью – а ещё тремя вещами, которые делаются *после* обучения.

Регуляризация контролирует переобучение и устойчивость модели.
Калибровка проверяет, можно ли вообще считать выход модели вероятностью. **Порог** превращает вероятность в конкретное решение «да / нет» – и зависит от того, как именно модель используется в системе безопасности.



Регуляризация

надёжность модели



Калибровка

честность вероятности



Порог

само решение



После изучения вы сможете:

- ✓ объяснять назначение регуляризации как способа ограничить сложность модели;
- ✓ различать L1- и L2-регуляризацию на прикладном уровне;
- ✓ понимать влияние регуляризации на переобучение, устойчивость и интерпретацию;
- ✓ объяснять, что такое калибровка вероятностей и зачем она нужна;
- ✓ читать calibration curve и понимать идею reliability;
- ✓ выбирать порог принятия решения на validation set;
- ✓ объяснять компромисс precision-recall при изменении порога;
- ✓ связывать выбор порога с ценой ошибок в ИБ-сценарии.



Что нужно знать до начала

4 / 52

ЧАСТЬ 1 · ВВЕДЕНИЕ

Эта лекция опирается на три предыдущие

L06

Линейные модели

Вектор весов w , score $\langle w, x \rangle + b$, sigmoid $\sigma(z)$ и log-loss. Регуляризация и калибровка строятся поверх этой модели.

L04

Метрики и цена ошибок

Precision, recall и идея, что разные ошибки стоят по-разному. Здесь мы применяем это к выбору порога.

L05

Валидация и leakage

Зачем нужен отдельный validation set и почему нельзя подбирать что-либо по test. Критично для подбора λ и порога.



План лекции

5 / 52

ЧАСТЬ 1 · ВВЕДЕНИЕ

7 частей · 52 слайда · ~70 минут изучения

1	Введение	1-5	~6 мин
2	Мотивация: зачем это в ИБ	6-9	~5 мин
3	Основное содержание	10-38	~38 мин
4	Связки с практикой ИБ	39-45	~10 мин
5	Итоги	46-48	~4 мин
6	Источники для углубления	49-50	~3 мин
7	Глоссарий	51-52	~3 мин

Тёмно-синие части – содержательное ядро, на которое приходится бóльшая часть времени.



Почему обученной модели с отличной метрикой может быть недостаточно

Представьте детектор сетевых атак с ROC-AUC = 0.95. По метрике из L04 это отличная модель: она хорошо *ранжирует* объекты – почти всегда ставит атаке более высокий score, чем легитимному трафику. Кажется, что работа сделана.

Но ROC-AUC не отвечает на три вопроса, без которых система не работает:

(1) не переобучилась ли модель на случайных артефактах обучающих данных; (2) можно ли доверять её числу 0.97 как *вероятности*; (3) при каком пороге превращать score в решение «блокировать / пропустить».



ROC-AUC = 0.95

...но это не значит:

- модель устойчива и не переобучена
- её score – это калиброванная вероятность
- порог 0.5 даёт работающее решение



Три рычага после обучения

7 / 52

ЧАСТЬ 2 · МОТИВАЦИЯ

Карта лекции: что мы добавляем к обученной модели и в каком порядке

Каждый рычаг отвечает за свой вопрос. Они идут по цепочке: от самой модели – к её выходу – к решению.

1



Регуляризация

Надёжна ли сама модель?

Штраф за сложность ограничивает переобучение и снижает зависимость от случайных признаков.

Блок 1

2



Калибровка

Вероятность ли это?

Проверяем, соответствует ли число на выходе фактической частоте события.

Блок 2

3



Порог

Какое решение принять?

Превращаем вероятность в действие «да / нет» под конкретный режим использования.

Блоки 3-4



Одна модель – два противоположных требования к порогу

CIS-IDS-2018 · ЧТО ЭТО

Сквозной датасет курса: ~16 млн записей сетевого трафика (flow) за 10 дней, 80 признаков, 14 типов атак + Benign. Используем его как единый пример на протяжении всего курса.

Одна обученная модель выдаёт для каждого flow score «насколько это похоже на атаку». Но используют её в двух разных местах системы – и требования к ней противоположны:



Автоматическая блокировка

Нужна высокая precision. Ложная блокировка легитимной операции = недоступность сервиса. Цена ошибки FP очень высока.



Приоритизация алертов SOC

Нужен высокий recall. Пропущенная атака опаснее лишнего алерта: аналитик всё равно проверит. Цена ошибки FN высока.

Вывод: модель одна – а порог должен быть разный. Это и есть тема лекции.



Что ломается без них

9 / 52

ЧАСТЬ 2 · МОТИВАЦИЯ

Три типовые ошибки реальных ML-систем в ИБ

ЧАСТАЯ ОШИБКА



Порог оставлен 0.5 «по умолчанию»

ПОЧЕМУ ЭТО НЕВЕРНО

0.5 оптимален только при равной цене ошибок и калиброванной вероятности. В ИБ так почти не бывает – система либо заваливает SOC ложными алертами, либо пропускает атаки.

ЧАСТАЯ ОШИБКА



Score принят за вероятность без проверки

ПОЧЕМУ ЭТО НЕВЕРНО

Некалиброванная «уверенность 0.99» запускает автоматическую блокировку там, где модель на самом деле не уверена. Для автоматических решений это прямой риск.

ЧАСТАЯ ОШИБКА



Регуляризация настроена «на глаз»

ПОЧЕМУ ЭТО НЕВЕРНО

Без контроля на validation модель либо переобучается на артефактных признаках конкретного дампа трафика, либо теряет сигнал. В проде качество рухнет на новых данных.



ЧАСТЬ 3 · ОСНОВНОЕ СОДЕРЖАНИЕ · БЛОК 1 из 4



Регуляризация

Ограничение сложности модели как защита от переобучения. Что штрафует, зачем и чем отличаются L1 и L2.



Откуда берётся переобучение там, где модель «всего лишь» линейная

Линейная модель из L06 кажется простой: она складывает признаки с весами. Но если признаков много, **у модели хватает свободы подстроиться под шум** – случайные совпадения в обучающих данных, которых нет в реальности.

Признак переобучения: веса w становятся большими и разнонаправленными – модель «выучивает» отдельные точки. На обучении качество растёт, на новых данных – падает.

В ИБ это особенно опасно: модель может «зацепиться» за артефакт конкретного дампа трафика (порядок портов, тайминги сбора) вместо настоящего признака атаки.



Симптом переобучения

Обучающая выборка
качество ↑ почти до 100%

Новые данные
качество ↓ резко падает



ОПРЕДЕЛЕНИЕ

Регуляризация – это добавление к функции потерь штрафа за сложность модели. Обучение начинает искать баланс: не только хорошо предсказывать на обучающих данных, но и держать веса небольшими.

Сложность $\approx$ величина весов

Чем больше и «резче» веса, тем гибче модель подстраивается под шум. Штраф удерживает их в разумных пределах.

Баланс, а не запрет

Регуляризация не запрещает сложность – она делает её «платной». Модель использует сложность только если та реально улучшает предсказание.



Как штраф за сложность встраивается в обучение

$$L_{\text{reg}}(w) = L(w) + \lambda \cdot R(w)$$

$L(w)$

Потери на данных

Насколько модель ошибается на обучающей выборке (например, log-loss из L06).

$R(w)$

Штраф за сложность

Мера «величины» весов. Чем больше веса – тем больше штраф.

λ

Сила регуляризации

Гиперпараметр. Задаёт, насколько дорого обходится сложность. Подбирается отдельно.



Две регуляризации: L2 и L1

14 / 52

ЧАСТЬ 3 · БЛОК 1

Один и тот же принцип, разный штраф $R(w)$ – и разный эффект



L2-регуляризация

$$R(w) = \|w\|^2 = \sum w_i^2$$

Сглаживает веса.

Уменьшает все веса плавно, но почти не зануляет.
Модель становится устойчивее к шумным признакам, сохраняя все из них.

Эффект: устойчивость, гладкость.



L1-регуляризация

$$R(w) = \|w\|_1 = \sum |w_i|$$

Разреживает признаки.

Часть весов становится ровно нулём –
соответствующие признаки выпадают из модели.
Похоже на автоматический отбор признаков.

Эффект: разреженность, отбор.



Гиперпараметр λ и его подбор

15 / 52

ЧАСТЬ 3 · БЛОК 1

Слишком слабый штраф – переобучение, слишком сильный – недообучение

λ не выучивается при обучении – его задаём мы. Он управляет балансом между точностью на данных и простотой модели.


λ мало → штраф почти не работает → **переобучение**.

λ велико → веса задавлены → **недообучение**.



Как выбирать: перебираем несколько λ , обучаем модель на train, сравниваем качество на **validation** (из L05) – берём λ с лучшим validation-качеством.

Ошибка в зависимости от λ





Почему этот инструмент особенно важен именно в ИБ-задачах

ИБ-КОНТЕКСТ

В ИБ-данных полно «обманчивых» признаков: конкретные IP, номера портов, тайминги сбора дампа. Они отлично разделяют классы в обучающей выборке, но не переносятся на новый трафик. Регуляризация снижает зависимость модели от таких случайных признаков.

1

Устойчивость к артефактам

Модель меньше «цепляется» за особенности конкретного дампа и лучше работает на свежем трафике.

2

Подготовка к drift

Меньшая зависимость от случайных признаков = мягче деградация при смене источника данных. Подробно – в L17.

3

Понятнее веса

L1 обнуляет лишнее, L2 сглаживает – в обоих случаях итоговую модель проще анализировать (связь с L09).



ЧАСТАЯ ОШИБКА



«L1 надёжно отбирает правильные признаки – если вес обнулится, признак точно лишний».

ПОЧЕМУ ЭТО НЕВЕРНО



Среди коррелированных признаков L1 произвольно оставляет один и зануляет остальные – выбор зависит от случайностей данных, а не от «настоящей» важности. **Обнулённый признак не значит «бесполезный»; оставленный не значит «единственно верный».**



Как правильно: относитесь к L1 как к инструменту разреживания, а не к доказательству важности. Усиливать или ослаблять регуляризацию – только с контролем на validation.



Четыре вещи, которые нужно унести из блока 1

1

Штраф за сложность

Регуляризация добавляет в потери штраф $\lambda \cdot R(w)$ и удерживает веса небольшими – это защита от переобучения.

2

$L2 \neq L1$ по эффекту

$L2$ плавно уменьшает все веса; $L1$ часть весов зануляет, давая эффект отбора признаков.

3

λ подбирают на validation

Слишком мало – переобучение, слишком много – недообучение. Оптимум ищут на validation, не на test.

4

В ИБ – про устойчивость

Регуляризация снижает зависимость от артефактных признаков дампа и готовит модель к смене данных (drift, L17).



БЛОК 1 ЗАВЕРШЁН → ПЕРЕХОД К БЛОКУ 2

Мы научились **контролировать саму модель**.
Теперь посмотрим на её **выход**.

Модель выдаёт число от 0 до 1. Но можно ли считать его **вероятностью**? Об этом – блок 2: калибровка.



Блок 2 · Калибровка вероятностей



ЧАСТЬ 3 · ОСНОВНОЕ СОДЕРЖАНИЕ · БЛОК 2 из 4



Калибровка вероятностей

Можно ли доверять числу на выходе модели как вероятности? Reliability, calibration curve, Brier score.



$\sigma(z)$ – это ещё не вероятность

21 / 52

ЧАСТЬ 3 · БЛОК 2

Самое частое заблуждение про выход классификатора

ЧАСТАЯ ОШИБКА



«Модель выдала 0.9 – значит, вероятность атаки 90%». Раз *sigmoid* возвращает число от 0 до 1, это и есть вероятность.

ПОЧЕМУ ЭТО НЕВЕРНО



$\sigma(z)$ обучена *разделять* классы, а не выдавать честную частоту. Модель может стабильно говорить «0.9» там, где на деле атак лишь 60%. Число в диапазоне $[0, 1]$ ещё не значит «вероятность» – это просто **score** после сжатия.

Что значит «честное» число: среди всех объектов с предсказанием 0.9 примерно 90% действительно должны оказаться атаками. Это свойство и называется **калиброванностью**.



Когда число на выходе можно честно называть вероятностью



ОПРЕДЕЛЕНИЕ

Модель **калибрована**, если её предсказанные вероятности совпадают с фактическими частотами: среди объектов с предсказанием p доля положительных примерно равна p .

Ранжирование $\neq$ калибровка

Модель может идеально упорядочивать объекты (высокая ROC-AUC), но при этом систематически завышать или занижать вероятности.

Зачем это нужно

Если число – настоящая вероятность, его можно сравнивать с порогом, складывать с ценой ошибки, использовать в автоматических решениях.



Calibration curve

23 / 52

ЧАСТЬ 3 · БЛОК 2

Как одним графиком увидеть, честны ли вероятности модели

По оси X – **предсказанная** вероятность, по оси Y – **фактическая** доля положительных в этой группе.


Диагональ – идеал. Точки на ней = калибровано.

Ниже диагонали = модель *переуверена* (обещает 0.9, по факту реже).

Выше = недоуверена.

Reliability diagram – другое название этого же графика.
«Reliability» = надёжность вероятностей.

Calibration curve





Одно число для качества вероятностей – на уровне понимания

$$\text{Brier} = \text{среднее } (p - y)^2$$

Что внутри

p – предсказанная вероятность (от 0 до 1).

y – факт: 1 если событие случилось, иначе 0.

Считаем квадрат расхождения и усредняем по всем объектам.

Как читать

Меньше – лучше. 0 – идеальные вероятности.

Штрафует и за ошибку, и за **ложную уверенность**:
уверенное «0.99» по неверному объекту наказывается сильно.

Удобен как одно сравнимое число между моделями.



Перекалибровка не трогает модель – только переводит её score в честную вероятность

Platt scaling

Сигмоида поверх score.

Подгоняет одну гладкую S-образную кривую, которая переводит score модели в вероятность.

- ✓ работает на малых данных
- ✓ устойчива, мало параметров
- предполагает «сигмоидную» форму искажения

Isotonic calibration

Ступенчатая монотонная функция.

Не задаёт форму заранее – строит любую неубывающую кривую под данные.

- ✓ гибче, ловит сложные искажения
- ✓ не требует предположений о форме
- переобучается на малых данных



Когда плохая калибровка опасна

26 / 52

ЧАСТЬ 3 · БЛОК 2

В безопасности цена ложной уверенности зависит от режима использования

ИБ-КОНТЕКСТ

Для ранжирования калибровка не критична – важен лишь порядок. Но как только score используется в **автоматическом решении**, ложная уверенность становится прямым риском: система действует так, будто уверена, хотя на деле – нет.

Калибровка не критична

Приоритизация алертов, ранжирование расследований: важен порядок, а не абсолютное значение вероятности.

Калибровка обязательна

Автоблокировка по «вероятность > 0.95»: некалиброванное 0.95 запускает блокировку там, где реальный риск куда ниже.

Важно: калибровка, настроенная на одном трафике, ломается при смене источника данных. Калибровка под drift – отдельная тема в [L17](#).



Мини-резюме: калибровка

27 / 52

ЧАСТЬ 3 · БЛОК 2

Четыре вещи, которые нужно унести из блока 2

1

Score $\neq$ вероятность

Выход sigmoid – это число в $[0,1]$, но не обязательно честная вероятность. Это надо проверять, а не предполагать.

2

Калибровка = факт

Среди объектов с предсказанием p доля положительных должна быть $\approx p$. Calibration curve показывает это наглядно.

3

Brier – одно число

Меньше – лучше. Штрафует и за ошибку, и за ложную уверенность. Удобен для сравнения моделей.

4

Platt и isotonic

Перекалибровка переводит score в вероятность: Platt – гладкая и устойчивая, isotonic – гибкая, но жаднее к данным.



БЛОК 2 ЗАВЕРШЁН → ПЕРЕХОД К БЛОКУ 3

Теперь у нас есть **честная вероятность**. Осталось превратить её в **решение**.

Вероятность 0.73 – это «блокировать» или «пропустить»? Ответ зависит от **порога**. Об этом – блок 3.



Блок 3 · Выбор порога принятия решения



ЧАСТЬ 3 · ОСНОВНОЕ СОДЕРЖАНИЕ · БЛОК 3 из 4



Выбор порога

Превращаем вероятность в решение «да / нет». Почему 0.5 не универсален и как порог связан с ценой ошибок.



Почему 0.5 – не универсален

30 / 52

ЧАСТЬ 3 · БЛОК 3

Порог по умолчанию оптимален лишь при двух условиях, которых в ИБ обычно нет

Порог 0.5 неявно предполагает, что:

Цена ошибок равна

- 1 Ложное срабатывание стоит столько же, сколько пропуск. В ИБ почти никогда: пропустить атаку ≠ заблокировать клиента.

Вероятности калиброваны

- 2 0.5 – честная граница «50 на 50». Если модель не калибрована (блок 2), 0.5 вообще не означает равновесия.



Порог – это инженерное решение

Порог нельзя «угадать» – его **выбирают** под конкретную задачу: насколько дорого ошибиться в каждую сторону и в каком режиме работает модель.

Дальше: как сдвиг порога меняет precision и recall.



Сдвиг порога: precision vs recall

31 / 52

ЧАСТЬ 3 · БЛОК 3

Введено в L04 – здесь применяем к выбору рабочего порога

Порог выше → срабатываем только при высокой уверенности.


Меньше ложных тревог → **precision** ↑, но пропускаем часть атак → **recall** ↓.

Порог ниже → срабатываем чаще.

Ловим больше атак → **recall** ↑, но больше ложных тревог → **precision** ↓.

Нельзя максимизировать оба сразу. Выбор точки на кривой = выбор баланса под задачу.

Зависимость от порога





Порог подбирают на validation под цену ошибок – это инженерный шаг, не обучение

1

Зафиксировать цену ошибок

Сколько стоит ложное срабатывание и сколько – пропуск. Это формулирует бизнес/SOC, не модель.

2

Перебрать пороги

Для набора порогов считаем precision, recall и итоговую «стоимость» на validation set (из L05).

3

Выбрать лучший по цели

Берём порог, который оптимизирует нужную метрику: минимум стоимости, либо recall при ограничении на FP.

4

Задokumentировать выбор

Фиксируем порог и причину. К документированию вернёмся на следующем слайде и в L20.



ЧАСТАЯ ОШИБКА



«Переберём пороги прямо на test set и возьмём тот, что даёт лучшие precision/recall – заодно и качество померим».

ПОЧЕМУ ЭТО НЕВЕРНО



Подбор порога – это настройка под данные. Делая её на test, вы фактически **подсматриваете в экзамен** (по сути leakage из L05). Оценка станет оптимистичной: на новых данных порог сработает хуже. **И отдельно: высокая ROC-AUC не гарантирует хороший рабочий порог – это разные вещи.**



Как правильно: порог подбираем на validation, а test трогаем один раз – только чтобы честно оценить итог.



Четыре вещи, которые нужно унести из блока 3

1

0.5 не универсален

Порог по умолчанию хорош лишь при равной цене ошибок и калиброванных вероятностях – в ИБ так почти не бывает.

2

Trade-off precision-recall

Выше порог – precision ↑, recall ↓; ниже – наоборот. Оба максимизировать нельзя, выбираем баланс.

3

Порог – на validation

Перебираем пороги на validation под цену ошибок. На test подбирать порог нельзя – это leakage.

4

Порог под цену ошибок

Выбор порога – инженерное решение под задачу: что дороже – ложная тревога или пропуск.



ЧАСТЬ 3 · ОСНОВНОЕ СОДЕРЖАНИЕ · БЛОК 4 из 4



Режимы использования

Один score – разные режимы. Как режим применения модели в системе диктует свой порог.



Четыре режима – четыре порога

36 / 52

ЧАСТЬ 3 · БЛОК 4

Линия курса «модель как компонент системы»: режим применения диктует порог



Автоблокировка

Требуется: **очень высокая precision**

Действуем без человека. Ложное срабатывание = ущерб → порог высокий, бьём только наверняка.



Предупреждение

Требуется: **баланс precision/recall**

Показываем предупреждение пользователю. Цена ошибки умереннее → порог средний.



Ручная проверка / триаж

Требуется: **управляемый поток**

Алерт уходит аналитику. Порог – под пропускную способность SOC, чтобы не захлебнуться.



Приоритизация

Требуется: **высокий recall**

Ранжируем расследования по score. Порог низкий или не нужен – важен порядок, не отсечка.



Порог без зафиксированной причины – это мина замедленного действия

Порог – это не магическое число, а **решение**, принятое под конкретные допущения. Если их не записать, через полгода никто не вспомнит, почему стоит 0.83, а не 0.5.



Итоговая фиксация порога вместе с другими решениями о надёжности оформляется в reliability note – об этом в **L20**.

Что зафиксировать

- значение порога и режим использования;
- цену ошибок, под которую он выбран;
- на каком наборе данных подбирался (validation);
- ожидаемые precision / recall на этом пороге;
- дату и условия пересмотра.



Три вещи, которые нужно унести из блока 4

1

Режим определяет порог

Автоблокировка требует высокой precision, приоритизация – высокого recall. Одна и та же модель работает с разными порогами в разных местах системы.

2

Одна модель ≠ один порог

Не существует «правильного» порога в отрыве от применения. Порог – часть интеграции модели в систему, а не свойство самой модели.

3

Документируйте выбор

Фиксируйте порог, его режим, цену ошибок и данные подбора. Итоговая фиксация – в reliability note (L20).



Соберём всю лекцию на одном детекторе сетевых атак

ДАТАСЕТ

CIC-IDS-2018: ~16 млн flow сетевого трафика, 80 признаков, сильный дисбаланс (атак – единицы процентов). Обучили классификатор: на каждый flow он выдаёт калиброванную вероятность «это атака».

Одна и та же модель встраивается в два узла системы безопасности. Мы пройдем по обоим и увидим: метрики у модели одни, а рабочий порог – разный.



Узел 1: автоблокировка

Inline-защита периметра. Блокирует flow автоматически, без человека. → слайд 40



Узел 2: приоритизация

Очередь алертов для SOC-аналитиков. Ранжирует, кого проверять первым. → слайд 41



Узел 1: автоблокировка

40 / 52

ЧАСТЬ 4 · СВЯЗКИ С ИБ

Высокий порог → высокая precision: блокируем только наверняка

РЕЖИМ: БЛОКИРОВАТЬ

Цена ошибки FP огромна: заблокировать легитимный трафик = положить рабочий сервис. Поэтому выбираем высокий порог.

Порог $T = 0.92$

99.3%

precision – почти нет ложных блокировок

61%

recall – часть атак проходит мимо

0.02%

доля заблокированного легитимного трафика

Что это значит на практике: почти все блокировки оправданы (precision 99.3%), но детектор сознательно пропускает ~39% атак – их ловит второй узел. Для inline-блокировки это правильный размен: лучше пропустить, чем заблокировать своих.

Низкий порог → высокий recall: ничего не теряем, аналитик разберётся

РЕЖИМ: ПРИОРИТИЗИРОВАТЬ

Здесь нет автоматического действия: алерт уходит человеку. Цена FN высока (пропущенная атака), цена FP терпима (лишняя проверка). Берём низкий порог.

Порог $T = 0.35$

97%

recall — почти все атаки попадают в
очередь

44%

precision — много ложных алертов

× 6

рост потока алертов к аналитикам

Та же модель, другой порог. Recall взлетел до 97% — мы почти ничего не пропускаем. Платим ростом ложных алертов, поэтому score ещё и используем для *ранжирования*: аналитик начинает с самых вероятных. Порог под пропускную способность SOC.



Пример: фишинговый фильтр

42 / 52

ЧАСТЬ 4 · СВЯЗКИ С ИБ

Тот же принцип на другой задаче: порог под допустимое число ложных блокировок

ИБ - КЕЙС

Фильтр входящей почты ставит письму вероятность «фишинг». Заблокированное письмо пользователь не увидит. Ложная блокировка делового письма может стоить дороже, чем пропущенный спам – порог задаём под допустимый уровень FP.

Порог низкий

агрессивная блокировка

Ловим почти весь фишинг, но блокируем и часть деловой почты. Пользователи теряют письма – недопустимо.

Порог средний

разумный баланс

Подозрительное – в карантин, не удаляем. Пользователь может проверить папку «спам». Частый рабочий выбор.

Порог высокий

только наверняка

Блокируем лишь явный фишинг, остальное пропускаем с пометкой. Минимум ложных блокировок, но больше пропусков.



Кульминация: одна модель работает в двух режимах одновременно

ИБ - КЕЙС

Антивирус оценивает файл и выдаёт вероятность «вредоносный». Один и тот же score используется сразу в двух режимах – с двумя разными порогами.



Режим «предупредить»

Порог низкий (≈ 0.3).

Файл не блокируется – пользователь видит предупреждение и решает сам. Высокий recall: предупреждаем обо всём подозрительном, ложная тревога стоит дёшево.



Режим «заблокировать»

Порог высокий (≈ 0.9).

Файл удаляется автоматически. Высокая precision: удаляем только при явной уверенности – ложно удалить рабочий файл недопустимо.

Главный вывод лекции: модель – это компонент системы. Её пригодность определяется не только метриками, но и тем, в каком режиме и с каким порогом она применяется.



Три особенности, из-за которых порог и калибровка в ИБ важнее обычного



Сильный дисбаланс

Атак – единицы процентов или доли процента. Порог 0.5 почти всегда мимо; точность без recall обманчива.



Дрейф источников

Трафик и типы атак меняются со временем. Порог и калибровка, настроенные вчера, завтра могут «поплыть».



Score как ранжирование

Часто score корректен по порядку, но не как вероятность. Для очереди алертов годится, для автоблокировки – лишь после калибровки.

Вывод: именно из-за этих особенностей в ИБ нельзя оставлять порог по умолчанию и принимать score за вероятность без проверки.



Калибровка ломается при смене источника

Перекалибровали на трафике одной сети – развернули в другой. Вероятности снова врут. Возвращаемся к этому в L17 (drift).



Порог «защит» и забыт

Однажды подобранный порог живёт годами без пересмотра, хотя данные и атаки давно изменились. Поэтому фиксируем условия пересмотра.



ROC-AUC выдают за готовность к прод

Высокая AUC на отчёте ≠ работающая система. Без выбранного порога, калибровки и режима модель в прод не готова.



Если унести только это – лекция выполнила свою задачу

- 1 Качество ML-решения = модель + регуляризация + калибровка + порог.
- 2 Регуляризация штрафует сложность: L2 сглаживает, L1 разреживает; λ – на validation.
- 3 Выход sigmoid – это score, а не обязательно вероятность; калибровку надо проверять.
- 4 Calibration curve и Brier score показывают, честны ли вероятности.
- 5 Порог 0.5 не универсален; precision и recall меняются при его сдвиге.
- 6 Порог выбирают на validation под цену ошибок, не на test.
- 7 Один score – разные пороги под режим: блокировка, предупреждение, триаж, приоритизация.



Что мы сознательно НЕ разбирали – и где это встретится

Строгая теория обобщения

Формальные оценки обобщающей способности и теория регуляризации остаются за рамками курса.

Оптимизация L1

Алгоритмы минимизации негладкого L1-штрафа здесь не разбираем – берём эффект, не механику.

Bayesian calibration

Сложные вероятностные модели калибровки выходят за уровень «на понимание».

Conformal prediction

Более продвинутый подход к оценке неопределённости – упоминаем, но не углубляемся.

Cost-sensitive learning

Учёт цены ошибок прямо в обучении – отдельный класс методов, не рассматриваем.

Авто-оптимизация порога

Автоматический подбор порога под сложные бизнес-функции оставляем за рамками.



Где идеи этой лекции продолжаютсся дальше

L07 – это узел между «получить модель» и «эксплуатировать решение». Вот куда тянутся её нити:

L08

Деревья и ансамбли

Та же регуляризация и калибровка применимы к ансамблям, не только к линейным моделям.

L09

Интерпретируемость

Разреженная (L1) модель и понятные веса упрощают анализ ошибок.

L17

Устойчивость к drift

Калибровка и порог «плывут» при смене данных – отдельная тема устойчивости.

L20

Reliability note

Итоговая фиксация порога и решений о надёжности оформляется здесь.



С чего начать, чтобы закрепить материал лекции



Pattern Recognition and Machine Learning – *C. Bishop*

Гл. 3-4: линейные модели, регуляризация, вероятностная трактовка выхода.



The Elements of Statistical Learning – *T. Hastie, R. Tibshirani, J. Friedman*

Гл. 7: оценка моделей и подбор сложности; основа для λ и validation.



Probability calibration (CalibratedClassifierCV) – *scikit-learn*

Практика: calibration curve, Platt (sigmoid) и isotonic «из коробки».



Когда базовый материал освоен

Platt (1999)

Probabilistic Outputs for SVMs – первоисточник идеи sigmoid-калибровки (Platt scaling).

Niculescu-Mizil & Caruana (2005)

Predicting Good Probabilities – сравнение методов калибровки, наглядные calibration curves.

Conformal prediction (обзор)

Современный подход к оценке неопределённости с гарантиями покрытия – для тех, кому мало калибровки.

Datasheet CIC-IDS-2018

Описание сквозного датасета курса: состав трафика, типы атак, известные особенности и артефакты.



Регуляризация и калибровка

Регуляризация

Штраф за сложность модели, добавляемый к функции потерь.

L2-регуляризация

Штраф $\|w\|^2$; плавно уменьшает веса, повышает устойчивость.

L1-регуляризация

Штраф $\|w\|_1$; зануляет часть весов, разреживает признаки.

λ (лямбда)

Гиперпараметр силы регуляризации; подбирается на validation.

Переобучение

Подстройка модели под шум обучающих данных; падение качества на новых.

Калибровка

Соответствие предсказанной вероятности фактической частоте события.

Calibration curve

График предсказанной vs фактической вероятности; диагональ — идеал.

Reliability

Надёжность вероятностей; синоним идеи калиброванности.



Порог и режимы использования

Brier score

Среднее $(p-y)^2$; качество вероятностей, меньше — лучше.

Platt scaling

Калибровка сигмоидой поверх score; устойчива на малых данных.

Isotonic calibration

Монотонная непараметрическая калибровка; гибкая, но жадная к данным.

Порог (threshold)

Граница вероятности, выше которой принимается положительное решение.

Precision-recall trade-off

Рост порога повышает precision и снижает recall, и наоборот.

Цена ошибок

Относительная стоимость ложного срабатывания и пропуска.

Режим использования

Способ применения модели: блокировка, предупреждение, триаж, приоритизация.

Reliability note

Документ с зафиксированным порогом и решениями о надёжности (L20).