



ЛЕКЦИЯ 09

Интерпретируемость моделей и анализ ошибок

Машинное обучение и безопасность систем

Магистратура НИУ ВШЭ (МИЭМ) · ОП «Информационная безопасность и технологии ИИ»

Автор: Силаев Ю. В. · Время изучения: ≈ 75 минут · self-paced



Эта лекция за одну минуту

2 / 57

ЧАСТЬ 1 · ВВЕДЕНИЕ

О чём L09 и почему она стоит сразу после ансамблей

Хороший ML-эксперимент не заканчивается числом на validation set.

Высокая метрика говорит, что модель часто угадывает ответ, но ничего не говорит о том, *как именно* она его получает – на какие признаки опирается, где систематически ошибается и не выучила ли случайную или утечную закономерность.

Интерпретируемость и анализ ошибок – это инструменты проверки: они показывают, действительно ли модель выучила осмысленные и допустимые закономерности. В этой лекции вы научитесь читать модель глобально и локально, разбирать ошибки по типам и подгруппам и через интерпретацию находить утечки данных.

КЛЮЧЕВОЙ ТЕЗИС

Интерпретируемость нужна не для «красивых объяснений», а для проверки того, что модель решает задачу по правильным причинам.

ГДЕ В КУРСЕ

Блок 1 · после L08 (деревья и ансамбли).



Учебные результаты лекции L09

1

Различать два взгляда на модель. глобальную и локальную интерпретацию – и понимать, какой вопрос решает каждый.

3

Применять методы интерпретации. коэффициенты, feature importance, permutation importance; понимать идею SHAP, LIME и partial dependence на прикладном уровне.

5

Находить утечки и спурионные связи. выявлять leakage и неустойчивые закономерности через подозрительно важные признаки.

2

Делать содержательный error analysis. разбирать false positives и false negatives отдельно, а не смотреть на одну итоговую метрику.

4

Анализировать ошибки по подгруппам. slice analysis по пользователям, источникам, времени и чувствительным группам как часть надёжности модели.

6

Формулировать выводы о доработке. что улучшать: данные, признаки, протокол валидации, модель или порог.



Что нужно знать до начала

4 / 57

ЧАСТЬ 1 · ВВЕДЕНИЕ

Лекция опирается на уже пройденный материал курса

К этому моменту вы прошли все основные семейства моделей. L09 не вводит новые модели – она учит проверять уже обученные.

Лекция	Тема	Что понадобится в L09
L04	Метрики и цена ошибок	FP/FN, precision/recall, почему цена ошибок несимметрична.
L05	Валидация и утечки данных	Типология leakage и схемы split – вернёмся к ним при поиске утечек.
L06	Линейные модели	Коэффициенты w как первый инструмент интерпретации.
L07	Порог и калибровка	Выбор порога под цену ошибок; confidence модели.
L08	Деревья и ансамбли	Impurity-based importance – концепция отсюда, методы – в L09.



План лекции

5 / 57

ЧАСТЬ 1 · ВВЕДЕНИЕ

Семь частей · 57 слайдов · *≈ 75 минут самостоятельного изучения*

1	Введение	слайды 1-5	<i>≈ 6 мин</i>
2	Мотивация: зачем мало одной метрики	слайды 6-10	<i>≈ 7 мин</i>
3	Основное содержание: интерпретация, методы, error analysis, slice, leakage	слайды 11-45	<i>≈ 45 мин</i>
4	Связки с практикой ИБ	слайды 46-50	<i>≈ 7 мин</i>
5	Итоги	слайды 51-53	<i>≈ 4 мин</i>
6	Источники для углубления	слайды 54-55	<i>≈ 3 мин</i>
7	Глоссарий	слайды 56	<i>≈ 3 мин</i>



Метрика 0.95 ничего не значит

Высокое число на validation set – необходимое, но далеко не достаточное условие

Представьте две модели обнаружения вторжений. Обе показывают **ROC-AUC ≈ 0.95** на отложенной выборке. По таблице метрик они неразличимы – и обе выглядят «готовыми к проду».

Но первая опирается на поведенческие признаки трафика, а вторая – на признак, который в реальном потоке данных просто отсутствует (его проставляют постфактум аналитики). **В проде вторая модель рушится**, хотя на офлайне была «отличной». Итоговая метрика этого различия не видит – его видно только когда мы спрашиваем модель: *по каким признакам ты решаешь?*

0.95

одинаковый ROC-AUC у обеих
моделей

≈ 0

реальная польза второй модели в
проде



ИБ-кейс: антифрод, который выучил не то

Реальный сценарий – модель «отличная» офлайн, но бесполезная в эксплуатации

ИБ-КЕЙС

Команда обучила антифрод-модель на исторических транзакциях. **Precision и recall на тесте – выше 0.9.** После выката в прод поток ложных срабатываний вырос в разы: легитимные операции массово блокировались. Разбор через интерпретацию показал, что топ-1 признак по важности – `manual_review_flag`, который проставляется аналитиком уже *после* решения по транзакции. Модель выучила не поведение мошенника, а след работы аналитика.

Что показала только метрика

«Модель отличная, можно катить». Цифра зелёная – вопросов нет.

Что показала интерпретация

Модель опирается на утечку (leakage по target). В проде признака нет – решение мусорное.



Объяснимость в ИБ – не роскошь

Особенности задач безопасности делают проверяемость решения обязательной

В информационной безопасности цена ошибки несимметрична, а доверие к системе хрупко. Возможность проверить, на каком основании модель приняла решение, – часть надёжности, а не косметика.

Ложные срабатывания подрывают доверие

Если система часто кричит «атака» по легитимному трафику, аналитики начинают игнорировать алерты – и пропустят настоящий инцидент.

Пропуски (FN) особенно дороги

Незамеченное вторжение – уже реализованный риск. FN нужно разбирать отдельно и прицельно, а не растворять в средней метрике.

Аналитику нужно понимать сигнал

При триаже алерта человек должен видеть, по каким признакам модель сделала вывод, иначе он не может ни подтвердить, ни оспорить решение.

Интерпретация вскрывает дефекты данных

Через подозрительно важные признаки находятся leakage, артефакты датасета и спурионные зависимости – раньше, чем они навредят.



Что ломается без анализа ошибок

Типовые провалы реальных систем, когда инженер остановился на итоговой метрике

ЧАСТАЯ ОШИБКА

«Метрика хорошая → модель готова». Инженер смотрит на одно итоговое число (accuracy, ROC-AUC, F1), не разбирает, где именно модель ошибается, не отделяет false positives от false negatives, не проверяет качество по подгруппам и не задаётся вопросом, почему самый важный признак именно такой.

ПОЧЕМУ ЭТО НЕВЕРНО

Средняя метрика усредняет и прячет провалы. За «хорошим» числом скрываются: модель, выучившая утечку (как антифрод на прошлом слайде); систематический пропуск целого класса атак; деградация на отдельной подсети или в ночные часы; уверенные ошибки, которым команда доверяет больше всего. Ни один из этих дефектов не виден в таблице метрик – и каждый проявится в проде, когда цена уже реальна.



Карта лекции: от числа к смыслу

Как устроено основное содержание – пять шагов от метрики к выводам о доработке

Дальше лекция выстроена как маршрут. Сначала учимся читать модель, затем разбираем её ошибки всё детальнее, и в конце превращаем находки в конкретные решения о том, что чинить.



...а затем – Часть 4: те же инструменты на реальном ИБ-пайплайне (CIC-IDS-2018, фишинг, изображения).



А

Блок А

Два взгляда на модель: глобально и локально

Прежде чем измерять важность признаков или разбирать ошибки, нужно договориться, что вообще значит «интерпретировать модель». В этом блоке – два базовых режима интерпретации, первые инструменты (коэффициенты и feature importance), их ограничения и понятие спурионной корреляции.

В этом блоке: глобальная vs локальная интерпретация · коэффициенты линейной модели (L06) · их ограничения · feature importance (L08) · спурионная корреляция



Глобальная и локальная интерпретация

Два разных вопроса к одной и той же обученной модели

ОПРЕДЕЛЕНИЕ

Глобальная интерпретация отвечает на вопрос «как модель устроена в целом» – какие признаки в среднем важны для её решений. **Локальная интерпретация** отвечает на вопрос «почему *этот* конкретный объект получил именно такой ответ».

Глобально

Вопрос: на что модель опирается вообще?

Инструменты: коэффициенты, feature importance, permutation importance, partial dependence.

ИБ-смысл: понять общую логику детектора, найти подозрительно важный признак.

Локально

Вопрос: почему именно этот объект?

Инструменты: SHAP- и LIME-объяснения отдельного предсказания.

ИБ-смысл: объяснить аналитику, почему модель пометила это соединение как атаку.



Коэффициенты – первый инструмент

13 / 57


ЧАСТЬ 3 · БЛОК А

Коэффициенты линейной модели мы видели в L06 – теперь систематически, как интерпретацию

В линейной модели score объекта – это $\langle \mathbf{w}, \mathbf{x} \rangle + \mathbf{b}$. Каждый коэффициент w_j – это вклад признака x_j в итоговый score. Знак показывает направление влияния, величина – силу. Это самый прозрачный вид глобальной интерпретации: модель буквально раскрывает свою логику в виде вектора весов.

Как читать: $w_j > 0$ – признак толкает к классу «атака»; $w_j < 0$ – к «benign»; $w_j \approx 0$ – почти не влияет.

Веса детектора (пример)



Знак = направление, длина = сила влияния



Почему вес признака нельзя читать как «важность» напрямую

ЧАСТАЯ ОШИБКА

«У признака самый большой коэффициент → он самый важный». Это верно только при стандартизованных признаках и при отсутствии сильной корреляции между ними. Иначе величина веса говорит больше о масштабе признака, чем о его роли.

Масштаб признака

Признак в байтах и признак в гигабайтах получают разные веса при одинаковой роли. Без стандартизации сравнивать величины нельзя.

Коллинеарность

Два сильно коррелированных признака делят вес между собой произвольно – один может выглядеть «важным», другой «нулевым».

Только линейный эффект

Коэффициент описывает линейный вклад. Нелинейные зависимости и взаимодействия признаков он не показывает.



Feature importance в ансамблях


Impurity importance – концептуально из L08, методы интерпретации – здесь

Линейная модель раскрывает себя через веса. У деревьев и ансамблей весов нет – но есть **feature importance**: числовая оценка того, насколько каждый признак в среднем влиял на решения модели. Это тоже *глобальная* интерпретация – она характеризует модель целиком, а не отдельный объект.

ГРАНИЦА ТЕМЫ (РАЗВИЛКА L08 ↔ L09)

Сам механизм impurity-based importance и его смещения мы ввели в **L08**. Здесь мы не возвращаемся к устройству деревьев – мы используем importance как **инструмент интерпретации уже обученной модели** и сравниваем его с более надёжными методами (следующий блок).

Feature importance (пример)



Сумма ≈ 1 ; всегда ≥ 0 , направления не показывает



Понятие, ради которого мы вообще читаем важность признаков

ОПРЕДЕЛЕНИЕ

Спурионная (ложная) корреляция – устойчивая статистическая связь признака с целевой переменной, которая возникает из-за артефакта сбора данных или постороннего фактора, а не из-за содержательной зависимости. Модель честно её выучивает – и ломается, когда в проде этого артефакта нет.

Зачем это здесь: ни feature importance, ни коэффициенты сами по себе не отличают осмысленную связь от спурионной. Интерпретация даёт гипотезу, которую затем нужно проверить.

Осмысленная связь

Число неудачных попыток входа $\uparrow \rightarrow$ вероятность атаки $\uparrow$. Связь сохранится и в проде.

Спурионная связь

ID-диапазон сбора данных совпал с типом атаки в датасете. В проде совпадения нет – модель промахнётся.



Блок А: что мы разобрали

17 / 57

ЧАСТЬ 3 · БЛОК А

Мини-резюме перед переходом к методам интерпретации

1

Глобально ≠ локально

Глобальная интерпретация описывает модель в целом, локальная – отдельное предсказание. Это разные вопросы и разные инструменты.

2

Коэффициенты – вход в тему

Веса линейной модели прозрачны, но читаются корректно только при стандартизации и без сильной коллинеарности.

3

Feature importance – глобальный сигнал

Для деревьев и ансамблей роль признаков оценивает importance; механизм impurity-варианта – из L08.

4

Важность ≠ истина

Ни коэффициент, ни importance не отличают осмысленную связь от спурионной. Интерпретация даёт гипотезу, а не доказательство.

Дальше – Блок В: permutation importance, SHAP, LIME и partial dependence как более надёжные инструменты интерпретации.



В

Блок В

Методы интерпретации

В блоке А мы читали модель через коэффициенты и feature importance – и увидели их пределы. Теперь – более надёжные инструменты: permutation importance, SHAP, LIME и partial dependence. Все они даются на прикладном уровне: что метод делает, какие у него допущения и где он врёт.

В этом блоке: *impurity и её смещения · permutation importance (идея, формула, пример, ограничения) · SHAP · LIME · partial dependence · мини-резюме*



Impurity importance и её смещения

Почему встроенной важности ансамбля недостаточно

Деревья и ансамбли считают важность «бесплатно» – по тому, насколько каждый признак улучшал разбиения при обучении (**impurity-based importance**, механизм – из L08). Это удобно, но у метода два систематических смещения, из-за которых ему нельзя доверять как финальной оценке.

Что с этим делать. Impurity importance годится как быстрый первый взгляд, но выводы о роли признаков нужно перепроверять методом, не зависящим от устройства модели. Такой метод – permutation importance, к нему и переходим.

СМЕЩЕНИЕ 1

К признакам с многими уровнями.

Признаки с большим числом значений (id, порт) получают завышенную важность.

СМЕЩЕНИЕ 2

Нечувствительность к корреляциям.

Из группы коррелированных признаков важность достаётся одному, остальные кажутся лишними.



Модель-агностичный способ измерить, на что модель реально опирается

Идея проста: если признак действительно важен, то *разрушение* связи между этим признаком и ответом должно ухудшить качество модели. Берём обученную модель, в проверочной выборке **случайно перемешиваем** значения одного признака между объектами и снова считаем метрику. Насколько она просела – настолько признак важен.

Ключевое отличие от impurity: метод не заглядывает внутрь модели. Он работает с любой моделью одинаково – линейной, лесом, бустингом, нейросетью.

ФОРМУЛА

$$PI_j = s - s_j$$

s – метрика на исходной выборке

s_j – метрика после перемешивания признака j

PI_j – падение качества = важность j

Перемешивание повторяют несколько раз и усредняют – оценка случайная.



Пример: permutation на CIC-IDS-2018

Считаем важность признаков сетевого детектора перестановкой

CIC-IDS-2018: ЧТО ЭТО

Публичный датасет сетевого трафика
– сквозной пример курса.


≈ **16 млн** flow-записей за 10 дней

80 признаков потока

14 типов атак + класс Benign

*Задача: отличить атаку от
нормального трафика по признакам
потока.*

Permutation importance (падение ROC-AUC при перемешивании)



Как читать: перемешивание Dst Port роняет ROC-AUC на 0.131 – это главный сигнал детектора. Pkt Len Std почти не влияет (0.018) – кандидат на удаление. Если бы первым оказался искусственный признак – это повод заподозрить утечку (блок Е).



Ограничения permutation importance

Метод надёжнее impurity, но тоже не истина в последней инстанции

ЧАСТАЯ ОШИБКА

«Permutation importance показывает истинную важность признаков». Метод честнее impurity, но у него есть свои ловушки – особенно при коррелированных признаках и при разрушении реалистичности объектов.

Коррелированные признаки

Если два признака дублируют друг друга, перемешивание одного почти не вредит – модель берёт сигнал из второго. Оба выглядят неважными, хотя вместе важны.

Нереалистичные объекты

Перемешивание создаёт комбинации значений, которых в реальности не бывает (порт 80 с признаками UDP-флуда). Модель оценивается на «невозможных» точках.

Случайность оценки

Результат зависит от конкретной перестановки. Без усреднения по нескольким прогонам важность может скакать от запуска к запуску.




Локальная интерпретация: вклад каждого признака в конкретное предсказание

Permutation importance отвечает на *глобальный* вопрос. SHAP отвечает на *локальный*: почему **этот конкретный** объект получил такой ответ. Идея: разложить предсказание на вклады отдельных признаков так, чтобы вклады в сумме давали отклонение ответа от среднего по выборке.

Что вы получаете: для каждого объекта – список признаков с числовым вкладом и знаком: какие толкали к «атаке», какие к «benign» и насколько. Вклады аддитивны и согласованы между объектами.

Граница темы: математический вывод SHAP (значения Шепли) – вне курса. Нам важен прикладной смысл и ограничения.

SHAP-объяснение одного flow (пример)



+ толкает к «атаке», – к «benign»



Другой путь к локальному объяснению: простая модель вокруг одной точки

LIME решает ту же локальную задачу, но иначе. Вокруг интересующего объекта он генерирует множество слегка изменённых копий, смотрит, что предсказывает на них *исходная модель*, и подгоняет на этих точках **простую модель** (обычно линейную). Коэффициенты этой простой модели и есть локальное объяснение.

Интуиция: сложную нелинейную границу решения вблизи одной точки можно приблизить прямой. LIME строит эту локальную прямую и читает её как объяснение.

SHAP

Вклады признаков из теории игр; **аддитивны и согласованы** между объектами. Стабильнее, но дороже считать.

LIME

Локальная линейная аппроксимация; **быстрее и нагляднее**, но результат зависит от случайных возмущений и менее устойчив.



SHAP и LIME: допущения и пределы

Объяснение – это модель поведения модели, а не сама истина

ЧАСТАЯ ОШИБКА

«Раз есть красивый SHAP-график – модель объяснена». Локальное объяснение действительно только рядом с конкретным объектом. Переносить его на всю модель как глобальный закон нельзя – это разные уровни. Картинка без вывода о том, что менять, бесполезна.

ПОЧЕМУ ЭТО НЕВЕРНО

Допущения, которые часто игнорируют:

- При сильной корреляции признаков SHAP может приписывать вклад «не тому» признаку из группы.
- LIME нестабилен: повторный запуск с другими возмущениями даёт другое объяснение того же объекта.
- Оба объясняют, что модель сделала, но не доказывают, что связь причинная или допустимая – спурионный признак получит большой вклад так же охотно, как осмысленный.



Partial dependence: идея и пределы


Как в среднем меняется предсказание при изменении одного признака

Partial dependence (PDP) – ещё один *глобальный* взгляд. Вопрос: как меняется средний прогноз модели, если мысленно прогонять один признак по всему диапазону его значений, а остальные оставлять как есть? Получается кривая «значение признака → средний ответ модели».

КОГДА PDP ВВОДИТ В ЗАБЛУЖДЕНИЕ

- При корреляции признаков усреднение создаёт нереалистичные комбинации (как в permutation).
- Кривая усредняет: разнонаправленные эффекты у разных подгрупп взаимно гасятся и выглядят как «нет влияния».

PDP: вероятность атаки vs число неудачных входов





Мини-резюме методов интерпретации перед переходом к анализу ошибок

1**Глобально: permutation > impurity**

Permutation importance не зависит от устройства модели и надёжнее встроенной impurity, но чувствителен к корреляциям и реалистичности.

2**Локально: SHAP и LIME**

SHAP даёт аддитивные согласованные вклады; LIME – быструю локальную линейную аппроксимацию. Оба объясняют один объект, а не всю модель.

3**Эффект признака: PDP**

Partial dependence показывает средний эффект признака на прогноз, но усредняет подгруппы и страдает от корреляций.

4**Метод – гипотеза, не приговор**

У каждого инструмента свои допущения. Любое объяснение – повод проверить, осмыслен ли сигнал, а не финальное доказательство.

Дальше – Блок С: метрика посчитана, методы освоены – переходим к систематическому анализу ошибок (FP и FN по отдельности).



С

Блок С

Анализ ошибок

Метрика посчитана, методы интерпретации освоены. Теперь – не «сколько» ошибок, а «какие» и «почему». Систематический разбор ошибок отделяет ложные срабатывания от пропусков, ищет уверенные ошибки и закономерности в промахах. Это превращает одно число в список конкретных проблем модели и данных.

***В этом блоке:** что такое error analysis · почему FP и FN – разные ошибки · разбор false positives · разбор false negatives · анализ confidence · мини-резюме*



От «сколько модель ошибается» к «на чём и почему»

ОПРЕДЕЛЕНИЕ

Error analysis (анализ ошибок) – систематический разбор объектов, на которых модель ошиблась: их группировка, поиск общих признаков и закономерностей. Цель – понять природу ошибок и сформулировать, что менять: данные, признаки, протокол валидации, модель или порог.

Только метрика

«ROC-AUC = 0.94».

Одно число. Не говорит, какие объекты модель путает и можно ли это исправить.

Error analysis

«FN сконцентрированы на медленных атаках по ночам».

Конкретный диагноз → конкретное действие.



FP и FN – это разные ошибки

30 / 57

ЧАСТЬ 3 · БЛОК С

Усреднять их в одну метрику опасно: цена и причины различны

Как мы видели в **L04**, цена ошибок в ИБ несимметрична, поэтому false positives и false negatives нужно разбирать **раздельно**: у них разные последствия, причины и способы лечения. Сдвиг порога (**L07**) уменьшает один тип ошибок ценой роста другого.

False Positive (FP)

Benign помечен как атака.

Последствие: ложная тревога, лишняя блокировка, недоверие аналитиков к системе.

Лечение: точнее признаки, выше порог, разбор похожих легитимных объектов.

False Negative (FN)

Атака пропущена как benign.

Последствие: реализованный инцидент, который никто не увидел. В ИБ обычно дороже FP.

Лечение: ниже порог, новые признаки под пропущенный тип атаки, дозбор данных.



Какие нормальные потоки детектор путает с атакой – и почему

ИБ-КЕЙС · CIC-IDS-2018

Детектор даёт 4.1% ложных срабатываний. Собрали все FP и сгруппировали их. Оказалось: **62% FP – это легитимные сканеры мониторинга и бэкап-задания**, у которых профиль трафика (много коротких соединений к разным портам) похож на разведку. Модель реагирует на форму трафика, не на намерение.

Как разбирали – 3 шага:

1 · Собрать

Выгрузить все объекты с `y=benign`, но предсказанием «атака».

2 · Сгруппировать

Кластеризовать FP по признакам и источникам; найти общий профиль.

3 · Объяснить

SHAP на типичном FP: какой признак тащит к «атаке» ошибочно.




Какие атаки детектор пропускает – самый дорогой разбор в ИБ

ИБ-КЕЙС · CIC-IDS-2018

Общий recall высокий, но разбили пропуски по типам атак – и картина изменилась. **Медленные атаки (slow DoS, низкоинтенсивный brute-force) пропускаются в разы чаще:** их поток почти неотличим от нормального по мгновенным признакам. Средняя метрика это прятала – провал виден только в разрезе по типам.

Recall по типам атак (пример)



ВЫВОД

Два типа атак (Slow DoS, Infiltration) фактически не детектируются. Это не «шум в метрике», а слепая зона детектора. Лечение: признаки временной структуры (предвосхищение L12) и дозбор примеров этих атак.



Где модель ошибается уверенно – и почему это худший случай

Не все ошибки одинаковы. Ошибка при уверенности 0.51 – почти монетка, объект на границе. Ошибка при уверенности 0.97 – модель **уверенно права**. Именно уверенным предсказаниям доверяют автоматические блокировки и аналитики, поэтому уверенные ошибки опаснее всего. Калибровка вероятностей (**L07**) говорит, можно ли вообще доверять числу 0.97 как вероятности.

Что делать: отдельно собрать ошибки с высоким confidence и разобрать их в первую очередь – это либо утечка, либо систематический дефект данных.

Уверенно верно <i>хорошо</i>	Уверенно неверно <i>ХУДШЕЕ</i>
Неуверенно верно <i>о к</i>	Неуверенно неверно <i>о ж и д а е м о</i>

уверенность →

приоритет разбора – верхний правый угол



Частая ошибка: не смотрят на FN

Самая распространённая и самая дорогая ошибка анализа в ИБ

ЧАСТАЯ ОШИБКА

«Ассигасу высокая, FP мало – всё хорошо». Аналитик смотрит на общую точность и на ложные срабатывания (они заметны и раздражают), но не разбирает пропуски отдельно и не смотрит recall по типам атак и подгруппам.

ПОЧЕМУ ЭТО НЕВЕРНО

FP видно сразу, FN – нет, и именно поэтому FN опаснее.

- При сильном дисбалансе классов высокая ассигасу достигается, даже если почти все атаки пропущены.
- Пропущенный инцидент не приходит с жалобой – он просто остаётся незамеченным до последствий.
- Без разреза по типам атак слепая зона (как Slow DoS на прошлом слайде) прячется за хорошей средней цифрой.



Мини-резюме анализа ошибок перед переходом к slice analysis

1

Ошибки – это сигнал

Error analysis превращает одно число в список конкретных проблем: что и почему модель путает.

2

FP и FN – раздельно

Разная цена, причины и лечение. Усреднение в одну метрику прячет важный тип ошибки.

3

Уверенные ошибки – приоритет

Ошибка с высоким confidence опаснее: ей доверяют. Часто это маркер утечки или дефекта данных.

4

Смотреть в разрезе

Recall по типам атак и подгруппам вскрывает слепые зоны, невидимые в среднем. Это мост к slice analysis.

Дальше – Блок D: «средняя метрика прячет провалы на подгруппах» – формализуем разрез в slice analysis.

D

Блок D

Slice analysis

В блоке C мы увидели: recall по типам атак вскрывает слепые зоны, невидимые в среднем. Slice analysis формализует эту идею – мы считаем метрику не по всей выборке, а по осмысленным срезам: пользователи, источники, время, классы. Средняя цифра обманчива; провал почти всегда концентрируется на конкретной подгруппе.

***В этом блоке:** что такое slice analysis · slice по CIC-IDS-2018 · чувствительные группы и граница темы (не fairness-аудит) · мини-резюме*



Что такое slice analysis

Качество не в среднем, а по осмысленным срезам объектов

ОПРЕДЕЛЕНИЕ

Slice analysis (анализ по срезам) – оценка качества модели отдельно на подгруппах объектов (срезах), а не только в целом. Срез задаётся осмысленным признаком: тип объекта, источник, устройство, география, временной период, чувствительная группа.

Зачем: одна агрегированная метрика усредняет хорошие и провальные подгруппы в одно «приемлемое» число. Slice analysis возвращает скрытую структуру – показывает, где именно модель работает плохо, чтобы это можно было чинить адресно.

По каким срезам смотрят в ИБ:

Тип объекта

класс атаки, протокол,
сервис

Источник

подсеть, страна, провайдер

Время

час суток, день недели,
период

Сегмент

устройство, версия ПО,
группа




Где концентрируются ошибки детектора: по типам атак, времени и подсетям

ИБ-КЕЙС · CIC-IDS-2018

Общий F1 детектора = 0.91 – «хорошо». Но slice по часу суток показывает: **ночью (00:00-06:00) F1 падает до 0.62**. Ночной трафик реже и однороднее, медленные атаки на этом фоне теряются. Один и тот же детектор фактически работает по-разному в зависимости от времени.

F1 по времени суток (slice)



Среднее 0.91 (пунктир мысленно) прячет ночной провал 0.62

ЧТО ЭТО ДАЁТ

Диагноз вместо общей цифры. Видно конкретную слабую подгруппу → можно действовать адресно: отдельный порог для ночного трафика, дозбор ночных атак, признаки временной структуры. То же делают по подсетям и типам атак.



Чувствительные группы и граница темы

Slice по чувствительным группам – часть надёжности, но не fairness-аудит

Если ошибки концентрируются на отдельной группе пользователей, географии или сегменте инфраструктуры – это сигнал скрытой проблемы качества данных или признаков. Поэтому **slice по чувствительным группам – законная часть проверки надёжности модели**: мы проверяем, что модель не деградирует систематически на ком-то конкретном.

✓ В рамках L09

Проверить, нет ли подгруппы, где модель систематически хуже.

Найти причину в данных/признаках и устранить как дефект надёжности.

✗ За рамками L09

Полноценный fairness-аудит: формальные метрики справедливости, правовые определения дискриминации, баланс групп как отдельная цель.

Это самостоятельная большая тема, не входит в курс.

Связь с курсом: что происходит со срезами, когда среда меняется во времени (concept drift), – в L17. Там slice analysis применяется уже под drift.



Мини-резюме slice analysis перед переходом к поиску leakage

1

Считай метрику по срезам

Качество по подгруппам (тип, источник, время, сегмент), а не только агрегированное число по всей выборке.

2

Средняя цифра обманчива

Хорошее общее значение прячет провальные подгруппы. Slice возвращает скрытую структуру ошибок.

3

Концентрация = сигнал

Если ошибки собраны на одной подгруппе – это указание на дефект данных или признаков, который чинится адресно.

4

Это надёжность, не fairness

Slice по чувствительным группам – часть проверки надёжности, а не полноценный fairness-аудит (вне курса). Под drift – в L17.

Дальше – Блок E: интерпретация как детектор leakage – самый важный признак иногда оказывается утечкой.



Е

Блок Е

Интерпретация как детектор leakage

Самая практичная отдача от интерпретации в ИБ. Все методы блоков А-В – коэффициенты, importance, SHAP – сходятся в одном вопросе: «почему этот признак такой важный?». Иногда ответ – потому что это утечка. Интерпретация ловит leakage и спурионные связи раньше, чем модель провалится в проде.

В этом блоке: подозрительно важный признак (типология leakage – в L05) · ИБ-кейс утечки в triage · спурионные связи через интерпретацию · важность не равна причинности



Подозрительно важный признак

Главный красный флаг интерпретации: один признак решает «слишком хорошо»

Утечку данных (data leakage, типология – в **L05**) часто видно именно через интерпретацию. Симптом: один признак имеет аномально высокую важность и почти в одиночку определяет ответ модели. Это повод не радоваться, а насторожиться и спросить, откуда этот признак берётся в реальности.

Три вопроса к подозрительно важному признаку:

1

Будет ли он в проде?

Признак есть на обучении, но в реальном потоке появляется позже или вообще отсутствует?

2

Не отражает ли он ответ?

Признак кодирует результат расследования / разметки, а не поведение объекта до решения?

3

Откуда корреляция?

Связь содержательная – или это артефакт сбора данных (спурионная корреляция из блока А)?



ИБ-кейс: признак-утечка в triage

Классическая утечка target, пойманная через feature importance

ИБ-КЕЙС

Модель приоритизации алертов (triage) показывала отличный recall. Permutation importance дал топ-1 признак `analyst_disposition` с важностью втрое выше остальных. Проверка: этот признак – **решение аналитика по итогу расследования**. В обучающих данных он есть (разбор уже завершён), а в момент live-триажа алерта его ещё *не существует*. Модель «предсказывала» ответ, который сама же использовала как вход.

Что казалось

«Recall 0.97 – модель отлично приоритизирует алерты, можно автоматизировать триаж».

Что было на самом деле

Утечка target. Без признака recall падает до 0.71 – реальное качество модели. Признак удалён, модель переобучена честно.



Спурионные связи через интерпретацию

Не всякая утечка – это target. Артефакты датасета тоже всплывают в важности

Утечка по target (как на прошлом слайде) – частый, но не единственный случай. Интерпретация подсвечивает и **спурионные корреляции** (определение – из блока А): признак важен из-за артефакта сбора данных, а не из-за связи с угрозой. Инструменты блока В показывают это с разных сторон.

Permutation importance

Признак с аномально высоким падением метрики, которому нет содержательного объяснения, – кандидат в утечку или артефакт.

SHAP

Локальные объяснения концентрируются на одном «странном» признаке во всех объектах одного источника – след артефакта сбора.

Partial dependence

Резкий скачок прогноза на нереалистичном пороге значения (например, ровно на границе ID-диапазона датасета) выдаёт артефакт.

Общий принцип: важность без содержательного объяснения – гипотеза об утечке, а не вывод о причинности.



Частая ошибка: важность = причинность

Последнее и главное предостережение блока интерпретации

ЧАСТАЯ ОШИБКА

«Признак самый важный → он причина / он надёжный сигнал». Высокая важность означает лишь, что модель сильно на него опирается. Будет ли эта связь причинной, осмысленной и устойчивой – интерпретация не говорит. Причинный анализ – вне курса.

ПОЧЕМУ ЭТО НЕВЕРНО

Важность отвечает на «на что опирается модель», а не на «что является причиной». Спuriонный признак и признак-утечка получают высокую важность так же охотно, как осмысленный. Поэтому вывод всегда один: важность – это гипотеза, которую нужно проверить (будет ли признак в проде, откуда корреляция, устойчив ли он), а не доказательство.

Связь с курсом: целенаправленно внедрённую закладку (backdoor) тоже можно обнаружить через локальные интерпретации – подробнее в L19.



4

Часть 4

Связки с практикой ИБ

Инструменты разобраны по отдельности. Теперь – как они живут вместе в реальном ИБ-пайплайне. Сначала соберём весь маршрут блоков А-Е в один цикл проверки на сквозном детекторе, затем покажем, что та же интерпретация работает не только на табличных признаках: на токенах текста и на областях изображения. И отдельно – ловушки, специфичные для ИБ-данных.

В этой части: сквозной цикл проверки на CIC-IDS-2018 · интерпретация текста (токены, → L15) · интерпретация изображений (Grad-CAM, → L14) · ловушки ИБ-данных



Сквозной цикл: разбор детектора

47 / 57

ЧАСТЬ 4 · СВЯЗКИ С ИБ

Все блоки А-Е как единый цикл проверки модели на CIC-IDS-2018

Так выглядит реальная проверка обученного сетевого детектора – от метрики до решения, что чинить.



Цикл замыкается: после доработки модель снова проходит те же шаги.



Интерпретация текста: фишинг

Та же идея вкладов – но признаки это токены письма

Интерпретация не привязана к табличным признакам. Для классификатора фишинговых писем «признаки» – это **токены** (слова и подстроки). Локальное объяснение (SHAP/LIME) показывает, какие токены толкнули письмо к классу «фишинг», а какие – к «легитимное». Это позволяет проверить, ловит ли модель смысл или артефакт.

СВЯЗЬ С КУРСОМ

Полноценный разбор текстов – от TF-IDF к эмбедингам – в **L15**. Здесь важно одно: метод интерпретации тот же, меняется лишь природа признака. Подозрительно важный токен – такой же сигнал утечки, как подозрительно важный столбец.

Вклад токенов (пример)

Уважаемый клиент , ваш
счёт **заблокирован** .
Срочно **подтвердите** данные
по **ссылке** : **http://**
bit.ly/x9 ...

красным – токены, тянущие к «фишинг»




Куда «смотрит» модель – визуальная проверка через тепловые карты

Для моделей на изображениях локальная интерпретация отвечает на вопрос «на какие **области** картинки опирается модель». Тепловая карта (Grad-CAM) подсвечивает пиксели, сильнее всего повлиявшие на решение. Это та же проверка адекватности: смотрит ли модель на объект – или на фон, водяной знак, артефакт съёмки.


СВЯЗЬ С КУРСОМ

Grad-CAM и переносимость качества на новые данные – в [L14](#). Принцип неизменен: если модель «смотрит» не туда, высокая метрика обманчива – классический симптом спурионной зависимости.

Куда смотрит модель



✓ на объекте
(адекватно)



✗ на фоне
(артефакт)



Ловушки ИБ-данных в интерпретации

50 / 57

ЧАСТЬ 4 · СВЯЗКИ С ИБ

Что специфично для безопасности и чаще всего сбивает с толку

ЧАСТАЯ ОШИБКА

«Интерпретация показала важные признаки – значит, модель адекватна». В ИБ данные особенно богаты артефактами: разметка по итогу расследования, способ сбора, нестабильность во времени. Важный признак часто отражает их, а не угрозу.

Разметка постфактум

Метки ставятся по итогу расследования. Признаки, коррелирующие с этим итогом, – утечка target (как triage-кейс).

Способ сбора данных

Honeypot, конкретный сенсор или диапазон IP оставляют отпечаток. Модель учит сенсор, а не атаку.

Нестабильность во времени

Сигнатуры, порты, поведение атак меняются. Важный сегодня признак может исчезнуть завтра (drift – L17).

Вывод части: интерпретация в ИБ – это всегда проверка «откуда признак», а не любование графиком.



Семь ключевых утверждений

- 1 Высокая метрика не доказывает, что модель решает задачу правильно – она лишь говорит, что модель часто угадывает.
- 2 Глобальная интерпретация описывает модель в целом, локальная – отдельное предсказание. Это разные вопросы и разные инструменты.
- 3 Permutation importance надёжнее встроенной impurity; SHAP и LIME объясняют один объект, PDP – средний эффект признака.
- 4 Важность $\neq$ причинность. Любое объяснение – это гипотеза, которую нужно проверить, а не доказательство.
- 5 False positives и false negatives разбираются отдельно: у них разные цена, причины и лечение.
- 6 Средняя метрика прячет провалы на подгруппах – slice analysis возвращает скрытую структуру ошибок.
- 7 Интерпретация – главный детектор leakage: подозрительно важный признак часто оказывается утечкой или артефактом.



Интерпретация – рабочий инструмент проверки, а не украшение

Применять

- Проверять адекватность решения и искать leakage.
- Разбирать ошибки по типам и подгруппам.
- Объяснять аналитику основание конкретного решения.
- Формулировать, что чинить: данные, признаки, порог, модель.

Не делать

- Читать важность как доказательство причинности.
- Переносить локальное объяснение на всю модель.
- Показывать SHAP-график без вывода о доработке.
- Подменять slice-проверку полноценным fairness-аудитом.

Границы темы L09: не входят математический вывод SHAP, counterfactual explanations, причинный анализ, полный fairness-аудит и глубокая интерпретируемость LLM (прикладные аспекты – в L16).



Связь с другими темами курса

53 / 57

ЧАСТЬ 5 · ИТОГИ

Куда ведут нити этой лекции – для самостоятельной навигации

L05	Утечки и валидация	Типология leakage введена там; здесь – её обнаружение через интерпретацию.	◀ назад
L06 · L08	Линейные модели · ансамбли	Коэффициенты и impurity importance – отправные инструменты этой лекции.	◀ назад
L12	Логи и время	Признаки временной структуры лечат пропуски медленных атак (FN-разбор).	▶ вперёд
L14	Изображения	Grad-CAM – та же локальная интерпретация для областей картинки.	▶ вперёд
L15	Тексты и эмбединги	Важные токены – интерпретация для текстовых признаков.	▶ вперёд
L17	Устойчивость к drift	Slice analysis под сдвигом данных: как срезы меняются во времени.	▶ вперёд
L19	Poisoning и backdoor	Закладку можно обнаружить через локальные интерпретации.	▶ вперёд



Базовая литература по интерпретации и важности признаков

Hastie, Tibshirani, Friedman

The Elements of Statistical Learning

Гл. 10.13 – variable importance в бустинге; гл. 15.3 – importance в random forests.

Christoph Molnar

Interpretable Machine Learning

Гл. permutation importance, SHAP, LIME, partial dependence – прикладной разбор каждого метода.

Bishop

Pattern Recognition and ML

Гл. 14 – combining models: контекст ансамблей, важности которых мы интерпретируем.



Для углубления и для рук

ДОПОЛНИТЕЛЬНО

Lundberg & Lee (2017)

оригинальная статья SHAP — для тех, кто хочет идею аддитивных вкладов глубже.

Ribeiro et al. (2016)

«Why Should I Trust You?» — оригинальная статья LIME.

ПРАКТИКА

`sklearn.inspection`

`permutation_importance`, `partial_dependence`, `PartialDependenceDisplay` — готовые инструменты.

`shap` / `lime`

официальные библиотеки с примерами на табличных данных и тексте.

Датасет для практики: CIC-IDS-2018 — обучите дерево/бустинг, посчитайте permutation importance и разберите FP/FN по типам атак.



Ключевые термины

Глобальная интерпретация

как модель устроена в целом

Локальная интерпретация

почему конкретный объект получил ответ

Feature importance

числовая оценка роли признака

Impurity importance

встроенная важность деревьев (L08)

Permutation importance

падение метрики при перемешивании признака

SHAP

аддитивные согласованные вклады признаков

LIME

локальная линейная аппроксимация модели

Partial dependence

средний эффект признака на прогноз

Error analysis

систематический разбор ошибок модели

False positive / negative

ложное срабатывание / пропуск

Slice analysis

оценка качества по подгруппам

Спурионная корреляция

связь из артефакта, не из сути

Data leakage

утечка недоступной в проде информации (L05)

Confidence

уверенность модели в предсказании



Памятка: интерпретация на практике

57 / 57

ЧАСТЬ 7 · ПАМЯТКА

Короткий чек-лист, который стоит держать рядом при разборе модели

✓ **Считай не одну метрику**

После итогового числа всегда разбирай ошибки: FP и FN отдельно, по типам и подгруппам.

✓ **Спрашивай «почему важен»**

Для топ-признаков проверяй: будет ли в проде, не отражает ли ответ, откуда корреляция.

✓ **Считай по срезам**

Время, источник, тип объекта, чувствительные группы – ищи концентрацию ошибок.

✓ **Приоритизируй уверенные ошибки**

Ошибки с высоким confidence разбирай первыми – частый маркер утечки.

✓ **Делай вывод о действии**

Каждое объяснение должно заканчиваться решением: что менять – данные, признаки, порог, модель.