



МАШИННОЕ ОБУЧЕНИЕ И БЕЗОПАСНОСТЬ СИСТЕМ

Лекция 14

Нейросетевые модели для изображений и переносимость качества на новые данные

Магистратура НИУ ВШЭ (МИЭМ) · ОП «Информационная безопасность и технологии ИИ»

Автор: Силаев Ю. В. *Время чтения ≈ 70 минут*



Главное по лекции

Изображения – отдельная модальность данных: это не таблица признаков, а массив пикселей, где важны локальные узоры и их положение. Свёрточные сети (CNN) умеют извлекать такие локальные признаки и строить из них иерархию – от краёв к объектам. Но центральная идея лекции не в устройстве сети. Главное: высокое качество модели на «своём» датасете не переносится автоматически на новые камеры, условия съёмки и источники данных. В задачах информационной безопасности к этому добавляется активный противник, который может сознательно влиять на вход модели.



Изображение = пиксели

Массив $H \times W \times C$, а не строка таблицы. Нужны представления, учитывающие локальность.



CNN = локальные признаки

Свёртка и pooling строят иерархию: края → текстуры → объекты. База – из L13.



Перенос не гарантирован

Качество на «своём» датасете $\neq$ работа на новых камерах и условиях (domain shift).



В ИБ есть противник

Атакующий контролирует вход и условия съёмки. Clean-test $\neq$ безопасность модели.



Учебные результаты лекции

- ✓ Вы научитесь **читать изображение как источник признаков** — и понимать, почему обычный MLP плохо масштабируется на пиксели
- ✓ Вы научитесь **объяснять идею convolution, pooling и feature maps** — как механизма извлечения локальных визуальных признаков
- ✓ Вы научитесь **осознанно применять transfer learning и augmentation** — выбирать frozen backbone vs fine-tuning; подбирать допустимые преобразования
- ✓ Вы научитесь **диагностировать domain shift и dataset bias** — видеть, когда модель выучила фон, источник или артефакт вместо цели
- ✓ Вы научитесь **проводить базовый error analysis изображений** — через confusion matrix и визуальный разбор ошибок (идея Grad-CAM)
- ✓ Вы научитесь **различать ИБ-специфику CV-задач** — steganalysis, anti-spoofing, document/screenshot forensics, артефакты фишинга



Что нужно знать до начала

4 / 56

ЧАСТЬ 1 · ВВЕДЕНИЕ

Лекция опирается на ранее пройденный материал

Базовая структура сети, обучение и диагностика переобучения только что разобраны в L13 – здесь мы строим CNN поверх этого. Понятия валидации, утечки данных и анализа ошибок тоже уже знакомы.

L13

Основы нейросетей

Нейрон, слой, обучение, переобучение и его диагностика. CNN – частный случай этой общей структуры.

L09

Интерпретируемость и анализ ошибок

Идея error analysis и интерпретации модели. В L14 – её визуальное продолжение (Grad-CAM).

L05

Валидация и утечки данных

Типология data leakage и схемы split. Для изображений добавится split по источникам и группам.

L10

Воспроизводимые конвейеры

Pipeline как защита от утечки на этапе предобработки – пригодится при работе с аугментацией.



Семь частей, 56 слайдов, ≈ 70 минут

		слайды	время
1	Введение	1-5	6 мин
2	Мотивация: зачем CV в ИБ	6-9	5 мин
3	Основное содержание	10-41	40 мин
4	Связки с практикой ИБ	42-49	10 мин
5	Итоги	50-52	4 мин
6	Источники для углубления	53-54	3 мин
7	Глоссарий	55-56	2 мин

ЧАСТЬ 3 – ПОДРОБНО

3.1 · Изображение и почему MLP не годится

3.2 · Convolution, pooling, CNN

3.3 · Transfer learning и augmentation

3.4 · Переносимость и domain shift

3.5 · Error analysis и Grad-CAM

Время – оценка для самостоятельного чтения ($\approx 1-1.5$ мин/слайд).



Зачем инженеру ИБ нейросети для изображений

6 / 56

ЧАСТЬ 2 · МОТИВАЦИЯ

Мотивация – реальные задачи, в которых изображение становится объектом защиты

Компьютерное зрение в информационной безопасности – это не «обзор картинок» и не распознавание котиков. Это отдельный класс задач, где изображение само является носителем угрозы или доказательством: подделанный документ, лицо-самозванец перед камерой, скрытый канал внутри безобидной фотографии. У таких задач своя модель угроз и свои ловушки качества. Прежде чем разбирать, как устроены CNN, посмотрим, где именно они нужны в ИБ и что ломается, если применять их наивно.



Anti-spoofing

*живое лицо или
атака на камеру?*



Steganalysis

*есть ли скрытый
канал в картинке?*



Document forensics

*подделан ли
документ / скриншот?*



Артефакты фишинга

*подменён ли
интерфейс / форма?*



Смена источника

*переносится ли
качество на прод?*



Пять типовых сценариев – и почему обычный CV-пайплайн к ним не сводится

1

Подделка документов и скриншотов

Паспорта, справки, банковские скриншоты подделывают пиксельно. Модель ищет артефакты ресэмплинга, рассогласование шрифтов, следы JPEG-перекодирования – а не «красиво ли выглядит».

2

Стеганография (скрытый канал)

Внутри обычной фотографии спрятаны данные. Сигнал – это едва заметные статистические отклонения младших бит, а не видимый объект. Целевой признак нельзя «увидеть глазами».

3

Биометрический спуфинг

Перед камерой распознавания лица – фото, видео с экрана или маска. Цена пропуска атаки несимметрична: пустить злоумышленника хуже, чем переспросить настоящего пользователя.

4

Визуальные артефакты фишинга

Поддельная страница банка визуально копирует оригинал. Признаки – мелкие расхождения в рендеринге, шрифтах, иконках, которые человек пролистывает не глядя.

5

САРТСНА в исследовательском контексте

Классификация САРТСНА-подобных изображений изучается как модельная задача распознавания в шуме – без обхода реальных защит.



Первый разбор реального примера

ИБ-КЕЙС

Биометрия на проходной

Задача: по кадру с камеры различить живое лицо и презентационную атаку (фото, видео с экрана, маска).

Данные: обучающая выборка снята на корпоративные камеры одного типа в одном холле.

Результат на тесте: ассигасу 99.1%. Модель уходит в прод.

В проде: новый филиал ставит камеры другой модели. Атаки с экрана нового смартфона проходят. Реальный FAR кратно выше тестового.

Что выучила модель на самом деле?

Не «живость» лица, а **характеристики конкретной камеры**: шум матрицы, баланс белого, типичную засветку холла. На новом источнике эти опоры исчезли – и качество рухнуло.

ГЛАВНЫЙ ТЕЗИС ЛЕКЦИИ

Высокое качество на «своём» датасете не доказывает работу на новых условиях. Переносимость нужно проверять отдельно, а не предполагать по умолчанию.



Типовое заблуждение инженера – и его конкретные последствия в ИБ

⚠ ЧАСТАЯ ОШИБКА

«Accuracy на тесте высокая – значит, модель готова к продю»

Инженер берёт один датасет, делает случайный train/test split, получает 98-99% и считает задачу решённой. Переносимость на другие камеры, источники и условия съёмки не проверяется – её молча считают данной по умолчанию.

ПОЧЕМУ ЭТО НЕВЕРНО

Тестовая выборка из того же источника наследует те же фон, камеру и условия, что и обучение. Модель отлично работает на этом источнике – и нигде больше. Последствия в ИБ конкретны:

Anti-spoofing: пропуск презентационной атаки на новой камере – злоумышленник входит в систему.

Steganalysis: модель выучила шум «чистого» источника, а не скрытый канал – стего-трафик проходит незамеченным.

Document forensics: модель опознаёт шаблон бланка, а не подделку – фальшивка с другого шаблона проходит проверку.

Инструмент, которого не хватает, – **дисциплина проверки переносимости**. Её мы и строим в этой лекции.



Часть 3 – разбираем тему по смысловым блокам



Как машина «видит» изображение

Почему изображение – не строка таблицы, и почему обычная полносвязная сеть для него не годится. Это фундамент, на котором дальше вырастут свёртки.



Прежде чем учить модель, нужно понять, в каком виде данные вообще попадают в неё

Для модели изображение – не «картинка», а трёхмерный массив чисел размера $H \times W \times C$: высота, ширина и число каналов. Каждый пиксель – это C значений интенсивности (для цветного RGB – три: красный, зелёный, синий), обычно целые от 0 до 255 или нормированные в диапазон $[0, 1]$. Картинка 224×224 пикселя в цвете – это уже $224 \cdot 224 \cdot 3 \approx 150$ тысяч чисел на один объект.

ОПРЕДЕЛЕНИЕ

Тензор изображения

$H \times W \times C$

H – высота в пикселях, W – ширина, C – число каналов (1 для ч/б, 3 для RGB). Значение в позиции (i, j, k) – интенсивность k -го канала в пикселе (i, j) .

Что из этого следует

Соседние пиксели не независимы – вместе они образуют края, текстуры, формы. Порядок и взаимное расположение значений несут смысл.

Один и тот же объект может оказаться в любом месте кадра – модель должна узнавать его независимо от положения.

Размерность огромна – даже маленькая картинка даёт десятки тысяч входных чисел.



Полносвязная сеть из L13 формально применима к пикселям – но цена катастрофична

В полносвязной сети (MLP, разобранный в L13) каждый нейрон первого слоя соединён с каждым входным числом. Если вход – развёрнутая в вектор картинка $224 \times 224 \times 3$, то на один нейрон приходится 150 528 весов. Для скромного слоя в 1000 нейронов это уже более 150 миллионов параметров – только на первом слое.

ФОРМУЛА

$$\text{params} = (H \cdot W \cdot C) \cdot n_{\text{neurons}} = 150\,528 \cdot 1000 \approx 1.5 \cdot 10^8$$

Полтора миллиона весов на одном слое – для картинки, которая по меркам компьютерного зрения совсем небольшая.

Переобучение

Столько параметров запоминают обучающую выборку целиком вместо обобщения.

Игнор структуры

Развёртка в вектор разрывает соседство пикселей – теряется локальность.

Нет инвариантности

Сдвиг объекта на 1 пиксель – и для MLP это совсем другой вход.



Две идеи, которые спасают: локальность и общие веса

13 / 56

ЧАСТЬ 3 · БЛОК 3.1

Свойства изображений, которые нужно встроить прямо в архитектуру модели

Вместо того чтобы соединять каждый нейрон со всем изображением, разумно использовать два наблюдения о природе картинок. Они и лягут в основу свёрточных сетей в следующем блоке.

ИДЕЯ 1

Локальная связность

Чтобы распознать край или угол, нейрону достаточно смотреть на маленькое окно соседних пикселей, а не на всю картинку.

Это резко сокращает число связей: окно 3×3 вместо 150 тысяч входов – всего 27 весов на канал.

ИДЕЯ 2

Общие веса (sharing)

Один и тот же небольшой фильтр применяется ко всем позициям изображения. Если он научился находить край – найдёт его где угодно в кадре.

Так возникает инвариантность к сдвигу: объект узнаётся независимо от того, где он расположен.



Соблазнительный путь, который ломает задачу ещё до начала обучения

⚠ ЧАСТАЯ ОШИБКА

«Картинка – просто числа. Развернём в вектор и подадим в обычную сеть»

Изображение $H \times W \times C$ действительно можно вытянуть в один длинный вектор и подать в полносвязную сеть. Формально всё работает: код запустится, модель обучится, на простом датасете даже покажет приемлемую точность.

ПОЧЕМУ ЭТО НЕВЕРНО

Но развёртка уничтожает пространственную структуру: пиксель сверху-слева и его сосед справа после flatten – просто два из 150 тысяч независимых чисел. Модель не знает, что они рядом.

Последствия: огромное число параметров → переобучение; нет инвариантности к сдвигу → смещённый объект не узнаётся; потеря локальности → края и текстуры приходится «переоткрывать» для каждой позиции. На реальных изображениях такая сеть проигрывает свёрточной с тысячекратно меньшим числом параметров.

*Правильный ответ – встроить локальность и общие веса в саму архитектуру. Это и есть **свёртка** (блок 3.2).*



Часть 3 – разбираем тему по смысловым блокам



Свёртка, pooling и CNN

Как именно сеть извлекает локальные признаки и собирает из них иерархию – от краёв до объектов. На уровне интуиции, без вывода математики.



Главная операция CNN – на уровне интуиции скользящего окна


ОПРЕДЕЛЕНИЕ

Свёртка (convolution)

Небольшое окно весов – **фильтр (ядро)** – скользит по изображению. В каждой позиции считается взвешенная сумма пикселей под окном: одно число – отклик фильтра на этот участок.

Один и тот же фильтр применяется во всех позициях (общие веса). Если он настроен на вертикальный край – отметит все вертикальные края в кадре.

Как это выглядит



Окно сдвигается на один шаг (stride) – и операция повторяется по всему изображению.




Карты признаков (feature maps)

17 / 56

ЧАСТЬ 3 · БЛОК 3.2

Что получается, когда мы прогоняем по картинке не один фильтр, а много

Один фильтр, пройдя по всему изображению, даёт одну карту признаков (feature map) – «тепловую карту» того, где встретился его паттерн. В свёрточном слое таких фильтров много: каждый ищет свой паттерн (горизонтальные края, диагонали, пятна цвета), и каждый порождает свою карту. На выходе слоя – стопка карт признаков.




Стопка карт признаков – это новое представление изображения: **не пиксели, а «где какой паттерн найден»**. Следующий слой свёртки работает уже над этими картами.



Почему глубокие сети «понимают» изображение лучше неглубоких

Когда свёрточные слои идут друг за другом, признаки складываются в иерархию. Ранние слои видят только маленькие участки и улавливают простейшее – края и градиенты. Каждый следующий слой комбинирует выходы предыдущего и потому «видит» больший участок изображения и более сложные структуры. Это и есть главная причина, почему CNN работают.



Рецептивное поле – участок исходного изображения, который влияет на один нейрон. С глубиной оно растёт.



Pooling: сжатие и устойчивость

19 / 56

ЧАСТЬ 3 · БЛОК 3.2

Вторая базовая операция CNN – уменьшает размер и добавляет локальную стабильность

ОПРЕДЕЛЕНИЕ

Pooling (субдискретизация)

Карта признаков делится на небольшие окна (обычно 2×2), и каждое окно заменяется одним числом. **Max pooling** берёт максимум, **average pooling** – среднее. **Зачем:** уменьшить размер представления (меньше вычислений) и добавить устойчивость к малым сдвигам – если паттерн чуть сместился внутри окна, максимум почти не изменится.

Max pooling 2×2

1	3	2	4
5	6	1	2
7	2	8	3
1	0	4	9




6	4
7	9

$4 \times 4 \rightarrow 2 \times 2$: каждое окно $\rightarrow$ его максимум.



Как свёртки и pooling собираются в полную сеть – и где звучит дисциплина baseline

Типичная свёрточная сеть чередует свёрточные слои и pooling: признаки становятся всё абстрактнее, а карты – всё меньше. В конце представление разворачивается в вектор и подаётся в полносвязные слои с softmax, который выдаёт вероятности классов.



Признаки: края → текстуры → части → классы. Размер карт падает, число каналов растёт.

ДИСЦИПЛИНА BASELINE

CNN – мощный инструмент, но не выбор по умолчанию. Как и в табличных задачах (L08, L13), сложную модель сравнивают с простым baseline: классическими признаками изображения + линейной моделью или бустингом. Если глубокая сеть не обыгрывает baseline заметно – её сложность и риск переобучения не оправданы. Это та же baseline-дисциплина курса, просто в визуальной модальности.



Блок 3.2 в пяти пунктах – перед переходом к transfer learning

- Свёртка – это маленький фильтр с общими весами, скользящий по изображению; он находит свой локальный паттерн в любой позиции кадра.
- Много фильтров дают стопку карт признаков – новое представление «где какой паттерн найден» вместо сырых пикселей.
- Слои, идущие друг за другом, строят иерархию: края → текстуры → части → объекты. С глубиной растёт рецептивное поле.
- Pooling уменьшает размер представления и добавляет устойчивость к малым сдвигам.
- CNN = чередование Conv + Pool, затем полносвязный слой с softmax. И даже мощную CNN сравнивают с baseline.



Часть 3 – разбираем тему по смысловым блокам



Transfer learning и augmentation

Когда размеченных изображений мало – а в ИБ их почти всегда мало. Две техники, которые помогают, и две ловушки, которые они приносят.



Зачем учить с нуля, если кто-то уже научил сеть видеть края и текстуры

Обучить большую CNN с нуля требует миллионов размеченных изображений и серьёзных вычислений. В реальных ИБ-задачах столько данных почти никогда нет. Transfer learning решает это: берём сеть, уже обученную на огромном корпусе (например, ImageNet), и переиспользуем выученные ею признаки для своей задачи.

ОПРЕДЕЛЕНИЕ

Transfer learning

Backbone – предобученная свёрточная часть сети. Её ранние слои уже умеют находить края, текстуры, формы – это универсально для любых изображений. К backbone приставляют новую «голову» под свою задачу и дообучают на небольшом своём датасете.

Что именно переносится

Низкоуровневые признаки (края, градиенты) – почти всегда полезны и переносятся хорошо.

Высокоуровневые признаки (части объектов ImageNet) – переносятся хуже, если ваш домен далёк от исходного. Лицо или документ – не кошка.

Чем дальше ваш домен от исходного, тем меньше можно полагаться на готовые признаки.



Два режима transfer learning – выбор зависит от объёма данных и близости доменов

Backbone можно либо заморозить (использовать как готовый экстрактор признаков), либо разморозить и дообучить под свою задачу. Выбор – это компромисс между риском переобучения и адаптацией к вашему домену.

РЕЖИМ 1

Frozen backbone

Весы backbone фиксируются, обучается только новая голова.

- + мало параметров → почти не переобучается; быстро.
- не адаптируется к домену.

Когда: данных очень мало, домен близок к исходному.

РЕЖИМ 2

Fine-tuning

Backbone (целиком или верхние слои) дообучается с малым learning rate.

- + адаптируется к вашему домену → выше потолок качества.
- больше параметров → риск переобучения на малых данных.

Когда: данных достаточно или домен далёк от исходного.



Удобство transfer learning приносит специфический для ИБ риск цепочки поставок

ИБ-КЕЙС

Доверие к чужим весам

Скачивая предобученный backbone из публичного хаба, вы доверяете чужому артефакту: вы не контролировали ни обучающие данные, ни процесс обучения, ни целостность файла весов. **В обычном CV это считается мелочью – в ИБ это часть поверхности атаки.** Скомпрометированный backbone может нести скрытый backdoor: вести себя нормально на обычных входах и срабатывать на триггер злоумышленника.

Что снижает риск

Источник с репутацией и контрольными суммами;
фиксация версии весов;
проверка поведения на триггерах;
переобучение головы вместо слепого доверия.

СВЯЗЬ С КУРСОМ

Это частный случай **supply-chain рисков ML**. Полностью – poisoning, backdoor и атаки на артефакты обучения – разбираются в **L19**.



Искусственно увеличиваем данные, чтобы модель стала устойчивее

Augmentation – это применение к обучающим изображениям случайных, но реалистичных преобразований. Из одного снимка получается много вариантов, и модель учится узнавать объект независимо от мелких изменений, а не запоминать конкретные пиксели.

ОПРЕДЕЛЕНИЕ

Augmentation

Типовые преобразования: повороты, отражения (flip), случайная обрезка (crop), изменение яркости и контраста, размытие (blur), добавление шума.

Эффект: больше эффективных данных и устойчивость к вариациям съёмки – без сбора новых снимков.

Один снимок → много примеров



оригинал



поворот



flip



crop



ярче



+ шум



Преобразование, безобидное для кошек, может уничтожить сигнал ИБ-задачи

⚠ ЧАСТАЯ ОШИБКА

«Augmentation всегда помогает – добавим побольше и поагрессивнее»

Инженер берёт стандартный набор аугментаций из tutorials (сильное размытие, JPEG-сжатие, шумоподавление) и применяет ко всем задачам подряд. Для распознавания обычных объектов это действительно почти всегда полезно.

ПОЧЕМУ ЭТО НЕВЕРНО

Но в ИБ целевой сигнал бывает хрупким. В **steganalysis** скрытый канал прячется именно в младших битах и тонком шуме изображения. Агрессивное сглаживание, blur или повторное JPEG-сжатие **физически уничтожают этот сигнал** – модель учится на данных, где целевого признака уже нет.

Правило: augmentation должен сохранять целевой признак. Допустимость каждого преобразования определяется задачей, а не tutorialом. Для steganalysis безопасны геометрические сдвиги, но не операции, меняющие пиксельную статистику.



Мини-резюме блока 3.3

28 / 56

ЧАСТЬ 3 · БЛОК 3.3

Перенос и расширение в пяти пунктах – перед главным блоком о переносимости

- Transfer learning переиспользует предобученный backbone – спасение, когда размеченных изображений мало (а в ИБ их почти всегда мало).
- Frozen backbone – для очень малых данных и близкого домена; fine-tuning – когда данных больше или домен далёк от исходного.
- Предобученный backbone – это supply-chain риск: чужие веса могут нести backdoor. Полностью тема – в L19.
- Augmentation увеличивает эффективный объём данных и устойчивость к вариациям съёмки.
- Augmentation должен соответствовать задаче: в steganalysis агрессивное сглаживание уничтожает скрытый сигнал.



Часть 3 – разбираем тему по смысловым блокам



Главное: качество не переносится само

Содержательное ядро лекции. Почему высокая точность на «своём» датасете ничего не говорит о работе на новых условиях – и как это проверять.



Распределение входных данных в эксплуатации отличается от обучающего

Модель обучается на изображениях, снятых в одних условиях, а работает на изображениях из других. Даже если задача та же, распределение пикселей сместилось – и выученные моделью опоры могут перестать работать. Для изображений источников такого сдвига особенно много.

ОПРЕДЕЛЕНИЕ

Domain shift

Систематическое расхождение между распределением обучающих данных и данных эксплуатации. **Качество, измеренное на «своём» домене, не переносится на новый домен автоматически.**

Источники сдвига для CV

камера / сенсор

освещение

фон сцены

ракурс / угол

разрешение

сжатие / формат

география

устройство

*Сдвиг, который возникает сам собой (среда меняется без злого умысла), – это **non-adversarial drift**; подробно – в L17.*



Split по источникам и группам, а не по отдельным кадрам – иначе оценка лжёт

Чтобы оценка качества предсказывала работу на новых данных, тест должен моделировать новый домен. Это значит делить выборку не по случайным кадрам, а по источникам: камерам, людям, сессиям съёмки, документам. Все кадры одного источника должны попасть целиком либо в train, либо в test – но не в оба сразу.

✗ СЛУЧАЙНЫЙ SPLIT ПО КАДРАМ

Кадры одной камеры/сессии попадают и в train, и в test.
Тест неотличим от обучения → завышенная, обманчивая оценка. Модель не проверена на новом домене вовсе.

✓ ГРУППОВОЙ SPLIT ПО ИСТОЧНИКАМ

Источник целиком в одной части. **Тест содержит камеры/людей, которых модель не видела** → оценка отражает реальную переносимость. Это идея group split из L05.



Ошибка: почти одинаковые кадры

32 / 56

ЧАСТЬ 3 · БЛОК 3.4

Самая частая и самая незаметная утечка в задачах с изображениями

⚠ ЧАСТАЯ ОШИБКА

«Я же случайно перемешал и поделил – всё честно»

Видео разбито на кадры, или сделана серия снимков одного объекта. Случайное перемешивание раскидывает почти идентичные кадры между train и test. Формально split случайный – кажется, что всё корректно.

ПОЧЕМУ ЭТО НЕВЕРНО

Соседние кадры почти не отличаются. Модель фактически тестируется на тех же изображениях, что видела при обучении, – это **утечка данных (как в L05)**. Метрика взлетает до 99%, а на по-настоящему новых данных модель проваливается.

Как избежать: дедупликация близких кадров; split по сессии/видео/объекту, а не по кадру; проверка, что одинаковые или почти одинаковые изображения не оказались по разные стороны разбиения.



Модель честно оптимизирует метрику – но цепляется не за то, за что нужно

Если в обучающих данных целевой класс случайно коррелирует с посторонней деталью, модель с радостью выучит именно эту деталь – она проще. Так возникают spurious correlations: предсказание опирается на признак, который в реальности с задачей не связан.

ОПРЕДЕЛЕНИЕ

Spurious correlation

Ложная связь между посторонним признаком и меткой, присутствующая в обучающих данных, но не в реальности. **Модель выучивает фон, источник или артефакт вместо целевого объекта.**

На что модель цепляется

- **Фон** – снимки класса А сняты в одном помещении
- **Водяной знак** – источник данных метит свои изображения
- **Шум камеры** – классы сняты разными устройствами
- **Формат / сжатие** – один класс хранится в другом формате



Классическая ловушка steganalysis – на данных BOSSbase

ИБ-КЕЙС

Steganalysis на BOSSbase

Задача: отличить «чистые» изображения от содержащих скрытый канал (стеганографию).

Данные: чистые кадры собрали с одной камеры, стего-кадры сгенерировали из снимков другой.

Результат: точность на тесте превосходная. Кажется, модель отлично детектирует стеганографию.

На деле: модель выучила сенсорный шум камеры-источника, а не сам скрытый канал. На стего из «чистой» камеры – не работает.

BOSSbase: что это

Эталонный публичный датасет для steganalysis: ~10 000 изображений в оттенках серого для проверки стего-алгоритмов.

Почему это типично

Скрытый сигнал стеганографии слабее, чем шум сенсора. Модели **проще выучить источник**, чем сам стего-канал. Лечится тем, что чистые и стего-кадры берут из **одного источника**.



Почему здесь нет CIC-IDS-2018

35 / 56

ЧАСТЬ 3 · БЛОК 3.4

Сквозной датасет курса в этой лекции неприменим – и это само по себе урок

В большинстве лекций курса примеры строятся на сквозном датасете CIC-IDS-2018. В L14 его нет.

CIC-IDS-2018 – табличный

Это ~16 млн flow-записей сетевого трафика с 80 числовыми признаками. У него нет пиксельной модальности – к нему неприменимы свёртки, domain shift по камерам, steganalysis. Визуальной задачи в нём попросту нет.

Урок про модальности

Тип данных диктует инструмент. Для CV берут специализированные датасеты: CelebA-Spoof (anti-spoofing), BOSSbase (steganalysis). Перенос инструментов между модальностями без оглядки на природу данных – сам по себе ошибка.

*Та же дисциплина переносимости применима и к выбору датасета: **данные должны соответствовать задаче и реальным условиям.***



Ядро лекции в пяти пунктах – то, что нужно унести в первую очередь

- Domain shift неизбежен: камера, освещение, фон, ракурс, разрешение, география – распределение входа меняется при переходе в прод.
- Делите данные по источникам и группам, а не по кадрам. Случайный split на изображениях из одной серии – это утечка (как в L05).
- Dataset bias: модель цепляется за фон, водяной знак, шум камеры. Высокая метрика может означать, что выучена не та опора.
- Переносимость нужно проверять отдельно, а не предполагать по умолчанию. Тест должен моделировать новый домен.
- Тип данных диктует инструмент: CIC-IDS-2018 (табличный) для CV неприменим – берут CelebA-Spoof, BOSSbase.



Часть 3 – разбираем тему по смысловым блокам



Диагностика: смотрим на ошибки

Метрика – это число. Чтобы понять, почему модель ошибается и на что она смотрит, нужно увидеть её ошибки глазами. Это визуальное продолжение анализа из L09.



Не верьте одной метрике

38 / 56

ЧАСТЬ 3 · БЛОК 3.5

Confusion matrix показывает структуру ошибок, а ваши глаза – их причину

Одно число (accuracy) скрывает, какие именно классы путаются и почему. Матрица ошибок раскладывает предсказания по парам «истинный класс × предсказанный» и сразу показывает, где модель слаба. Но матрица говорит только «что» – чтобы понять «почему», нужно открыть сами ошибочные изображения.

Матрица ошибок (anti-spoofing)

предсказано:		live	attack
истина ↓	live	847 <i>верно: live</i>	23 <i>FP</i>
	attack	31 <i>пропуск атаки!</i>	612 <i>верно: attack</i>

Что искать в ошибках

Асимметрию: 31 пропуск атаки опаснее 23 ложных тревог – в ИБ цена ошибок несимметрична (линия L04 → L07).

Систематику: если путаются конкретные условия (тёмные кадры, один тип экрана) – это след domain shift или bias.

Сами кадры: открыть ошибочные изображения и спросить – что в них общего?



Визуальная интерпретация – на уровне идеи, как продолжение L09


Confusion matrix говорит, где модель ошибается. Grad-CAM отвечает на следующий вопрос: на какую часть изображения сеть опиралась, принимая решение. Метод строит тепловую карту важности поверх исходного кадра – её можно посмотреть глазами.

ОПРЕДЕЛЕНИЕ


Grad-CAM (идея)

Тепловая карта, показывающая, какие области изображения сильнее всего повлияли на предсказание класса. **«Горячие» зоны – то, на что сеть смотрела.** Если они не совпадают с целевым объектом – модель опирается не на то.

Как читать тепловую карту



✓ фокус на лице



✗ фокус на углу/фоне

Общая идея интерпретации моделей вводится в L09; Grad-CAM – её вариант для изображений.



Тепловая карта вскрывает то, что метрика прятала – замыкаем блок про bias

ИБ-КЕЙС

Документ: подлинный или поддельный?

Классификатор подлинности документов показывает 97% на тесте. Перед выкаткой в прод инженер строит Grad-CAM на ошибочных и правильных примерах. **Тепловые карты «горят» в углу бланка – там, где стоит логотип источника, а не на полях с подделанными данными.** Модель научилась узнавать шаблон бланка, а не выявлять подделку.

Что это дало

Bias пойман до прода – там, где ассурасу молчала. Фикс: собрать бланки из разных источников, убрать логотип-подсказку, переобучить и снова проверить Grad-CAM.

СВЯЗЬ С БЛОКОМ 3.4

Это та самая **spurious correlation** из блока 3.4 – но теперь мы её **видим**. Интерпретация – инструмент поимки bias, а не украшение отчёта.



Блок 3.5 в четырёх пунктах – и на этом основное содержание завершено

- Одна метрика скрывает структуру ошибок. Confusion matrix показывает, какие классы путаются и где цена ошибки выше.
- Ошибочные изображения нужно смотреть глазами: общая деталь у ошибок выдаёт domain shift или bias.
- Grad-CAM показывает, на какую область кадра опиралась сеть. Общая идея интерпретации – из L09.
- Если «горячая» зона не на целевом объекте – модель выучила обманку. Интерпретация ловит bias до выката в прод.



Часть 4 – как теория переносимости работает в реальных CV-задачах безопасности



Четыре ИБ-задачи компьютерного зрения

Anti-spoofing, steganalysis, document forensics и артефакты фишинга – у каждой своя модель угроз и свои ловушки переносимости. Здесь они разобраны с числами.

В обычном CV нет противника – в безопасности он есть и активен

В типичном компьютерном зрении данные приходят «от природы»: меняются камеры и освещение, но никто не пытается обмануть модель специально. В ИБ всё иначе – у модели есть противник, который заинтересован в её ошибке и может влиять на вход. Это меняет постановку задачи.



Противник на входе

Атакующий контролирует или подменяет изображение: подносит фото к камере, встраивает скрытый канал, подделывает бланк.



Контроль условий

Противник может выбирать камеру, ракурс, освещение – то есть сознательно вызывать domain shift в свою пользу.



Несимметрия цены

Пропуск атаки (false negative) обычно куда дороже ложной тревоги. Редкий класс «атака» критичен.

*Когда противник целенаправленно меняет вход малым возмущением – это **adversarial-сюжет**; формально (включая FGSM) – в L18.*



Биометрия лица – различить живого человека и презентационную атаку

ИБ-КЕЙС

Anti-spoofing на CelebA-Spoof

Задача: классифицировать кадр лица: live / фото / экран / маска.

Данные: CelebA-Spoof – крупный публичный датасет лиц с разметкой типов атак.

Метрика: не accuracy, а APCER/BPCER (доли пропущенных атак и отклонённых живых). Цена пропуска атаки высока.

Ловушка: модель учит муар экрана конкретного типа. Новый смартфон с другим экраном – атака проходит.

Что характерно для ИБ

Класс «атака» редкий, но критичный.

Виды атак эволюционируют – модель устаревает.

Проверять перенос на новые устройства обязательно.

Асимметрия ошибок – порог настраивают под цену пропуска (линия L04 → L07).



Обнаружение скрытого канала внутри безобидного изображения

ИБ-КЕЙС

Детектор стеганографии

Задача: бинарная классификация clean / stego — есть ли встроенный скрытый канал.

Сигнал: слабые статистические отклонения младших бит. Глазами не виден, легко разрушается.

Данные: BOSSbase + стего-версии. Критично: clean и stego из одного источника.

Ловушка: augmentation со сглаживанием/JPEG уничтожает целевой сигнал; модель учит шум источника (см. блок 3.4).

Что характерно для ИБ

Целевой признак хрупкий — обращение с данными должно его сохранять.

Допустимы геометрические сдвиги; запрещены операции, меняющие пиксельную статистику.

Высокая точность подозрительна: проверь, не выучен ли источник.



Выявление подделки документов и скриншотов по визуальным артефактам

ИБ-КЕЙС

Подлинность документа / скриншота

Задача: отличить подлинный документ или скриншот от поддельного.

Признаки подделки: следы ресэмплинга, рассогласование шрифтов, двойное JPEG-сжатие, артефакты на границах вставок.

Ловушка: модель выучивает шаблон конкретного бланка вместо признаков подделки. Подделка на другом шаблоне проходит (см. кейс Grad-CAM, слайд 40).

Что характерно для ИБ

Подделки разнообразны и постоянно новые – нужен перенос на невиданные типы.

Сбор бланков из множества источников снижает риск выучить шаблон.

Grad-CAM – обязательная проверка: на что смотрит модель.



Распознавание поддельных интерфейсов и фишинговых страниц по виду

ИБ-КЕЙС

Поддельный интерфейс или форма входа

Задача: по скриншоту страницы определить, легитимный это интерфейс или фишинговая подмена.

Признаки: мелкие расхождения в рендеринге, шрифтах, иконках, расположении элементов формы входа.

Ловушка: набор брендов в обучении ограничен – модель выучивает «как выглядят знакомые бренды», а не саму подделку. Фишинг под новый бренд не ловится.

Что характерно для ИБ

Атакующий копирует оригинал намеренно близко – разница минимальна.

Визуальный сигнал дополняют URL, DOM, сертификатами – модель лишь часть системы.

Перенос на новые бренды и шаблоны – ключевая проверка.



Сводка: четыре ловушки ИБ-СV

48 / 56

ЧАСТЬ 4 · ПРАКТИКА ИБ

Один и тот же механизм провала повторяется во всех четырёх задачах

Разные ИБ-задачи компьютерного зрения проваливаются по одной схеме: модель находит лёгкую опору, коррелирующую с меткой в обучающих данных, но не связанную с настоящей задачей. Вот эти опоры-обманки в собранном виде.

⚠ Фон вместо объекта

Класс снят в одной обстановке – модель учит обстановку, а не цель.

⚠ Источник вместо сигнала

Шум камеры коррелирует с классом – модель учит устройство (steganalysis, anti-spoofing).

⚠ Шаблон вместо подделки

Узнаётся знакомый бланк/бренд, а не признаки фальсификации (forensics, фишинг).

⚠ Clean-test вместо переноса

Высокая точность на «своём» домене принимается за готовность к продю.



Финальная фиксация тезиса – почему чистой точности в ИБ недостаточно

⚠ ЧАСТАЯ ОШИБКА

«Модель показала 99% на тесте – она безопасна»

Clean-test измеряет качество на «чистых» данных того же распределения, что и обучение. Это необходимая, но совсем не достаточная проверка для модели, работающей против активного противника.

ПОЧЕМУ ЭТО НЕВЕРНО

Высокая clean-ассурансу не гарантирует ни **переносимости** (новый источник – другое распределение), ни **adversarial-устойчивости** (противник специально подбирает вход, ломающий модель). Это две разные оси надёжности, и clean-test не измеряет ни одну из них до конца.

Что проверять дополнительно: качество на новых источниках (перенос); поведение на редком критичном классе; устойчивость к малым возмущениям входа. Полная adversarial-картина для CV – в L18.



Ключевые тезисы

- 1 Изображение – отдельная модальность.** Массив пикселей, где важны локальность и положение, а не строка таблицы.
- 2 CNN извлекают локальные признаки.** Свёртка + pooling строят иерархию: края → текстуры → части → объекты.
- 3 Transfer learning экономит данные,** но несёт supply-chain риск чужого backbone (L19).
- 4 Augmentation должен соответствовать задаче.** В steganalysis агрессивное сглаживание уничтожает целевой сигнал.
- 5 Domain shift неизбежен.** Камера, свет, фон, источник – распределение входа меняется в проде.
- 6 Переносимость проверяется, не предполагается.** Split по источникам; тест должен моделировать новый домен.
- 7 Clean-test ≠ безопасность.** Нужны проверки переноса и adversarial-устойчивости (L17, L18).



Где применять, где не применять

51 / 56

ЧАСТЬ 5 · ИТОГИ

Трезвый взгляд: CNN – мощный инструмент, но не универсальный ответ

✓ подходит, когда

достаточно размеченных данных или есть близкий предобученный backbone;

целевой признак действительно визуальный и локальный;

домен эксплуатации стабилен или его сдвиг можно охватить данными;

есть возможность проверить перенос на новых источниках.

⚠ ОСТОРОЖНО, КОГДА

данных мало, а простой baseline не проверен – сначала baseline (L08, L13);

домены обучения и прода сильно расходятся и это не покрыть данными;

целевой сигнал хрупкий (steganalysis) – стандартные пайплайны его рушат;

против модели действует адаптивный противник – нужна adversarial-оценка (L18).



Куда ведут линии этой лекции – для самостоятельной навигации

Темы L14 продолжаютсЯ в других лекциях. Если какой-то сюжет зацепил – вот где он раскрывается дальше.

L17

Устойчивость и drift

Domain shift, который мы вводили, – это non-adversarial drift. Стресс-тесты и меры против сдвига.

L18

Adversarial

Противник, целенаправленно ломающий вход. FGSM, evasion, threat modeling для CV – формально.

L19

Poisoning, supply-chain

Риск чужого backbone из transfer learning раскрывается полностью: backdoor и атаки на артефакты.

L09

Интерпретируемость

Grad-CAM – частный случай. Общая методология интерпретации и анализа ошибок.

L15

Тексты и эмбединги

Другая модальность данных. Та же логика baseline и переносимости – но для текста.



Базовый минимум для понимания темы

- 1 Bishop, Pattern Recognition and Machine Learning**
Глава 5 – нейронные сети (основы, обратное распространение). Фундамент, на котором стоит вся лекция.
- 2 Hastie, Tibshirani, Friedman – The Elements of Statistical Learning**
Глава 11 – нейронные сети. Статистический взгляд, связь с baseline-моделями курса.
- 3 Goodfellow, Bengio, Courville – Deep Learning**
Глава 9 – свёрточные сети (convolution, pooling, рецептивное поле). Основной источник по CNN.

Главы 5 (Bishop) и 11 (Hastie-Tibshirani-Friedman) – те же, что в L13: нейросети вводятся там, здесь применяются к изображениям.



Для углубления и для тех, кто хочет попробовать руками

Для углубления

Selvaraju et al. (2017) – Grad-CAM. Оригинальная статья про визуальную интерпретацию CNN.

Обзоры domain shift / domain adaptation в CV. Как формально измеряют и снижают сдвиг.

Boroumand, Chen, Fridrich (2019) – deep steganalysis.

Современный взгляд на детектирование стеганографии сетями.

Практика и датасеты

PyTorch – Transfer Learning Tutorial. frozen backbone и fine-tuning на практике.

torchvision.transforms. Документация по augmentation – какие преобразования доступны.

CelebA-Spoof. Датасет для anti-spoofing с разметкой типов атак.

BOSSbase. Эталонный датасет для задач steganalysis.



Ключевые термины лекции

convolution

Операция локального фильтра, скользящего по изображению с общими весами.

feature map

Карта откликов одного фильтра – где в кадре встретился его паттерн.

pooling

Сжатие карты признаков с локальной устойчивостью к сдвигу (max/average).

CNN

Свёрточная сеть: чередование conv и pooling + полносвязный слой с softmax.

backbone

Предобученная свёрточная часть сети, переиспользуемая в transfer learning.

transfer learning

Перенос признаков предобученной сети на новую задачу.

fine-tuning

Дообучение backbone под свою задачу с малым learning rate.

augmentation

Случайные реалистичные преобразования обучающих изображений.

Ключевые термины лекции

domain shift

Расхождение распределений обучения и эксплуатации изображений.

dataset bias

Систематическое искажение в данных, ведущее к ложным опорам модели.

spurious correlation

Ложная связь признака и метки, есть в данных, но не в реальности.

Grad-CAM

Тепловая карта областей, повлиявших на предсказание (идея из L09).

steganalysis

Обнаружение скрытого канала (стеганографии) внутри изображения.

anti-spoofing

Различение живого лица и презентационной атаки в биометрии.

presentation attack

Подмена биометрии: фото, видео с экрана, маска.

document forensics

Выявление подделки документов и скриншотов по артефактам.