



ЛЕКЦИЯ 17

Устойчивость моделей к шуму, выбросам и сдвигу данных

Машинное обучение и безопасность систем

Магистратура НИУ ВШЭ (МИЭМ) · ОП «Информационная безопасность и технологии ИИ»

Автор: Силаев Ю. В. · Время изучения: ≈ 60-75 минут



Главная мысль, прежде чем углубляться в детали

Модель, показавшая отличное качество на тестовой выборке, ещё не доказала свою надёжность. Тест фиксирует прошлое распределение данных, а реальная эксплуатация живёт в среде, которая меняется сама: появляется шум, возникают выбросы, сдвигается состав пользователей, обновляется инфраструктура, меняются источники данных. В информационной безопасности это происходит особенно быстро.

КЛЮЧЕВОЙ ТЕЗИС

Надёжность модели определяется не только качеством на исходной выборке, но и устойчивостью к разумным изменениям данных, шума и условий применения. Эту устойчивость нужно проверять отдельно, а не считать следствием высокой точности.

Рамка лекции: здесь разбираем **non-adversarial drift** – среда меняется сама, без активного противника. Целенаправленные атаки на вход модели – это уже **L18**.



Учебные результаты

После изучения лекции вы научитесь:

- различать шум в данных, выбросы, доменный сдвиг и OOD-ситуацию;
- отличать non-adversarial drift (L17) от adversarial perturbation (L18);
- видеть, как устойчивость модели связана с реальной эксплуатацией;
- проектировать базовые стресс-тесты для проверки модели;
- анализировать деградацию метрик на изменённых подвыборках;
- понимать роль confidence, калибровки и uncertainty на прикладном уровне;
- выявлять подгруппы данных, на которых модель нестабильна;
- формулировать минимальные меры снижения риска деградации.



Что нужно знать до начала

4 / 52

ЧАСТЬ 1 · ВВЕДЕНИЕ

Эта лекция опирается на материал предыдущих

Лекция L17 не вводит понятия метрик, интерпретируемости или аномалий заново – она собирает их в единую рамку устойчивости.

L04

Метрики качества и цена ошибок – Под сдвигом мы будем заново перепроверять именно эти метрики.

L09

Интерпретируемость и slice analysis – Инструментарий разбора подгрупп – основа стресс-тестов.

L11

Аномалии и OOD – Методы обнаружения OOD-объектов; здесь – на уровне интуиции.

L12

Concept drift и временной анализ – Временная механика drift; здесь – общая рамка устойчивости.

L14

Domain shift в задачах изображений – Перенос качества на новые данные – частный случай сдвига.



План лекции

5 / 52

ЧАСТЬ 1 · ВВЕДЕНИЕ

7 частей · 52 слайда · ≈ 60-75 минут изучения

1	Введение	сл. 1-5	6-8 мин
2	Мотивация: почему тест врёт о будущем	сл. 6-9	5-6 мин
3	Основное содержание: типология, виды сдвига, стресс-тесты, калибровка	сл. 10-41	38-48 мин
4	Связки с практикой ИБ	сл. 42-46	6-8 мин
5	Итоги и мост к L18	сл. 47-49	3-4 мин
6	Источники для углубления	сл. 50-51	2-3 мин
7	Глоссарий	сл. 52	1-2 мин



Реальная ситуация, с которой начинается тема устойчивости

ИБ-КЕЙС

Антифрод-модель банка восемь месяцев стабильно держала **recall ≈ 0.94** на тестовой выборке и в проде. Затем банк запустил оплату через **новый платёжный канал (QR и СБП)**. Состав транзакций изменился: другие суммы, другое время суток, другие торговые точки. Уже на второй неделе recall на операциях нового канала упал до **0.61**, а доля пропущенного фрода выросла втрое. Метрики на старом тестовом наборе при этом не изменились — деградацию никто не заметил три недели.

Что произошло? Сама модель не менялась. Изменились **данные вокруг неё** — и старый тест перестал говорить правду о её надёжности. Именно это мы и научимся ловить.



Почему высокая метрика на test set не равна надёжности в эксплуатации

Когда мы делим данные на train и test, обе части берутся из **одного и того же распределения** – из того, что уже собрано. Тестовая метрика честно отвечает на вопрос «как модель работает на данных, похожих на обучающие». Но эксплуатация задаёт другой вопрос: «как модель работает на данных, которые придут **завтра**». Если завтрашние данные сместятся, тестовая оценка становится оценкой устаревшего мира.

ТЕСТ ОТВЕЧАЕТ

«Насколько модель хороша на данных, похожих на те, что я уже видела?»

ЭКСПЛУАТАЦИЯ СПРАШИВАЕТ

«Насколько модель надёжна на данных, которые придут завтра и могут оказаться другими?»

Вывод: устойчивость – это отдельный вопрос к модели, и тестовая метрика на него не отвечает.



Частая ошибка: «хороший test score – значит надёжно»

Самое распространённое заблуждение про устойчивость моделей

⚠ ЧАСТАЯ ОШИБКА

«Модель показала 0.94 на тесте – значит, она надёжна и готова к эксплуатации. Если метрика высокая, проверять больше нечего».

ПОЧЕМУ ЭТО НЕВЕРНО

Высокий test score измерен на **застывшем срезе прошлого**. Он ничего не говорит о том, что будет при смене источников данных, появлении новых подгрупп или дрейфе распределения. Последствия типичны и дороги:

- тихая деградация – качество падает, но никто не смотрит;
- рост числа пропусков (FN) ровно там, где цена ошибки максимальна;
- потеря доверия аналитиков, которые первыми замечают, что модель «поплыла».



Что мы разберём дальше

9 / 52

ЧАСТЬ 2 · МОТИВАЦИЯ

Четыре смысловых блока основного содержания (Часть 3)

Дальше мы движемся от «что вообще может пойти не так с данными» к конкретным инструментам проверки и мерам снижения риска:

Б1

Единая типология

Шум, выброс, доменный сдвиг, OOD – что это и чем различаются.

Б2

Виды сдвига

Covariate shift, label shift, место concept drift – на прикладном уровне.

Б3

Стресс-тесты

Как намеренно проверять устойчивость и находить нестабильные подгруппы.

Б4

Уверенность и меры

Калибровка, чрезмерная уверенность, меры снижения риска деградации.



БЛОК 1

Что вообще может пойти не так с данными

Прежде чем проверять устойчивость, нужен общий язык. В этом блоке мы строим единую типологию из четырёх явлений: шум, выброс, доменный сдвиг и OOD-объект. Это четыре разные причины, по которым модель может деградировать, – и путать их нельзя.



Главное понятие лекции – то, что мы будем проверять

ОПРЕДЕЛЕНИЕ

Устойчивость (robustness) модели – способность сохранять приемлемое качество при разумных изменениях данных, шума и условий применения – а не только на той выборке, на которой модель обучалась и тестировалась.

Ключевое слово – **«разумные изменения»**. Мы не требуем, чтобы модель работала на чём угодно: объект из совершенно другого мира она имеет право не распознать. Но если состав пользователей слегка сдвинулся, источник логов сменился, а во входе появился реалистичный шум – качество не должно обрушиваться.

Устойчивость – это про **предсказуемое поведение под предсказуемыми изменениями**.

Важно: устойчивость – отдельный объект проверки. Высокая точность на исходном датасете её не гарантирует и не заменяет.



Два источника шума с разными последствиями для модели

Шум – это случайные искажения в данных. Важно различать, где именно он возник: в признаках объекта или в его метке. Это разные проблемы, и лечатся они по-разному.

ШУМ В ПРИЗНАКАХ (x)

Искажены значения признаков: сбой сенсора, пропуски, ошибка парсинга лога, разный формат полей из разных источников.

Эффект: модель видит «смазанный» вход; качество падает плавно, чаще предсказуемо.

ШУМ В РАЗМЕТКЕ (y)

Неверные метки: аналитик ошибся, разметка устарела, атаку поместили как Benign. Особенно коварен – модель учится на лжи.

Эффект: смещается сама цель обучения; деградация скрытая и трудно диагностируемая.

В ИБ шум в разметке встречается часто: метки атак ставятся постфактум, задержка и ошибки разметки – норма.



Выброс: ошибка данных или редкий объект?

13 / 52

ЧАСТЬ 3 · ТИПОЛОГИЯ

Один и тот же объект – две принципиально разные трактовки

ОПРЕДЕЛЕНИЕ

Выброс (outlier) – объект, сильно отклоняющийся от основной массы данных по одному или нескольким признакам. Сам по себе факт отклонения ничего не говорит о его причине.

ТРАКТОВКА 1 – ОШИБКА ДАННЫХ

Сбой измерения, битый лог, опечатка. Такой выброс – мусор, его разумно чистить или чинить.

ТРАКТОВКА 2 – РЕАЛЬНЫЙ РЕДКИЙ ОБЪЕКТ

Редкая, но настоящая атака, аномальная сессия, новый паттерн. В ИБ это часто и есть то, что нужно поймать.

Решает не статистика, а смысл: прежде чем удалить выброс, нужно понять, что это за объект. В безопасности «выброс» и «цель детектирования» – нередко одно и то же.



Частая ошибка: автоматически удалять выбросы

14 / 52

ЧАСТЬ 3 · ТИПОЛОГИЯ

Стандартный приём из учебников статистики опасен в ИБ

⚠ ЧАСТАЯ ОШИБКА

«Перед обучением уберём все объекты за пределами 3σ – это же выбросы, они портят модель».

ПОЧЕМУ ЭТО НЕВЕРНО

В задачах безопасности редкий объект чаще всего и есть **целевой класс**. Автоматическая чистка по 3σ выкидывает именно атаки – те самые объекты, ради которых строилась модель. Что происходит:

- модель учится только на «нормальном» – и в проде не узнаёт атаку;
- recall по редким классам падает, но на «почищенном» тесте этого не видно;
- чистка маскирует проблему вместо того, чтобы её решить.



Распределение данных в эксплуатации уехало от обучающего

ОПРЕДЕЛЕНИЕ

Доменный сдвиг – ситуация, когда распределение данных в эксплуатации отличается от распределения, на котором модель обучалась: меняется либо распределение признаков $P(x)$, либо связь признаков с целью $P(y|x)$, либо и то и другое.

В отличие от шума, сдвиг – это **не случайность, а систематическое смещение**. Среда изменилась устойчиво: новый источник логов, другой контингент пользователей, обновлённая инфраструктура. Модель продолжает работать так, как её научили, – но мир вокруг стал другим. Виды сдвига (covariate, label) мы детально разберём в следующем блоке.

Связь с курсом: временную механику и детектирование дрейфа во времени вы видели в **L12 (concept drift)**; здесь – общая рамка устойчивости, в которую дрейф встраивается.



Out-of-distribution: вход «из другого мира»

ОПРЕДЕЛЕНИЕ

OOD-объект (out-of-distribution) – вход, который не принадлежит распределению обучающих данных вообще – не «сдвинутая» версия знакомого, а принципиально новый тип объекта, которого модель никогда не видела.

Граница тонкая, но важная. Доменный сдвиг – это знакомые объекты в изменившихся пропорциях; OOD – это объект, для которого у модели вообще нет опоры. Пример: антифрод-модель обучалась на карточных операциях, а на вход пришёл криптоплатёж – это не сдвиг, это другой мир. Опасность OOD в том, что модель всё равно выдаёт ответ, часто **уверенно и неправильно**.

Связь с курсом: методы обнаружения аномалий и OOD вы разбирали в **L11**; здесь нам достаточно интуиции «объект вне распределения».



Мини-резюме блока 1: четыре явления

17 / 52

ЧАСТЬ 3 · ТИПОЛОГИЯ

Что это, типичная причина, чем опасно – на одном слайде

Явление	Что это	Типичная причина	Чем опасно
Шум	Случайные искажения в x или y	Сбой сенсора, ошибка разметки	Смазывает вход или цель обучения
Выброс	Объект, далёкий от основной массы	Битый лог – или редкая атака	Чистить нельзя вслепую: можно убить целевой класс
Доменный сдвиг	Систематический сдвиг $P(x)$ и/или $P(y x)$	Новый источник, новый контингент	Модель решает старую задачу в новом мире
OOD	Объект вне обучающего распределения	Принципиально новый тип входа	Уверенный, но бессмысленный ответ

Главное: это четыре **разные** причины деградации. Меры против одной не работают против другой – поэтому сначала диагноз, потом лечение.



БЛОК 2

Какой именно сдвиг произошёл

«Сдвиг» – слишком общее слово. Чтобы выбрать правильную меру, нужно понять, что именно сместилось: распределение входов или связь входа с ответом. В этом блоке мы разложим domain shift на covariate shift и label shift и посмотрим, как сдвиг бьёт по порогу и цене ошибок.



Сдвигается распределение входов, но не связь «вход → ответ»

$$P_{\text{train}}(x) \neq P_{\text{test}}(x), \quad \text{но} \quad P(y | x) - \text{неизменна}$$

Меняется то, **какие объекты приходят** на вход, но правило «по таким признакам – такой ответ» остаётся прежним. Модель не ошибается в логике – она просто чаще оказывается в тех областях пространства признаков, где видела мало примеров.

ПРИМЕР В ИБ

Переход компании на удалённый режим: пользователи стали заходить с домашних IP, в другое время суток, с других устройств. Признаки трафика **сдвинулись**, но «подозрительное поведение всё ещё подозрительно» – связь $P(y|x)$ та же. Это covariate shift.



Сдвигается распределение классов, а не их признаки

$$P_{\text{train}}(y) \neq P_{\text{test}}(y), \quad \text{но} \quad P(x | y) - \text{неизменна}$$

Меняется **доля классов**, при этом сами классы выглядят так же, как раньше. Атака не стала выглядеть иначе – её просто стало больше или меньше. Это особенно важно для порога: модель, откалиброванная под старый баланс, на новом балансе систематически промахивается.

ПРИМЕР В ИБ

Во время массовой фишинговой кампании доля вредоносных писем за неделю выросла с 2% до 30%. Сами письма не изменились – изменилась их **частота**. Антиспам-модель с прежним порогом начинает массово ошибаться. Это label shift.



Covariate vs label: как различать

21 / 52

ЧАСТЬ 3 · ВИДЫ СДВИГА

Симптом → вероятный тип сдвига → что проверить

На практике тип сдвига распознают по симптомам. Это не строгая диагностика, а первая гипотеза, которая подсказывает, куда смотреть:

Симптом	Вероятный сдвиг	Что проверить
Входы выглядят непривычно, метки приходят с прежней логикой	Covariate	Распределение признаков $P(x)$: гистограммы, PSI по фичам
Признаки те же, но баланс классов резко изменился	Label	Долю положительного класса во времени; порог решения
Изменилось и то и другое – модель «поплыла» целиком	Смешанный / concept drift	Slice-метрики по времени и сегментам (см. Блок 3)

PSI – Population Stability Index, простой показатель того, насколько распределение признака уехало относительно обучающего. Подробно – в инструментарию Блока 3.



Где проходит граница между L17 и L12

Concept drift – это случай, когда меняется сама связь $P(y | x)$: то, что вчера считалось нормой, сегодня – атака, и наоборот. Это самый тяжёлый вид сдвига, потому что устаревает не баланс и не входы, а **правило принятия решения**.

В L12 (временной анализ)

Временная механика дрейфа: как его детектировать во времени, окна, задержка меток, rolling-валидация.

Здесь, в L17 (рамка устойчивости)

Место дрейфа среди других угроз устойчивости: одна из причин деградации наряду с шумом, выбросами и сдвигом.

Не дублируем L12: здесь дрейф нужен как элемент общей картины, а не как отдельная техника детектирования.



Сквозная линия курса: L04 → L07 → L09 → L17 → L20

Порог решения выбирается под **конкретный баланс классов и конкретную цену ошибок** (это вы делали в L07). Но и баланс, и цена ошибок живут в распределении данных – а оно сдвигается. Тот порог, что был оптимален вчера, под сдвигом перестаёт быть оптимальным.

При label shift

Вырос положительный класс → прежний порог даёт лавину ложных срабатываний или, наоборот, пропусков. Порог нужно пересчитать.

При covariate shift

Скоры «сползают» в новую область → распределение score меняется, и фиксированный порог режет уже не там. Нужна рекалибровка.

Вывод линии: порог – не константа, заданная однажды. Под сдвигом его, как и цену ошибок, нужно перепроверять. В L20 это войдёт в итоговый reliability note.



Почему меры против шума не лечат сдвиг

⚠ ЧАСТАЯ ОШИБКА

«Качество просело – добавим регуляризаци и сглаживания, как при шумных данных, и всё вернётся».

ПОЧЕМУ ЭТО НЕВЕРНО

Шум и сдвиг – **разные болезни**. Шум добавляет случайный разброс вокруг прежней закономерности; сдвиг меняет саму закономерность или состав данных. Меры против шума на сдвиг почти не действуют:

- регуляризация уменьшает переобучение, но не «возвращает» уехавшее распределение;
- сглаживание прячет симптом, тогда как сдвигу нужен пересчёт порога или переобучение;
- пока диагноз неверный, время уходит, а деградация продолжается.



Мини-резюме блока 2

25 / 52

ЧАСТЬ 3 · ВИДЫ СДВИГА

Что унести про виды сдвига

Covariate shift – меняется $P(x)$, связь $P(y|x)$ та же – приходят непривычные входы.

Label shift – меняется $P(y)$ – баланс классов; сами классы выглядят по-прежнему.

Concept drift – меняется само правило $P(y|x)$; самый тяжёлый случай (механика – в L12).

Порог под сдвигом – оптимальный вчера порог сегодня промахивается – его нужно пересчитывать.

Главный риск – лечить сдвиг как шум: меры одной природы не работают против другой.



БЛОК 3

Как проверять устойчивость намеренно

Мы научились различать причины деградации. Теперь – как искать их заранее, не дожидаясь инцидента в проде. В этом блоке: стресс-тесты как способ намеренно «потрясти» модель и slice-evaluation как способ увидеть, на каких подгруппах она ломается.



Проверка устойчивости намеренным изменением данных

ОПРЕДЕЛЕНИЕ

Стресс-тест – процедура, в которой мы сознательно подаём модели изменённые или ухудшенные данные и измеряем, как падает качество. Цель – не получить высокий score, а найти границу, за которой модель перестаёт быть надёжной.

Логика обратная привычной. Обычная оценка спрашивает «насколько хорошо», стресс-тест спрашивает «при каком воздействии становится плохо». Мы не верим модели на слово: вместо декларации «она устойчива» мы получаем кривую деградации – на сколько падает recall при 10% шума, при смене источника, при временном сдвиге.

Важно: стресс-тест проверяет устойчивость к **естественным** изменениям. Целенаправленные атаки на вход – отдельная процедура (L18).



Пять типовых воздействий, которыми проверяют ML-модель

Каждый тест имитирует одну из причин деградации из Блока 1-2. Прогоняют их по очереди и смотрят, какое воздействие модель переживает, а какое – нет.

Шум во входе

Добавить случайный шум в признаки и смотреть, как падает качество.

имитирует шум в x

Пропуски

Занулить / замаскировать часть признаков – как при сбое источника.

имитирует битые данные

Смена источника

Подать данные из другого источника / периода / сегмента.

имитирует covariate shift

Временной сдвиг

Обучить на раннем периоде, проверить на позднем.

имитирует drift во времени

Новые подгруппы

Выделить сегмент, слабо представленный в обучении.

имитирует OOD-подгруппу

Сдвиг баланса

Изменить долю классов в тестовой подвыборке.

имитирует label shift



Сквозной датасет курса

СКВОЗНОЙ ДАТАСЕТ

CIC-IDS-2018 – публичный датасет сетевого трафика: около **16 млн flow-записей за 10 дней, 80 признаков** на запись, **14 типов атак + Benign**. Каждый день собирался отдельно и содержит свой набор атак (Brute Force, DoS, DDoS, инфильтрация, ботнет и др.).

Почему он удобен для темы устойчивости: данные размечены по дням, и состав атак меняется от дня к дню. Это даёт готовый, реалистичный сценарий сдвига – без искусственного зашумления. Именно на нём мы сейчас и проведём стресс-тест.



Стресс-тест: день 1 → день 2

30 / 52

ЧАСТЬ 3 · СТРЕСС-ТЕСТЫ

Временной сдвиг на CIC-IDS-2018 – что показывают цифры

ИБ-КЕЙС · ПОСТАНОВКА

Обучаем детектор атак на трафике одного дня (преобладают DoS-атаки). Проверяем на следующем дне, где состав атак другой (появляется DDoS и инфильтрация). Признаки и метрики – те же, меняется только день. Это честный временной стресс-тест.

Метрика	Day 1 (test внутри дня)	Day 2 (другой день)	Δ
Recall (атаки)	0.96	0.68	-0.28
Precision	0.93	0.71	-0.22
F1	0.94	0.69	-0.25

Вывод: внутри дня модель выглядит отличной ($F1 = 0.94$), но один день сдвига роняет F1 до 0.69. **Без стресс-теста эту хрупкость не было бы видно** – обычный random-split на перемешанных днях её скрывает.



Качество не одним числом, а по подмножествам данных

Средняя метрика по всей выборке – это среднее по больнице. Slice-evaluation измеряет качество отдельно на подмножествах (срезах) данных: по времени, источнику, сегменту пользователей, типу атаки. Модель может держать $F1 = 0.9$ в среднем и при этом полностью проваливаться на одном важном срезе.

Инструментарий – из L09

Slice analysis по подгруппам вы уже делали при анализе ошибок. Здесь тот же инструмент – но для проверки устойчивости под сдвигом.

Метрики – из L04

На каждом срезе считаем те же recall, precision, F1 и цену ошибок, что вводились в L04. Новое – не метрика, а разрез, на котором она меряется.

Идея проста: усреднение скрывает локальные провалы. Slice-evaluation их вытаскивает на свет.



Простой воспроизводимый порядок действий

1**Выбрать оси разреза**

Время (день/неделя), источник данных, сегмент пользователей, тип атаки, диапазон значений ключевого признака.

2**Посчитать метрику на каждом срезе**

Те же recall / precision / F1, что и в общей оценке (L04) – но отдельно по каждому срезу.

3**Сравнить со средней**

Найти срезы, где метрика заметно ниже общей. Это кандидаты в «нестабильные подгруппы».

4**Проверить значимость и размер**

Маленький срез может «проваливаться» случайно. Смотрим и на размер среза, и на величину провала.



Частая ошибка: средняя метрика прячет провал

Почему один агрегированный score обманчив

⚠ ЧАСТАЯ ОШИБКА

«Общий $F1 = 0.91$ – модель работает хорошо на всех данных. Разбивать по подгруппам незачем».

ПОЧЕМУ ЭТО НЕВЕРНО

Средняя метрика – это **взвешенное по размеру среднее**. Крупный «лёгкий» срез (Benign-трафик) тянет общий $F1$ вверх и маскирует провал на маленьком, но критичном срезе (редкий тип атаки). Пример:

- общий $F1 = 0.91$, но $F1$ на срезе «инфильтрация» = 0.34 – модель почти слепа к классу;
- именно этот срез – самый дорогой по цене ошибки (L04), и именно он провален;
- агрегат бодро рапортует «всё хорошо», пока в проде копятся пропуски.



Мини-резюме блока 3

34 / 52

ЧАСТЬ 3 · СТРЕСС-ТЕСТЫ

Что унести про стресс-тесты и slice-evaluation

Стресс-тест – намеренно подаём ухудшенные данные и смотрим, где модель ломается.

Каталог воздействий – шум, пропуски, смена источника, временной сдвиг, новые подгруппы, сдвиг баланса.

Временной сдвиг важнее всего в ИБ – train на дне 1 / test на дне 2 роняет F1 с 0.94 до 0.69 (CIC-IDS-2018).

Slice-evaluation – качество по срезам, а не одним числом; инструмент – из L09, метрики – из L04.

Главный риск – средняя метрика прячет провал на маленьком, но критичном срезе.



БЛОК 4

Уверенность модели и что с ней делать

Мы научились находить деградацию. Остался последний вопрос блока: можно ли доверять самой модели, когда она говорит «я уверена»? И что делать, когда стресс-тест показал хрупкость. В этом блоке – про калибровку уверенности и про базовые меры снижения риска.



Что значит «модель уверена» – и насколько этому верить

Многие модели выдают не только метку, но и **оценку уверенности** – например, вероятность класса. На практике важно различать два понятия:

Confidence (уверенность)

Насколько высок выданный моделью score для предсказанного класса. Высокий $\neq$ правильный: модель может быть уверенно права.

Calibration (калибровка)

Соответствие уверенности реальной частоте: если модель говорит «0.8», она должна быть права примерно в 80% таких случаев.

Калибровку вы вводили в L07. Здесь важен один прикладной факт: под сдвигом данных калибровка ломается раньше, чем кажется. Глубокие методы оценки неопределённости (Bayesian deep learning) – вне рамок этого курса.



Reliability under shift: почему высокий score обманывает

Главная ловушка устойчивости в эксплуатации: при сдвиге и на OOD-объектах модель не «честно сомневается», а часто выдаёт высокий score. Она экстраполирует знакомую закономерность в незнакомую область – и делает это уверенно. Чем дальше вход от обучающего распределения, тем менее осмысленна уверенность.

RELIABILITY UNDER SHIFT

Надёжность под сдвигом – это не только «какая метрика», но и «можно ли верить уверенности». Откалиброванная на обучающих данных модель под сдвигом начинает **переоценивать себя**: доля ошибок среди «уверенных» предсказаний растёт. Поэтому метрики и калибровку нужно перепроверять на свежих данных, а не доверять однажды измеренным.

Практический приём: обращать внимание на объекты, далёкие от обучающего распределения, – на них уверенный score особенно подозрителен.



Частая ошибка: уверенный score – значит надёжный

38 / 52

ЧАСТЬ 3 · МЕРЫ

Подмена надёжности уверенностью модели

⚠ ЧАСТАЯ ОШИБКА

«Модель выдала 0.99 – значит, она точно права, и проверять этот случай не нужно».

ПОЧЕМУ ЭТО НЕВЕРНО

Уверенность – это **выход модели, а не свойство реальности**. На OOD-объекте и под сдвигом высокий score чаще всего означает, что модель экстраполирует, а не «знает». Что отсюда следует:

- уверенный score не освобождает от проверки на сдвиг и калибровку;
- самые опасные ошибки – уверенные ложные срабатывания и уверенные пропуски;
- доверять надо проверенной надёжности, а не самооценке модели.



Базовый набор – без продвинутой теории robust optimization

Это не магия устойчивости, а инженерная гигиена. Каждая мера снижает риск конкретной причины деградации:

Регуляризация

Снижает переобучение → модель меньше цепляется за шум обучающей выборки.

Data augmentation

Расширяет вариативность обучения → устойчивее к шуму и мелким сдвигам входа.

Пересборка датасета

Добавить данные новых источников/периодов → закрыть пробелы распределения.

Переобучение

Регулярно дообучать на свежих данных → догонять уехавшее распределение.

Обновление признаков

Пересмотреть/добавить признаки под новую среду → вернуть разделимость.

Контроль качества данных

Проверять источники и разметку на входе → ловить шум и битые данные рано.



Какая мера против какой угрозы

40 / 52

ЧАСТЬ 3 · МЕРЫ

Сначала диагноз, потом лечение – меры не взаимозаменяемы

Главный принцип всей лекции в одной таблице: мера должна соответствовать причине. Применять «лечение» наугад – значит маскировать симптом.

Причина деградации	Уместная мера	Что НЕ поможет
Шум в признаках/разметке	Регуляризация, контроль качества данных, augmentation	Переобучение на тех же шумных метках
Covariate shift	Пересборка датасета, обновление признаков, переобучение	Только сглаживание score
Label shift	Пересчёт порога, рекалибровка под новый баланс	Регуляризация модели
Concept drift	Регулярное переобучение на свежих данных	Однократная чистка выбросов
OOD-вход	Детекция OOD (L11), fallback на человека	Доверие к уверенному score



Мини-резюме блока 4

41 / 52

ЧАСТЬ 3 · МЕРЫ

Что унести про уверенность и меры

Confidence ≠ надёжность — высокий score — это выход модели, а не доказательство правоты.

Калибровка ломается под сдвигом — уверенность нужно перепроверять на свежих данных (калибровка — из L07).

Меры — это гигиена — регуляризация, augmentation, пересборка, переобучение, обновление признаков, контроль данных.

Мера под причину — covariate ≠ label ≠ concept drift ≠ шум: лечение должно соответствовать диагнозу.

Главный риск — лечить наугад — маскировать симптом вместо устранения причины.



Среда безопасности меняется быстрее, чем во многих доменах

Тема устойчивости важна везде, но в информационной безопасности – критична. Здесь меняется и фон, и цель: инфраструктура обновляется, поведение пользователей дрейфует, а состав угроз перестраивается постоянно. Модель, отличная вчера, может стать ненадёжной за дни.

Инфраструктура

Обновление ПО и сети меняет профиль трафика и логов.

Пользователи

Переход на удалёнку, новые устройства, новые сценарии.

Источники данных

Новые каналы операций, смена форматов и поставщиков логов.

Фон угроз

Появляются новые типы фишинга, атак, ботнетов – естественно, без участия противника здесь.



Covariate shift в сетевом трафике – с признаками и метриками

ИБ-КЕЙС · ЧТО ПРОИЗОШЛО

SOC использовал модель обнаружения аномального трафика (вход – 80 признаков потока: длительность, объём, число пакетов, флаги TCP). После миграции на новый VPN-шлюз изменились средняя длительность сессии и распределение портов. **Признаки сместились, типы атак – нет. Это covariate shift.**

Метрика	До миграции	После (1-я неделя)	Δ
Recall (аномалии)	0.91	0.74	-0.17
False positive rate	0.03	0.12	+0.09

Решение: не трогать архитектуру модели, а пересобрать обучающую выборку с трафиком нового шлюза и переобучить. Recall восстановился до 0.89 за один цикл.



Два сдвига одновременно – изменились и входы, и поведение

ИБ-КЕЙС · ЧТО ПРОИЗОШЛО

Антифишинг-фильтр почты обучался до перехода компании на удалённый режим. После перехода: (1) **поведение пользователей сдвинулось** – больше внешней переписки, переходов по ссылкам с личных устройств (covariate shift); (2) **появились новые шаблоны фишинга** под удалёнку («подтвердите VPN-доступ», «обновите пароль почты»). Модель не видела таких писем в обучении – для неё это ближе к OOD.

Что показал slice-анализ: общий recall фильтра просел умеренно (0.88 → 0.80), но на срезе «письма про удалённый доступ» recall был всего **0.41** – именно новый шаблон проходил сквозь фильтр. Средняя метрика этот провал маскировала.

Решение: пересборка датасета с новыми образцами + временное усиление ручного триажа на проблемном срезе, пока модель дообучается.



Где устойчивость рушится незаметно именно в безопасности

⚠ ГЛАВНАЯ ЛОВУШКА

«Робастность по заявлению»: модель называют устойчивой, потому что она хорошо отработала на одном тестовом срезе – без фактического stress testing.

Метки приходят с задержкой

Атаку размечают постфактум – деградацию видно не сразу, а через недели.

Редкий класс = цель

Именно редкие объекты (атаки) важнее всего, а их легко принять за выбросы.

Быстрый дрейф фона

Нормальное поведение само меняется – базовая линия «нормы» не статична.

Дисбаланс маскирует провал

Огромный Benign-класс тянет среднюю метрику вверх, пряча провал на атаках.



Что проверять регулярно

46 / 52

ЧАСТЬ 4 · ИБ

Практический чек-лист повторной проверки качества в ИБ

Устойчивость – не разовая проверка, а привычка. Минимальный набор разрезов, по которым стоит перепроверять модель в эксплуатации:

По времени



День к дню, неделя к неделе: не падает ли качество на свежих данных.

По источникам



Каждый новый канал/шлюз/поставщик логов – отдельный срез.

По сегментам



Группы пользователей, типы устройств, географии.

По типам атак



Recall отдельно по каждому классу угроз, не только в среднем.

Калибровку



Соответствует ли уверенность реальной частоте на новых данных.

Порог



Не сместился ли оптимальный порог под новый баланс классов.



Семь ключевых утверждений

- 1 Высокое качество на тесте $\neq$ надёжность в эксплуатации: устойчивость – отдельный объект проверки.
- 2 Шум, выброс, доменный сдвиг и OOD – четыре разные причины деградации; путать их нельзя.
- 3 Сдвиг бывает covariate (меняется $P(x)$), label (меняется $P(y)$) и concept drift (меняется $P(y|x)$).
- 4 Под сдвигом порог и цена ошибок перестают быть оптимальными – их нужно пересчитывать.
- 5 Стресс-тесты и slice-evaluation вытаскивают хрупкость, которую средняя метрика прячет.
- 6 Уверенность модели – её выход, а не доказательство правоты: под сдвигом калибровка ломается.
- 7 Мера должна соответствовать причине: сначала диагноз, потом лечение.



Границы темы L17 – чтобы не выйти за рамки

ПРИМЕНЯЙТЕ L17, КОГДА

- проверяете модель перед / во время эксплуатации;
- среда, источники или пользователи могут измениться;
- нужно понять, на каких подгруппах модель хрупка;
- качество просело, и надо поставить диагноз.

ЭТО – ВНЕ РАМОК L17

- строгая теория robust optimization, DRO;
- conformal prediction и Bayesian deep learning;
- production monitoring как отдельная дисциплина;
- **состязательные атаки на вход – это L18.**

Связь с курсом: stress tests войдут в итоговый reliability note в L20; интерпретация подгрупп – продолжение L09.



Две компоненты модели угроз ML – и где проходит граница

Эта лекция охватила первую компоненту threat modeling для ML: **среда меняется сама**. Но есть и вторая: вход модели меняет **целенаправленный противник**. Это принципиально разные модели угроз – и меры против них разные.

L17 – ЭТА ЛЕКЦИЯ

Non-adversarial drift

Природа меняется сама: шум, выбросы, covariate/label shift, OOD, concept drift.

Меры: регуляризация, augmentation, пересборка, переобучение, пересчёт порога.

L18 – СЛЕДУЮЩАЯ ЛЕКЦИЯ

Adversarial perturbation

Противник целенаправленно меняет вход: evasion, целевые возмущения, перенос атак.

Меры: иные по природе – ансамбли проверок, hardening, fallback-механизмы.

Главное правило развилки: не применяйте меры одной природы против угроз другой. Вместе L17 и L18 образуют полную двухкомпонентную модель угроз для ML-компонента.



Обязательное – главы из учебников и базовая статья

Hastie, Tibshirani, Friedman – The Elements of Statistical Learning

Гл. 7 «Model Assessment and Selection» – оценка обобщающей способности, источники ошибки, основа понимания деградации под сдвигом.

Bishop – Pattern Recognition and Machine Learning

Гл. 1 (introduction): bias-variance, переобучение, обобщение – фундамент, на котором строится понятие устойчивости.

Quiñonero-Candela et al. – Dataset Shift in Machine Learning (MIT Press, 2009)

Гл. 1-3: типология dataset shift (covariate / prior / concept) – академический первоисточник темы.



Дополнительно, практические tutorиалы и датасет

ДОПОЛНИТЕЛЬНО

- Moreno-Torres et al. — A unifying view on dataset shift (Pattern Recognition, 2012): обзор видов сдвига.
- Документация scikit-learn: модуль metrics и приёмы оценки качества по подвыборкам.

ПРАКТИЧЕСКИЕ ТУТОРИАЛЫ

- scikit-learn User Guide: cross-validation и оценка на сдвинутых данных.
- Evidently / scikit-learn cookbook: расчёт PSI и сравнение распределений признаков.

ДАТАСЕТ

- CIC-IDS-2018 (Canadian Institute for Cybersecurity): данные размечены по дням — готовый сценарий временного сдвига.

Связь с курсом: итоговый *reliability note* и фиксация *stress-тестов* — в L20.



Ключевые термины

Устойчивость

сохранение качества при разумных изменениях данных и условий.

Шум

случайные искажения в признаках (x) или в разметке (y).

Выброс

объект, далёкий от основной массы; в ИБ часто – сама цель.

Доменный сдвиг

систематическое смещение распределения данных.

Covariate shift

меняется $P(x)$, связь $P(y|x)$ сохраняется.

Label shift

меняется $P(y)$ – баланс классов.

Concept drift

меняется само правило $P(y|x)$.

OOD

объект вне обучающего распределения.

Стресс-тест

намеренная подача ухудшенных данных для проверки.

Slice-evaluation

оценка качества по подмножествам данных.

Калибровка

соответствие уверенности реальной частоте.

Reliability under shift

надёжность и доверие к уверенности под сдвигом.

PSI

Population Stability Index – мера ухода распределения.